راهنمای نوشتن مقاله

دسته‌بندی گزارش‌های حوادث دریایی با مدل‌های زبانی، از صفر تا مقاله

محمد مهدی عرب · مهر ۱۴۰۵

پیش از شروع: این راهنما را چطور بخوانی

این راهنما دو کار می‌کند:

۱. **تو را از صفر با همه‌چیز آشنا می‌کند:** مسئله، مفاهیم پایه، روش، نتایج.
۲. **برای هر بخش مقاله می‌گوید چه بنویسی.** برای بخش‌های مهم، جمله‌ی پیشنهادی انگلیسی هم آمده است.

هر بخش دو قسمت دارد:

- **به زبان ساده:** برای فهمیدن.
- **در مقاله:** چه چیزی و به چه ترتیبی بنویسی.

فرض کرده‌ام مقاله **انگلیسی** و برای یک **نشریه‌ی بین‌المللی** است. اگر فارسی بنویسی، ساختار همین است و فقط جمله‌ها را ترجمه کن.

همه‌ی نتایج آمده‌اند. آخرین به‌روزرسانی (۲۱ مهر ۱۴۰۵): نتایج افزایش داده با LLM و BiLSTM بزرگ‌تر. گزارش کامل با همه‌ی شکل‌ها: `presentations/1405-7-21_full-report/report_fa.pdf` .

قانون طلایی مقاله‌نویسی: هر جمله‌ای که می‌نویسی باید یا **عدد** پشتش باشد، یا **منبع**. اگر هیچ‌کدام نیست، آن جمله ادعای بی‌پشتوانه است. حذفش کن یا نرمش کن.

بخش ۱: کل داستان در یک صفحه

به زبان ساده

یک مقاله **یک داستان** است. داستان ما شش جمله است:

۱. **مسئله:** گزارش‌های حوادث دریایی را باید بر اساس **نوع حادثه** دسته‌بندی کرد. کلاس‌های خطرناک (آتش‌سوزی، واژگونی، غرق‌شدن) **کمیاب‌اند** و مدل‌ها آن‌ها را کم یاد می‌گیرند.

۲. **شکاف:** مقاله‌ی مرجع (Zhao et al., 2025) ادعا کرده BiLSTM روی BERT کمک می‌کند، ولی مدل‌ها را با تنظیمات **متفاوت** و فقط **یک بار** اجرا کرده، و معیارش **accuracy** است که روی داده‌ی نامتوازن گمراه‌کننده است.

۳. **کار ما:** روی داده‌ی **عمومی** MAIB، مدل‌ها را با تنظیمات **کاملاً یکسان** و **چند seed** مقایسه کردیم؛ با **Macro-F1** و **recall هر کلاس**.

۴. **سؤال‌ها:** آیا BiLSTM و attention کمک می‌کنند؟ کدام روش مقابله با نامتوازنی بهتر است: وزن‌دهی تابع زیان، نمونه‌گیری دوباره، یا تولید داده با LLM؟

۵. **یافته‌ها:** BERT از روش کلاسیک بهتر است. BiLSTM و attention بهبود معناداری نمی‌دهند. **تابع زیان وزن‌دار (wce)** بیشترین کمک را می‌کند. oversampling کمک نمی‌کند. attention یک زیرگروه پنهان (SOLAS) را آشکار می‌کند.

۶. **پیام اصلی:** سقف عملکرد بیشتر از **ابهام برچسب** می‌آید تا از معماری. پس پیچیده‌تر کردن مدل راه‌حل نیست.

ساختار مقاله (IMRaD)

تقریباً همه‌ی مقاله‌های پژوهشی این ساختار را دارند:

بخش مقاله	چه سؤالی را جواب می‌دهد	بخش این راهنما
Title + Abstract	کل کار در ۲۵۰ کلمه	بخش ۱۱
1. Introduction	چرا مهم است؟ چه کم است؟ ما چه کردیم؟	بخش ۲
2. Related Work	دیگران چه کرده‌اند؟	بخش ۴
3. Data	با چه داده‌ای؟	بخش ۵
4. Methods	دقیقاً چه کردیم؟	بخش‌های ۳ و ۶
5. Experimental Setup	چطور مقایسه کردیم؟	بخش ۷
6. Results	چه شد؟ (فقط عدد، بدون تفسیر)	بخش ۸
7. Discussion	یعنی چه؟ چرا؟	بخش ۹
8. Limitations, Conclusion	کجا ضعیف است؟ قدم بعدی چیست؟	بخش ۱۰

بخش ۲: مسئله از صفر (برای Introduction)

۲-۱. MAIB و گزارش حادثه

MAIB (Marine Accident Investigation Branch) سازمان بررسی سوانح دریایی بریتانیاست. برای هر حادثه یک گزارش کوتاه ثبت می‌کند. یک گزارش واقعی از داده‌ی تو، با برچسب **Flooding**:

> *Sailing yacht suffered water ingress resulting in tow to safety. A sailing yacht with four crew onboard suffered water ingress after losing the propeller. The crew, who were wearing lifejackets, were bailing by hand as the bilge pump was not working. Two search and rescue (SAR) vessels were tasked to assist and bail out the yacht. The yacht was then towed to a harbour.*

یک کارشناس MAIB **نوع حادثه** را تعیین کرده: Flooding / Foundering. این برچسب در داده با نام «Main Event L1» آمده است.

۲-۲. «دسته‌بندی متن» یعنی چه؟

```
ورودی: متن یک گزارش        ←  مدل  ←  خروجی: یکی از ۹ نوع حادثه
```

مدل از روی هزاران گزارش برچسب‌دار **یاد می‌گیرد** که هر نوع حادثه با چه کلمه‌ها و الگوهایی می‌آید. بعد برای گزارش جدید، خودش برچسب را حدس می‌زند. به این «یادگیری با نظارت» (supervised learning) می‌گویند، چون جواب‌های درست را در آموزش نشانش می‌دهیم.

۲-۳. چرا مهم است؟

- **سرعت:** دسته‌بندی دستی هزاران گزارش وقت‌گیر است.
- **یکدستی:** دو کارشناس ممکن است یک گزارش را متفاوت برچسب بزنند.
- **پیشگیری:** آمار درست از نوع حوادث به سیاست‌گذاری ایمنی کمک می‌کند. مثلاً اگر بدانیم آتش‌سوزی موتور قایق‌های تفریحی زیاد شده، می‌شود برایش برنامه گذاشت.

۲-۴. سه چالش

۱. نامتوازنی (class imbalance). کلاس‌ها خیلی نابرابرند:

کلاس	تعداد گزارش
Accident to person(s)	1,662
Capsizing / Listing	99

نسبت بزرگ‌ترین به کوچک‌ترین **۱۶.۸** است. و **خطرناک‌ترین کلاس‌ها کمیاب‌ترین‌اند.** مدلی که فقط دنبال دقت کلی باشد، می‌تواند کلاس‌های کمیاب را تقریباً نادیده بگیرد.

۲. ابهام برچسب. هر گزارش **فقط یک** برچسب دارد، ولی خیلی از حوادث **چند رویداد** دارند. مثلاً «موتور خراب شد و قایق به گل نشست»: آیا برچسب Loss of Control است (علت) یا Grounding (پیامد)؟ MAIB گاهی علت را برچسب می‌زند و گاهی پیامد را.

۳. واژگان تخصصی. کلمه‌هایی مثل *girting* (نوعی واژگونی یدک‌کش) یا *allided* (برخورد با جسم ثابت) برای مدل‌های عمومی مثل BERT ناآشنا هستند.

۲-۵. شکاف پژوهشی (Research Gap)

«شکاف» یعنی **چیزی که هنوز کسی درست انجام نداده و تو انجامش می‌دهی.** شکاف ما:

۱. **ارزیابی ناعادلانه در کار قبلی.** مقاله‌ی مرجع (Zhao et al., 2025) مدل‌ها را با تنظیمات متفاوت آموزش داده (dropout، منظم‌سازی، آستانه‌ی گرادیان و تابع فعال‌سازی متفاوت؛ جدول ۹ مقاله‌شان) و فقط یک بار اجرا کرده. پس معلوم نیست بهبود ادعاشده از معماری است یا از تنظیمات. در جدول ۳ خودشان، فقط تغییر هایپرپارامترها دقت را ۲.۳ واحد جابه‌جا می‌کند. این بیشتر از بهبود ادعاشده‌ی BiLSTM (۱.۱ واحد) است.

۲. **معیار نامناسب.** گزارش accuracy روی داده‌ی نامتوازن، ضعف روی کلاس‌های کمیاب را پنهان می‌کند.

۳. **داده‌ی غیرعمومی.** نتایج کار قبلی قابل بازتولید نیست. داده‌ی ما عمومی است.

۴. **مقایسه‌ی نظام‌مند روش‌های نامتوازنی کم است.** معمولاً یک روش امتحان می‌شود، نه مقایسه‌ی وزن‌دهی زیان، نمونه‌گیری دوباره و تولید داده با LLM در کنار هم.

۲-۶. پرسش‌های پژوهش (برای مقاله)

پیشنهاد من برای قالب‌بندی سؤال‌ها در مقاله (کمی دقیق‌تر از پروپوزال):

- **RQ1 (معماری):** با تنظیمات آموزش یکسان، آیا افزودن BiLSTM و attention روی BERT دسته‌بندی را بهتر می‌کند؟ بزرگ کردن BiLSTM چطور؟
- **RQ2 (نامتوازنی):** کدام روش، رده‌های کمیاب و ایمنی‌بحرانی را بیشتر بهبود می‌دهد: وزن‌دهی تابع زیان (wce، focal، cb)، نمونه‌گیری دوباره (oversampling)، یا افزایش داده با مدل زبانی بزرگ؟
- **RQ3 (تفسیر):** وزن‌های attention و خطاهای باقی‌مانده درباره‌ی حد این مسئله چه می‌گویند؟

۲-۷. سهم‌های مقاله (Contributions)

در آخر Introduction معمولاً ۳ تا ۵ سهم به‌صورت فهرست می‌آید:

۱. **ارزیابی کنترل‌شده:** همه‌ی مدل‌ها با تنظیمات یکسان، چند seed، خط مبنای کلاسیک، Macro-F1 و recall هر کلاس. با این روش ادعای برتری BiLSTM را آزمودیم و روی این داده تأیید نشد.

۲. **مقایسه‌ی نظام‌مند راهبردهای نامتوازنی:** سه تابع زیان، دو روش نمونه‌گیری دوباره و افزایش داده با LLM همراه با فیلتر برچسب. همه روی داده‌ی عمومی و با تأکید بر رده‌های ایمنی‌بحرانی.

۳. **تحلیل تفسیرپذیری و خطا:** attention یک زیرگروه پنهان را آشکار کرد (عدم انطباق نردبان راهنما با SOLAS). تحلیل خطا نشان داد سقف عملکرد بیشتر از ابهام برچسب علت و پیامد می‌آید.

۴. **بازتولیدپذیری:** کد کامل روی داده‌ی عمومی منتشر می‌شود.

در مقاله: نقشه‌ی Introduction (پنج پاراگراف)

پاراگراف	محتوا	جمله‌ی شروع پیشنهادی
۱	اهمیت ایمنی دریایی و گزارش‌های حادثه	*Marine accident investigation bodies such as the UK MAIB produce thousands of short incident reports, but turning them into reliable statistics still depends on manual coding.*
۲	چالش‌ها: نامتوازنی، ابهام، واژگان	*Automatic classification of these reports is difficult because the most safety-critical incident types are also the rarest.*
۳	کار قبلی و شکاف	*Recent work combined BERT with a BiLSTM and reported gains over plain BERT (Zhao et al., 2025), but the models were trained with different settings and evaluated once, with accuracy as the main metric.*
۴	کار ما و سؤال‌ها	*In this study, we compare ... under identical training settings and multiple random seeds, and ask three questions: ...*
۵	سهم‌ها (فهرست)	*Our contributions are as follows: (1) a controlled evaluation ...; (2) ...; (3) ...*

بخش ۳: مفاهیم پایه از صفر (برای Methods و Related Work)

۳-۱. از متن به عدد: TF-IDF

کامپیوتر فقط عدد می‌فهمد. پس اول باید متن را به عدد تبدیل کنیم.

ساده‌ترین روش، «کیسه‌ی کلمات» (bag of words): فقط بشمار هر کلمه چند بار آمده. ترتیب کلمه‌ها گم می‌شود.

TF-IDF بهترش می‌کند. برای هر کلمه در هر گزارش یک عدد می‌دهد که:

- **زیاد** است اگر کلمه در **این** گزارش زیاد آمده باشد (TF = term frequency).
- **کم** است اگر کلمه در **همه‌ی** گزارش‌ها رایج باشد (IDF = inverse document frequency).

مثلاً `vessel` در همه‌ی گزارش‌ها هست، پس IDF کمی دارد. `capsized` فقط در گزارش‌های واژگونی است، پس IDF بالایی دارد.

در کار ما: کلمه‌ها **و جفت‌کلمه‌ها** (مثل «ran aground»)، و حذف کلمه‌هایی که فقط در یک گزارش آمده‌اند.

۳-۲. SVM

حالا هر گزارش یک بردار عددی است، یعنی یک نقطه در یک فضای خیلی بزرگ. **SVM** (Support Vector Machine) بین نقطه‌های هر کلاس **مرز** می‌کشد. ما از نوع **خطی** (LinearSVC) استفاده کردیم: ساده، سریع (چند ثانیه روی CPU) و برای متن خیلی خوب (Joachims, 1998).

چرا لازم بود؟ این **خط مبنا** (baseline) است. اگر BERT نتواند این روش ساده را به‌روشنی شکست دهد، هزینه‌ی سنگینش توجیه ندارد. مقاله‌ی مرجع چنین خط مبنایی نداشت.

۳-۳. شبکه‌ی عصبی و آموزش، در یک صفحه

مفهوم	به زبان ساده
پارامتر (وزن)	عددهای قابل تنظیم مدل. BERT حدود ۱۱۰ میلیون دارد
تابع زیان (loss)	عددی که می‌گوید پیش‌بینی چقدر بد بود. آموزش یعنی کم کردن این عدد
گرادیان	جهتی که باید وزن‌ها را تغییر داد تا زیان کم شود
نرخ یادگیری (learning rate)	اندازه‌ی هر قدم تغییر وزن‌ها
batch	تعداد گزارش‌هایی که با هم پردازش می‌شوند و بعد وزن‌ها یک بار به‌روز می‌شوند
epoch	یک بار دیدن کل داده‌ی آموزش
overfitting	حفظ کردن داده‌ی آموزش به جای یاد گرفتن الگو. مدل در آموزش عالی است و در آزمون بد
validation (val)	داده‌ای جدا برای انتخاب بهترین epoch و تنظیمات
test	داده‌ای جدا که **فقط یک بار، در آخر** استفاده می‌شود؛ مثل امتحان نهایی
seed	عدد شروع تصادف. seed یکسان یعنی نتیجه‌ی یکسان

چرا سه بخش داده (۷۰/۱۵/۱۵)؟ اگر بهترین تنظیم را با test انتخاب کنی، test دیگر «امتحان نهایی» نیست؛ از قبل به آن نگاه کرده‌ای. برای همین انتخاب‌ها با val انجام می‌شود و test فقط یک بار.

۳-۴. ترنسفورمر و BERT

ترنسفورمر (Vaswani et al., 2017) معماری‌ای است که در آن هر کلمه به **همه‌ی** کلمه‌های دیگر جمله «نگاه می‌کند» تا معنی خودش را بهتر بفهمد. به این **self-attention** می‌گویند.

BERT (Devlin et al., 2019) یک ترنسفورمر ۱۲ لایه است که روی میلیاردها کلمه‌ی انگلیسی **پیش‌آموزش** (pre-training) دیده. کارش در پیش‌آموزش حدس زدن کلمه‌های پنهان‌شده بوده. پس زبان را «می‌فهمد».

fine-tuning یعنی همان BERT را با نرخ یادگیری خیلی کوچک کمی تنظیم کنیم تا برای کار ما (۹ نوع حادثه) تخصصی شود.

اصطلاح‌هایی که در مقاله می‌آیند:

اصطلاح	معنی
token / word-piece	BERT کلمه‌های ناآشنا را به تکه‌های آشنا می‌شکند: `capsized` ← `caps` + `##ized`
[CLS]	توکن ویژه‌ی اول متن. بردارش را معمولاً خلاصه‌ی کل متن می‌گیرند
۷۶۸	BERT برای هر توکن یک بردار ۷۶۸ عددی می‌دهد
bert-base-uncased	نسخه‌ی پایه، ۱۲ لایه، ۱۱۰ میلیون پارامتر؛ uncased یعنی حروف بزرگ و کوچک یکی‌اند
max length = 192	حداکثر ۱۹۲ توکن خوانده می‌شود. میانه‌ی گزارش ۵۹ کلمه است و فقط حدود ۲٪ گزارش‌ها بریده می‌شوند

۳-۵. LSTM و BiLSTM

LSTM (Hochreiter & Schmidhuber, 1997) یک شبکه‌ی **بازگشتی** است: متن را **کلمه‌به‌کلمه، به ترتیب** می‌خواند و یک «حافظه» با خودش می‌برد.

BiLSTM (Schuster & Paliwal, 1997) دو LSTM است: یکی از **چپ به راست** و یکی از **راست به چپ** می‌خواند. پس هر کلمه هم از قبل خودش خبر دارد و هم از بعد خودش.

در کار ما:

- **۱۲۸ واحد** در هر جهت، پس **۲۵۶ عدد** برای هر کلمه.
- **مدل مرجع:** حالت **پایانی** دو جهت به دسته‌بند داده می‌شود.
- **سؤال منطقی:** BERT خودش دوطرفه است. پس BiLSTM چه چیزی اضافه می‌کند؟ این دقیقاً RQ1 است.

۳-۶. Attention (توجه)

مشکل حالت پایانی BiLSTM این است که کلمه‌ی کلیدی وسط متن ممکن است «فراموش» شود. **Attention** به **هر کلمه یک وزن** می‌دهد و **میانگین وزن‌دار** همه‌ی کلمه‌ها را می‌سازد (Bahdanau et al., 2015; Zhou et al., 2016):

```
score_t = v · tanh(W · h_t)     # one number per word: how useful is word t?
alpha   = softmax(score)        # weights between 0 and 1 that sum to 1
c       = Σ alpha_t · h_t       # weighted average = one vector for the whole report
```

- `h_t` : خروجی BiLSTM برای کلمه‌ی t.
- `W` و `v` : پارامترهای قابل‌آموزش.
- `alpha` : وزن هر کلمه. **ذخیره‌اش می‌کنیم و می‌بینیم مدل به کجا نگاه کرده**؛ یعنی **تفسیرپذیری**.

احتیاط علمی: وزن attention نشان می‌دهد مدل **کجا** را نگاه کرده، نه لزوماً **چرا** تصمیم گرفته (Jain & Wallace, 2019; Wiegreffe & Pinter, 2019). در مقاله حتماً این را بنویس.

فرق با self-attention داخل BERT: BERT در هر لایه برای **هر کلمه** با نگاه به بقیه یک بردار جدید می‌سازد. attention ما فقط **یک بار** و برای ساختن **یک بردار برای کل گزارش** است. به آن **attention pooling** هم می‌گویند.

۷-۳. مقابله با نامتوازنی: سه خانواده

خانواده‌ی الف: تغییر تابع زیان (سطح الگوریتم)

روش	ایده	فرمول
ce (cross-entropy)	همه‌ی گزارش‌ها برابرند؛ «هیچ اقدامی»	-log p
wce (weighted ce)	اشتباه روی کلاس کمیاب گران‌تر	وزن کلاس c برابر N / (K · n_c)
focal (Lin et al., 2017)	گزارش‌های **آسان** کمتر حساب شوند	-(1-p)^γ · log p، با γ = 2
cb (Cui et al., 2019)	نسخه‌ی ملایم wce با «تعداد مؤثر نمونه»	وزن متناسب با (1-β) / (1-β^n_c)، با β = 0.999

در فرمول‌ها: p احتمالی است که مدل به **کلاس درست** داده؛ N تعداد کل گزارش‌های آموزش (۴,۰۳۳)؛ K تعداد کلاس‌ها (۹)؛ n_c تعداد گزارش‌های کلاس c.

مثال عددی wce: وزن Capsizing = 4033 / (9 × 69) = **6.49** و وزن Accident = 4033 / (9 × 1163) = **0.39**. یعنی یک اشتباه روی Capsizing حدود **۱۷ برابر** گران‌تر است. نکته‌ی جالب: تعداد × وزن برای **همه‌ی** کلاس‌ها ۴۴۸ می‌شود. یعنی سهم کل هر کلاس در آموزش برابر می‌شود.

خانواده‌ی ب: نمونه‌گیری دوباره (سطح داده، بدون داده‌ی جدید)

- **Random Oversampling (برای SVM):** گزارش‌های کلاس‌های کوچک به‌صورت تصادفی کپی می‌شوند تا همه‌ی کلاس‌ها هم‌اندازه‌ی بزرگ‌ترین شوند. داده‌ی آموزش از ۴,۰۳۳ به ۱۰,۴۶۷ گزارش رسید.
- **Class-Balanced Sampling (برای BERT):** احتمال انتخاب هر گزارش برابر ۱ ÷ اندازه‌ی کلاسش است و طول epoch ثابت می‌ماند. این همان `WeightedRandomSampler` در PyTorch است.

نکته‌ی عمیق: در BERT، هر گزارش Capsizing در هر epoch به‌طور میانگین **6.49** بار دیده می‌شود. این دقیقاً همان وزن wce است. یعنی این دو روش **در امید ریاضی** تقریباً یک کارند. تفاوتشان در **تصادفی بودن** است: با oversampling در هر epoch حدود ۶۸٪ گزارش‌های Accident اصلاً دیده نمی‌شوند.

خانواده‌ی ج: تولید داده‌ی جدید (Data Augmentation)

نمونه‌گیری دوباره **اطلاعات جدیدی** نمی‌دهد: فقط همان گزارش‌ها تکرار می‌شوند. **افزایش داده** متن **جدید** می‌سازد:

روش	ایده
EDA (Wei & Zou, 2019)	تغییرهای ساده: مترادف، جابه‌جایی و حذف کلمه
Back-translation (Sennrich et al., 2016)	ترجمه به یک زبان دیگر و برگرداندن
SMOTE (Chawla et al., 2002)	نمونه‌ی مصنوعی **بین دو نمونه** در فضای بردار؛ برای متن مستقیماً مناسب نیست
LLM paraphrasing ← روش ما	یک مدل زبانی بزرگ گزارش را با کلمه‌های دیگر بازنویسی می‌کند
LAMBADA (Anaby-Tavor et al., 2020)	تولید با مدل زبانی و **فیلتر با یک دسته‌بند**؛ ما فیلترش را به کار بردیم

۸-۳. ارزیابی

ماتریس درهم‌ریختگی (confusion matrix): جدولی که می‌گوید هر کلاس واقعی، با چه کلاسی پیش‌بینی شده است. قطر اصلی = پیش‌بینی‌های درست.

سه معیار پایه، با مثال واقعی (مدل Att + wce، seed ۱، کلاس Capsizing):

- **Recall** = از ۱۵ گزارش واقعی Capsizing، مدل ۱۲ تا را پیدا کرد ← **0.80**. یعنی «چندتا را از دست ندادیم؟»
- **Precision** = مدل ۱۲ بار گفت Capsizing و هر ۱۲ بار درست بود ← **1.00**. یعنی «چقدر هشدار اشتباه دادیم؟»
- **F1** = میانگین هارمونیک این دو = 1.80 / 0.80 × 1.00 × 2 = **0.889**. فقط وقتی بالاست که هر دو بالا باشند.

Macro-F1 = میانگین **ساده‌ی** F1 نُه کلاس. هر کلاس، کوچک یا بزرگ، **وزن برابر** دارد. **معیار اصلی ما همین است.**

چرا accuracy نه؟ فرض کن همین مدل **هیچ‌وقت** Capsizing نگوید. accuracy فقط حدود ۱.۴٪ پایین می‌آید، ولی Macro-F1 حدود ۰.۱۰ پایین می‌آید. پس accuracy خطرناک‌ترین خطا را پنهان می‌کند.

Recall کلاس‌های بحرانی: میانگین recall سه کلاس آتش‌سوزی، واژگونی و آب‌گرفتگی.

نوسان seed: هر مدل با ۲ seed آموزش دید و «میانگین ± انحراف معیار» گزارش شد. قاعده‌ی ما: اگر تفاوت دو مدل بیشتر از بزرگ‌ترین انحراف معیارشان باشد، می‌گوییم «**بزرگ‌تر از نوسان بین seedها**». این **آزمون آماری نیست.**

آزمون آماری (هنوز انجام نشده؛ پیش از ارسال مقاله لازم است):

- **Paired bootstrap:** هزار بار از ۸۶۵ گزارش آزمون با جایگذاری نمونه بگیر، Macro-F1 دو مدل را حساب کن، و ببین در چند درصد موارد مدل A بهتر است.
- **McNemar** (Dietterich, 1998): برای هر گزارش آزمون، کدام مدل درست گفت؟ آیا تفاوت‌ها بیشتر از شانس است؟

پیش‌بینی‌های هر اجرا در `results/*.json` ذخیره شده، پس این آزمون‌ها بدون آموزش دوباره قابل انجام‌اند.

بخش ۴: کارهای مرتبط (Related Work)

به زبان ساده

بخش Related Work سه کار می‌کند: نشان می‌دهد **ادبیات را می‌شناسی**، کار دیگران را **دسته‌بندی** می‌کند، و می‌گوید **کار تو چه فرقی دارد**. هر پاراگراف باید با یک جمله‌ی «ولی...» تمام شود که به شکاف تو برسد.

گروه ۱: پردازش زبان طبیعی روی گزارش‌های حوادث دریایی

کار	چه کرده	فرق با کار ما
Zhao et al. (2025)، Systems 13(4):284	BERT + BiLSTM برای دسته‌بندی **علت** حادثه (۳۲ کلاس) روی گزارش‌های سواحل چین؛ گزارش دقت 89.8٪؛ قواعد همبستگی Apriori	داده غیرعمومی؛ تنظیمات متفاوت بین مدل‌ها؛ یک اجرا؛ معیار accuracy؛ افزایش داده تا حدود ۸۰۰ نمونه در هر کلاس، با ترتیب نامشخص نسبت به تقسیم داده
Black et al. (2026)، Ocean Engineering 357	SeaSafeBERT (BERT تطبیق‌یافته با دامنه‌ی دریایی) + TF-IDF برای دسته‌بندی **عوامل انسانی** با طبقه‌بندی SHIELD؛ ۳۳۰ گزارش؛ ۵۳ کد	هدف آن‌ها عوامل انسانی است، ما **نوع حادثه**؛ آن‌ها مدل دامنه‌ای ساختند، ما مقایسه‌ی کنترل‌شده‌ی معماری و روش‌های نامتوازنی
Yu et al. (2026)	گراف دانش برای گزارش‌های **تصادم**: استخراج موجودیت با LEBERT-BiLSTM-CRF و K-BERT-BiLSTM-CRF؛ دسته‌بندی **شدت** حادثه	فقط تصادم؛ استخراج اطلاعات و شدت، نه نوع حادثه
Wang et al. (2026)	استخراج اطلاعات مبتنی بر هستان‌شناسی (BiLSTM-CRF ،XLM-RoBERTa) + شبکه‌ی بیزی پویا برای **آتش‌سوزی و انفجار**؛ ۱۹۸ گزارش؛ نظارت ضعیف با LLM	فقط آتش‌سوزی؛ مدل‌سازی علّی، نه دسته‌بندی

الگوی مشترک که ارزش ذکر دارد: ترکیب **BERT + BiLSTM** در این حوزه زیاد استفاده می‌شود (Zhao، Yu، Wang). پس پرسیدن اینکه «آیا BiLSTM واقعاً لازم است؟» برای این حوزه سؤال مهمی است.

گروه ۲: مدل‌های زبانی بزرگ در حوزه‌ی دریایی

کار	چه کرده
Nguyen et al. (2025)، Llamarine	اولین LLM متن‌باز تخصصی ناوبری دریایی؛ پیش‌آموزش ادامه‌دار روی کتاب‌ها و مقاله‌های دریایی
Park et al. (2025)، AIS-LLM	ترکیب داده‌ی AIS (موقعیت کشتی‌ها) با LLM برای پیش‌بینی مسیر، تشخیص ناهنجاری و ریسک تصادم

جمله‌ی ربط به کار ما: LLMها وارد حوزه‌ی دریایی شده‌اند، ولی استفاده از آن‌ها برای **تولید داده‌ی آموزشی** برای رده‌های کمیاب گزارش‌های حادثه هنوز بررسی نشده است. ما این را امتحان می‌کنیم.

گروه ۳: روش‌های مقابله با نامتوازنی و افزایش داده

یک پاراگراف کوتاه با ارجاع به: Lin et al. (2017)، Cui et al. (2019)، Chawla et al. (2002)، Kang et al. (2020)، Wei & Zou (2019)، Sennrich et al. (2016) و Anaby-Tavor et al. (2020). جمع‌بندی: «این روش‌ها معمولاً جدا از هم بررسی

می‌شوند؛ ما آن‌ها را روی یک داده و با یک پروتکل مقایسه می‌کنیم.»

در مقاله: ایرادهای مقاله‌ی مرجع را محترمانه بنویس

✗ «.Zhao et al. made a mistake»

✓ *It is not stated whether the data split was performed before augmentation; if not, near-duplicates of a report could appear in both training and test sets.*

✓ *Because the compared models were trained with different hyperparameters (Table 9 in Zhao et al., 2025), it is unclear whether the reported gain stems from the architecture or from the settings.*

بخش ۵: داده (بخش Data مقاله)

به زبان ساده

- **منبع:** دیتاست عمومی `baker-street/maib-incident-reports-5K` روی Hugging Face (Munaev, 2025)؛ مجوز Apache-2.0).
- **برچسب:** فیلد «Main Event L1» خود MAIB. **ما برچسب‌ها را عوض نکردیم.**
- **پاک‌سازی:**

  ۱. فاصله‌های اضافه حذف و املای متفاوت یک برچسب یکی شد.

  ۲. ۱ گزارش دقیقاً تکراری حذف شد. اگر یک متن دو برچسب متفاوت داشت هم حذف می‌شد (۰ مورد).

  ۳. کلاس‌های با کمتر از ۲۰ گزارش حذف شدند: Hull Failure (۳) و Non-accidental Event (۲). با این تعداد، مجموعه‌ی آزمون صفر یا یک نمونه از آن‌ها داشت.
- **نتیجه:** ۵,۷۶۲ گزارش و ۹ کلاس. میانه‌ی طول ۵۹ کلمه و میانگین ۶۶.۸ کلمه.
- **تقسیم:** طبقه‌بندی‌شده (stratified) ۷۰/۱۵/۱۵ با seed ثابت ۴۲. **یک تقسیم برای همه‌ی مدل‌ها.**

Table 1 مقاله: توزیع کلاس‌ها

Class	Total	Train	Val	Test
Accident to person(s)	1,662	1,163	249	250
Damage / Loss of Equipment	1,374	962	206	206
Loss of Control	823	576	123	124
Grounding / Stranding	561	393	84	84
Contact	406	284	61	61
Collision	326	228	49	49
Fire / Explosion*	324	227	49	48
Flooding / Foundering*	187	131	28	28
Capsizing / Listing*	99	69	15	15
Total	**5,762**	**4,033**	**864**	**865**

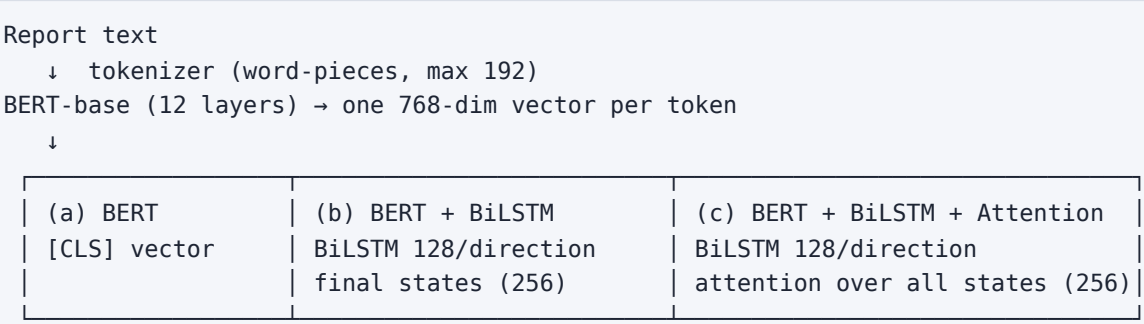
*کلاس‌های ایمنی‌بحرانی. شکل ۱ مقاله: `maib-thesis/reports/class_distribution.png` .

جمله‌ی پیشنهادی

We use the publicly available MAIB incident dataset (Munaev, 2025), which contains 5,768 short incident narratives labelled by MAIB with the main event type. After removing one duplicate and two classes with fewer than 20 reports, 5,762 reports in nine classes remain. The class imbalance ratio between the largest and the smallest class is 16.8. We split the data once into training (70%), validation (15%) and test (15%) sets, stratified by class, and use the same split for all models.

بخش ۶: روش (بخش Methods مقاله)

۶-۱. مدل‌ها



همه‌ی مدل‌های عصبی **دقیقاً یک BERT مشترک** دارند و فقط در «سر» (head) فرق دارند. پس هر تفاوت نتیجه **فقط** از سر می‌آید. به این طراحی **مطالعه‌ی حذفی (ablation study)** می‌گویند: هر بار **فقط یک جزء** عوض می‌شود.

پیشنهاد: شکل این معماری را برای مقاله تمیز بکش (در PowerPoint یا draw.io). مقاله‌ها تقریباً همیشه یک «شکل ۱: نمای کلی روش» دارند.

۶-۲. توابع زیان

بخش ۳-۷ را ببین. در مقاله: یک جدول با فرمول‌ها. حتماً بنویس که **وزن‌ها فقط از داده‌ی آموزش** محاسبه شدند.

۶-۳. نمونه‌گیری دوباره

- **SVM:** random oversampling تا اندازه‌ی بزرگ‌ترین کلاس (۱,۱۶۳).
- **BERT:** class-balanced sampling با طول epoch ثابت، **با ce** (نه wce). چون ترکیب هر دو، نامتوازنی را دو بار جبران می‌کرد.

۶-۴. افزایش داده با LLM

جزء	مقدار
مدل زبانی	Qwen2.5-1.5B-Instruct (Qwen Team, 2024)؛ متن‌باز (Apache-2.0)؛ اجرا روی GPU محلی
کار	بازنویسی (paraphrasing) گزارش‌های **واقعی آموزش** رده‌های کمیاب
هدف	هر کلاس با کمتر از ۴۰۰ گزارش آموزش، تا ۴۰۰ پر شود: ۱,۴۹۳ بازنویسی تولید و ۱,۰۶۸ پذیرفته شد (۷۱.۵٪)؛ داده‌ی آموزش از ۴,۰۳۳ به ۵,۱۰۱ رسید
تنظیم تولید	نمونه‌گیری با temperature 0.8 و top-p 0.95؛ حداکثر ۲۵۶ توکن جدید
فیلتر ۱	نسبت طول بازنویسی به اصل بین ۰.۵ و ۲
فیلتر ۲	اشتراک کلمه (Jaccard) بین ۰.۱۵ و ۰.۸: نه کپی، نه بی‌ربط
فیلتر ۳	حذف تکراری‌ها

جزء	مقدار
فیلتر ۴ (برچسب)	یک TF-IDF + SVM آموزش‌دیده **فقط روی داده‌ی واقعی** باید بازنویسی را در کلاس گزارش اصلی قرار دهد (مثل LAMBADA)؛ ردشده‌ها با بازنویسی تازه جایگزین می‌شوند
نشت داده	val و test **هرگز** به مدل زبانی داده نمی‌شوند

دستور (prompt) را عیناً در پیوست مقاله بیاور:

You rewrite marine incident reports. Rewrite the report below with different words and sentence structure. Keep every fact exactly: the type of vessel, what happened, the cause, injuries and damage. Do not add new facts and do not name the incident category. Reply with the rewritten report only.

چرا «do not name the incident category»؟ اگر مدل زبانی اسم کلاس را در متن بنویسد، BERT یاد می‌گیرد فقط دنبال همان کلمه بگردد؛ میان‌بری که در گزارش‌های واقعی وجود ندارد.

بررسی دستی (برای مقاله): در نمونه‌هایی که بررسی کردیم، **نوع حادثه همیشه حفظ شده بود**، ولی گاهی **جزئیات فرعی** عوض شده بود (مثلاً liferaft ← lifeboat، یا towed ← escorted). **سبک** بازنویسی‌ها هم رسمی‌تر از گزارش‌های اصلی بود. هر دو را در Limitations بنویس.

نرخ پذیرش در فیلتر برچسب (برای مقاله، جدول کوچک):

کلاس	واقعی	تولیدشده	پذیرفته	نرخ پذیرش
Capsizing	69	487	331	٪68
Flooding	131	408	269	٪66
Fire	227	184	173	٪94
Collision	228	187	172	٪92
Contact	284	215	116	٪54
Grounding	393	12	7	٪58

Fire و Collision واژه‌های شاخص دارند (fire، collided) و بیشتر پذیرفته شدند. فیلتر سخت‌گیر است: مثلاً بازنویسی یک گزارش Contact با «collided with a concrete quay wall» رد شد، با اینکه هنوز Contact است.

۵-۶. BiLSTM بزرگ‌تر

واحد در هر جهت	لایه	خروجی برای هر کلمه	پارامترهای BiLSTM
128	1	256 (پیش‌فرض)	0.92M
384	1	768 (هم‌اندازه‌ی BERT)	3.5M
128	2	256	1.3M
384	2	768	7.1M

برای مقایسه: BERT پایه حدود ۱۱۰ میلیون پارامتر دارد.

همه با wce، چون بهترین تابع زیان بود. با ۲ لایه، dropout برابر ۰.۱ بین لایه‌ها است.

۶-۶. تنظیمات آموزش (Table 2 مقاله)

تنظیم	مقدار	دلیل
مدل پایه	bert-base-uncased	هم‌سطح با مقاله‌ی مرجع
حداکثر طول	۱۹۲ توکن	حدود ۲٪ گزارش‌ها بریده می‌شوند
batch مؤثر	32 = 8 × 4 (gradient accumulation)	مثل مقاله‌ی مرجع؛ ۴ GPU گیگابایتی
بهینه‌ساز	AdamW (Loshchilov & Hutter, 2019)، weight decay 0.01	استاندارد fine-tuning
نرخ یادگیری	BERT: 2e-5؛ لایه‌های جدید: 1e-3	BERT فقط باید کمی تنظیم شود؛ لایه‌های جدید از صفر شروع می‌کنند
زمان‌بندی	warmup ۱۰٪ و کاهش خطی	پایداری اول آموزش
clipping گرادیان	1.0	جلوگیری از گرادیان انفجاری
دقت محاسبه	*fp16 (mixed precision; Micikevicius et al., 2018)؛ BiLSTM و attention در fp32*	سرعت و حافظه؛ پایداری عددی
epoch	حداکثر ۵، توقف زودهنگام با صبر ۲	محدودیت زمان
انتخاب مدل	بهترین epoch با Macro-F1 مجموعه‌ی val	test در هیچ تصمیمی دخالت ندارد
seed	1 و 2	تکرارپذیری و سنجش نوسان
سخت‌افزار	GTX 1650 Ti (4GB)؛ حدود ۷۵ دقیقه برای هر اجرا	

جمله‌ی پیشنهادی (پروتکل)

All BERT-based models share the same encoder and training recipe; consecutive configurations differ in exactly one component (the head or the loss). For each run, the epoch with the highest validation macro-F1 is selected, and the test set is used only once, at the end of the run. We report the mean and standard deviation over random seeds.

بخش ۷: طراحی آزمایش‌ها (Experimental Setup)

#	مقایسه	سؤال	اجراها
1	TF-IDF + SVM	خط مبنای کلاسیک	1
2	Attention + ← BiLSTM + BERT ← BERT (همه با ce)	RQ1	6
3	Attention + ce / wce / focal / cb	RQ2، تابع زیان	6 (+۲ مشترک)
4	oversampling روی SVM و روی Attention + ce	RQ2، نمونه‌گیری	1 + 2
5	افزایش داده با LLM روی SVM، Attention + ce و Attention + wce	RQ2، تولید داده	1 + 4
6	BiLSTM با (384,1)، (128,2) و (384,2)، همه با wce	RQ1، ظرفیت	6

جمع: ۲۴ اجرای BERT (۱۲ پیکربندی × ۲ seed)، هر کدام حدود ۶۰ تا ۹۲ دقیقه؛ در مجموع حدود ۳۱ ساعت روی GPU لپ‌تاپ، به‌علاوه‌ی ۲.۵ ساعت تولید داده با LLM.

بخش ۸: نتایج (بخش Results مقاله)

قانون بخش Results: فقط **چه شد**، با عدد. تفسیر **چرا** را برای Discussion نگه دار.

۸-۱. جدول اصلی (Table 3 مقاله)

میانگین ± انحراف معیار روی ۲ seed؛ مجموعه‌ی آزمون (۸۶۵ گزارش).

Configuration	Macro-F1	Critical-class recall	Accuracy
TF-IDF + SVM	0.885	0.827	0.914
TF-IDF + SVM + oversampling	0.885	0.834	0.917
TF-IDF + SVM + LLM augmentation	0.889	0.850	0.916
BERT	0.898 ± 0.007	**0.873 ± 0.008**	0.927 ± 0.005
BERT + BiLSTM (reference)	0.901 ± 0.004	0.851 ± 0.040	0.928 ± 0.001
BERT + BiLSTM + Att (ce)	0.905 ± 0.004	0.845 ± 0.016	0.931 ± 0.002
+ Att + wce	0.914 ± 0.006	0.868 ± 0.016	**0.935 ± 0.003**
+ Att + focal	0.905 ± 0.001	0.858 ± 0.012	0.930 ± 0.001
+ Att + cb	0.910 ± 0.001	0.857 ± 0.000	**0.935 ± 0.004**
+ Att + ce + oversampling	0.909 ± 0.001	0.851 ± 0.008	0.931 ± 0.002
+ Att + ce + LLM augmentation	0.908 ± 0.009	0.862 ± 0.008	0.932 ± 0.004
+ Att + wce + LLM augmentation (best)	**0.915 ± 0.002**	0.868 ± 0.016	**0.935 ± 0.002**
+ Att + wce, BiLSTM 384 × 1	0.909 ± 0.003	0.862 ± 0.007	0.929 ± 0.009
+ Att + wce, BiLSTM 128 × 2	0.910 ± 0.007	**0.873 ± 0.008**	**0.935 ± 0.007**
+ Att + wce, BiLSTM 384 × 2	0.913 ± 0.001	0.868 ± 0.016	0.932 ± 0.004

قانون جدول: در هر ستون **بیشترین مقدار** را پررنگ کن، و متن باید همان پیکربندی را «بهترین» بنامد. اگر بهترین را به دلیل دیگری (مثلاً سادگی) انتخاب نمی‌کنی، صریح بنویس چرا. (نظر استاد راهنما: متن و جدول نباید با هم تناقض داشته باشند.)

شکل مقاله: `presentations/_build/build_data.py` دو نمودار میله‌ای می‌سازد: `fig_macro_f1.png` و `fig_critical_recall.png` . هر معیار در یک شکل جدا، و محور از صفر (نظر استاد راهنما: نمایش نقطه‌ای دو معیار کنار هم مناسب نیست).

۸-۲. RQ1: معماری

مقایسه	تغییر Macro-F1	حکم
BERT + BiLSTM در برابر BERT	+0.004	در حد نوسان seed
Attention + در برابر BiLSTM	+0.004	در حد نوسان seed
BiLSTM 384 × 1 در برابر 128 × 1 (هر دو wce)	-0.006	در حد نوسان seed
BiLSTM 128 × 2 در برابر 128 × 1	-0.005	در حد نوسان seed

مقایسه	تغییر Macro-F1	حکم
BiLSTM 384 × 2 در برابر 1 × 128	-0.001	در حد نوسان seed

یک الگوی کوچک: attention در هر دو seed بهترین recall را روی سه کلاس «برخورد» داشت (Contact، Collision و Grounding)؛ حدود ۲ تا ۳ گزارش در Contact.

۳-۸. RQ2: نامتوازنی

روش	تغییر Macro-F1 نسبت به ce	تغییر recall بحرانی	حکم
wce	+0.009	+0.022	**بزرگ‌تر از نوسان**
cb	+0.005	+0.011	کمی بزرگ‌تر از نوسان؛ قطعی نیست
focal	±0.000	+0.013	در حد نوسان
oversampling (BERT)	+0.003	+0.005	در حد نوسان
oversampling روی SVM (نسبت به SVM)	+0.0006	+0.007	عملاً صفر
LLM augmentation (BERT، با ce)	+0.003	+0.017	در حد نوسان
wce + LLM augmentation (نسبت به wce)	+0.001	±0.000	در حد نوسان
LLM augmentation روی SVM (نسبت به SVM)	+0.005	+0.022	تک‌اجرا؛ بهبود کوچک

معامله‌ی wce (تعداد گزارش‌های درست، میانگین دو seed، wce ← ce):

- Capsizing: ۱۰.۵ ← ۱۱.۵ از ۱۵ (+۶.۷٪ recall)
- Collision: ۴۵.۵ ← ۴۷ از ۴۹
- Loss of Control: ۱۱۰ ← ۱۱۳ از ۱۲۴
- Accident: ۲۴۶ ← ۲۴۴.۵ از ۲۵۰ (فقط -۰.۶٪)
- **در کل ۳.۵ گزارش درست بیشتر.** accuracy هم کم نشد (0.935 ← 0.931).

oversampling روی BERT: بهترین recall در Collision (۴۸ از ۴۹). Capsizing در هر دو seed ۱۱ از ۱۵ بود، بدون هیچ پیش‌بینی اشتباه (precision = 1.0). در عوض حدود ۳.۵ گزارش کمتر در Accident. روی SVM هم همین الگو دیده شد: خطا از بزرگ‌ترین کلاس به کلاس‌های کوچک‌تر جابه‌جا می‌شود.

LLM augmentation (تعداد گزارش‌های درست، میانگین دو seed):

کلاس (test n)	ce	ce + aug	wce	wce + aug
Capsizing (15)	10.5	11	11.5	11.5
Flooding (28)	24	24.5	24	24
Fire (48)	47	47	47	47
Collision (49)	45.5	47.5	47	48.5
Contact (61)	52	52	51.5	51.5

تنها بهبود پایدار در Collision است (۱.۵ تا ۲ گزارش). کلاس‌های پرتکرار آسیب ندیدند (میانگین F1 چهار کلاس پرتکرار با wce: 0.936 ← 0.935). روی Capsizing: SVM ۱۰ ← ۱۱ از ۱۵، و Collision و Contact هر کدام ۱ گزارش بیشتر. هزینه: هر اجرای BERT ۹۲ دقیقه به‌جای ۷۵ (۲۲٪ بیشتر).

BiLSTM بزرگ‌تر: در seed اول، BiLSTM با ۳۸۴ واحد خطای آموزش کمتری داشت (0.064 در برابر 0.081) ولی Macro-F1 اعتبارسنجی همان ماند (0.915)؛ ظرفیت اضافه صرف حفظ کردن داده‌ی آموزش شد.

۸-۴. نتایج هر کلاس (Table 4 مقاله)

تعداد گزارش‌های درست‌تشخیص‌داده‌شده (میانگین seedها)؛ نادرترین کلاس بالاست:

Class (test n)	SVM	BERT	+BiLSTM	+Att	+Att+wce
Capsizing (15)	10	12	11	10.5	11.5
Flooding (28)	24	23.5	23.5	24	24
Fire (48)	46	47	47	47	47
Collision (49)	43	44.5	45	45.5	47
Contact (61)	49	48.5	50	52	51.5
Grounding (84)	78	78	79	79.5	79.5
Loss of Control (124)	110	109.5	110.5	110	113
Damage (206)	186	193	192	191	191
Accident (250)	245	246	244.5	246	244.5

در مقاله حتماً بنویس: با ۱۵ گزارش Capsizing در آزمون، هر گزارش ۶.۷ واحد recall است. تفاوت‌های ۱ تا ۲ گزارشی بین مدل‌های BERT قابل اتکا نیست. چیزی که قطعی است برتری **همه‌ی** مدل‌های BERT بر SVM در این کلاس است.

۸-۵. اشتباه‌های پرتکرار (بهترین پیکربندی Att + wce + LLM augmentation، جمع دو seed)

کلاس واقعی	پیش‌بینی	تعداد
Damage / Loss of Equipment	Loss of Control	13
Loss of Control	Damage / Loss of Equipment	9
Contact	Collision	8
Damage / Loss of Equipment	Contact	7
Grounding	Loss of Control	6
Flooding	Grounding	5

جدول بالا برای Att + wce است. در بهترین پیکربندی (wce + LLM augmentation) عددها کمی فرق می‌کند؛ تعداد کل اشتباه‌ها در هر دو ۱۱۲ از ۱,۷۳۰ است:

کلاس واقعی	پیش‌بینی	wce + LLM augmentation	wce
Damage / Loss of Equipment	Loss of Control	17	13
Damage / Loss of Equipment	Contact	8	7

کلاس واقعی	پیش‌بینی	wce + LLM augmentation	wce
Contact	Collision	8	8
Loss of Control	Damage / Loss of Equipment	7	9
Grounding	Loss of Control	6	6

شکل مقاله: `maib-thesis/reports/confusion_matrix.png` (بهترین پیکربندی؛ در `config.MAIN_CONFIG` تعیین می‌شود).

۸-۶. واژه‌های پروزن attention (Table 5 مقاله)

کلاس	واژه‌ها
Accident	fell، sustained، passenger، injury، fractured
Capsizing	capsized (حدود ۳ برابر واژه‌ی بعدی)
Collision	collided، manoeuvring، tanker، moored
Contact	contact، quayside، struck، lock
Damage	**solas، ladder، pilot، conform، regulations**
Fire	engine، caught، smoke، extinguish
Flooding	ingress، water، taking
Grounding	grounded، ran، aground، sandbank
Loss of Control	failure، engine، fouled، propulsion، propeller

۸-۷. تحلیل خطا: سه الگو

۱. **زنجیره‌ی علت و پیامد:** «propulsion failure … grounded» با برچسب Grounding، که مدل آن را Loss of Control پیش‌بینی کرد؛ و برعکس.

۲. **گزارش چندرویدادی:** «crewmember fell overboard … hit the lock side» با برچسب Contact، که مدل Accident to person پیش‌بینی کرد.

۳. **واژگان تخصصی:** «girting» و «allided».

بخش ۹: بحث (بخش Discussion مقاله)

به زبان ساده

Discussion جواب «**یعنی چه؟**» و «**چرا؟**» است. برای هر یافته‌ی مهم یک پاراگراف بنویس: یافته، تفسیر، شاهد، و ارتباط با کار دیگران.

نکته‌های اصلی

۱. معماری گلوگاه نیست. BiLSTM و attention بهبودی بیشتر از نوسان ندادند. یک توضیح محتمل: BERT خودش دوطرفه است و ۱۲ لایه self-attention دارد. گزارش‌ها هم کوتاه‌اند (میانه‌ی ۵۹ کلمه). پس لایه‌ی بازگشتی اطلاعات زیادی اضافه نمی‌کند. **BiLSTM بزرگ‌تر این را تقویت کرد:** با ۱.۴ تا ۷.۷ برابر پارامتر (تا ۷.۱ میلیون) هیچ بهبودی دیده نشد، و خطای آموزش کمتر بدون بهبود اعتبارسنجی، نشانه‌ی حفظ کردن داده است. لازم نیست خروجی BiLSTM هم‌اندازه‌ی BERT (۷۶۸) باشد: ورودی BiLSTM همیشه ۷۶۸ بعد است و خروجی آن فقط خلاصه‌ای برای ۹ کلاس است.

۲. تابع زیان مهم‌تر از معماری است. wce با یک تغییر ساده در یک خط کد، بیشتر از لایه‌های اضافه کمک کرد.

۳. نمونه‌گیری دوباره اطلاعات جدید نمی‌دهد. oversampling در امید ریاضی همان وزن wce را دارد، ولی با نویز نمونه‌گیری. روی SVM هم اثری نداشت. خطاهای Capsizing احتمالاً **معنایی‌اند**، نه **کمّی**.

۳ب. افزایش داده با LLM واژه‌ی تازه می‌آورد، نه اطلاعات تازه. LLM augmentation روی SVM کمی کمک کرد (+0.005)، روی BERT با ce در حد نوسان بود (+0.003)، و همراه با wce بیشترین Macro-F1 همه‌ی آزمایش‌ها را داد (0.915)؛ اما برتری‌اش بر wce تنها فقط 0.001 است. توضیح: SVM هر واژه را ویژگی جدا می‌بیند؛ مترادف تازه برایش ویژگی تازه است. BERT از پیش‌آموزش می‌داند capsized و overturned هم‌معنا هستند؛ بازنویسی برایش همان اطلاعات قبلی است. این با Longpre et al. (2020) هم‌خوان است: افزایش داده‌ی عمومی (بازنویسی، ترجمه‌ی رفت‌وبرگشتی) به مدل‌های پیش‌آموزش‌دیده کمک چندانی نمی‌کند. wce، oversampling و augmentation هر سه سهم کلاس‌های کمیاب را بالا می‌برند؛ وقتی wce این سهم را درست کرده باشد، افزایش داده فقط کمی اضافه می‌کند (0.001) و پراکندگی بین اجراها را کم می‌کند (0.002 ← 0.006).

۴. سقف حدود ۰.۹۱ از ابهام برچسب می‌آید. شواهد:

- (الف) پرتکرارترین خطاها بین کلاس‌های علت و پیامد است (Damage ↔ Loss of Control، Grounding ↔ Loss of Control).
- (ب) واژه‌های مشترک در attention: contact در فهرست Collision و ingress در فهرست Grounding.
- (ج) SVM ساده به BERT نزدیک است (0.885 در برابر 0.914)؛ یعنی مسئله بیشتر واژه‌محور است.

پیامد عملی: شاید دسته‌بندی **چندبرچسبی** (چند برچسب برای هر گزارش) یا جدا کردن علت از پیامد مناسب‌تر از تک‌برچسبی باشد.

۵. ارزش attention در تفسیرپذیری است، نه دقت. یافته‌ی SOLAS نشان می‌دهد attention می‌تواند الگوهای پنهان یک کلاس کلی را آشکار کند. برای سازمان‌های ایمنی هم اطلاعات مفیدی است: نردبان راهنمای غیراستاندارد یک مشکل تکراری است.

۶. مقایسه با مقاله‌ی مرجع. عددها مستقیماً قابل مقایسه نیستند (وظیفه و داده‌ی متفاوت). ولی **ادعا** قابل آزمون است: با تنظیمات یکسان، برتری BiLSTM را ندیدیم. این تأکیدی است بر اهمیت ارزیابی کنترل‌شده در این حوزه.

جمله‌ی پیشنهادی

Taken together, these results suggest that the remaining errors are driven less by model capacity than by the single-label annotation of multi-event reports: the most frequent confusions occur between cause and consequence classes, and a linear TF-IDF baseline comes within 0.03 macro-F1 of the best model.

بخش ۱۰: محدودیت‌ها و کارهای آینده

محدودیت‌ها (صادقانه؛ داورها همین را دنبال می‌کنند)

۱. **فقط ۲ seed؛** انحراف معیار با ۲ نمونه تقریبی است. **آزمون معناداری** هنوز انجام نشده.

۲. **مجموعه‌ی آزمون کوچک برای رده‌های نادر:** ۱۵ گزارش Capsizing.

۳. **حداکثر ۵ epoch؛** در ۹ اجرا از ۱۲ اجرای اصلی، بهترین epoch همان آخری بود.

۴. **γ و β تنظیم نشدند** (مقادیر پیشنهادی مقاله‌های اصلی).

۵. **یک تقسیم داده** (بدون cross-validation).

۶. **فقط BERT پایه؛** RoBERTa، DeBERTa و مدل دامنه‌ای امتحان نشد.

۷. **وزن attention توضیح علّی نیست.**

۸. **LLM augmentation:** مدل کوچک (1.5B)؛ جزئیات فرعی گاهی عوض می‌شود؛ سبک بازنویسی با گزارش‌های اصلی فرق دارد. فیلتر برچسب SVM ممکن است بازنویسی‌های «سخت ولی درست» را هم دور بریزد.

۹. **فقط داده‌ی MAIB (انگلیسی)؛** تعمیم به داده‌ی کشورهای دیگر بررسی نشده.

کارهای آینده

۱. seed بیشتر و آزمون bootstrap یا McNemar.

۲. مدل‌های قوی‌تر و مدل تطبیق‌یافته با دامنه، مثل SeaSafeBERT (Black et al., 2026).

۳. مقایسه با LLM به‌صورت zero-shot یا few-shot.

۴. دسته‌بندی چندبرچسبی یا جدا کردن علت از پیامد.

۵. افزایش داده‌ای که **اطلاعات** تازه بیاورد، نه فقط واژه‌ی تازه؛ مثلاً تولید سناریوی تازه با LLM بزرگ‌تر و بررسی انسانی، با دستوری که سبک گزارش اصلی را حفظ کند.

بخش ۱۱: نقشه‌ی نوشتن

ترتیب نوشتن (نه ترتیب خواندن)

مقاله را به ترتیبی که خوانده می‌شود **ننویس**. این ترتیب ساده‌تر است:

۱. **Methods و Data:** کارهایی که انجام دادی؛ ساده‌ترین بخش.

۲. **Results:** جدول‌ها و شکل‌ها، بعد متن کوتاه.

۳. **Discussion**

۴. **Introduction:** حالا که می‌دانی چه یافتی، معرفی‌اش ساده است.

۵. **Related Work**

۶. **Conclusion**

۷. **Abstract:** آخر از همه.

۸. **Title**

عنوان پیشنهادی (انگلیسی)

What Helps in Classifying Imbalanced Maritime Incident Reports? A Controlled Comparison of BERT Architectures, Loss Re-weighting, and LLM-Based Data Augmentation

Architecture or Imbalance Handling? A Controlled Evaluation of BERT-Based Models for Classifying Marine Incident Reports

اسکلت چکیده (۲۰۰ تا ۲۵۰ کلمه)

زمینه (۱ جمله): *Marine accident reports are a key source for safety learning, but their manual classification is slow and the most safety-critical incident types are rare.*

شکاف (۱ جمله): *Prior work reported gains from adding BiLSTM layers to BERT, but under non-identical training settings and single runs.*

روش (۲ جمله): *Using 5,762 public MAIB reports in nine classes, we compare a TF-IDF + SVM baseline with BERT, BERT + BiLSTM and BERT + BiLSTM + attention under identical settings and multiple seeds, and evaluate four loss functions, oversampling and LLM-based data augmentation with a label-consistency filter.*

نتایج (۲ تا ۳ جمله): *All BERT models outperform the baseline (macro-F1 0.885 vs. up to 0.915). BiLSTM and attention layers bring no gain beyond seed variance, even with up to eight times more BiLSTM parameters, whereas inverse-frequency weighted cross-entropy improves macro-F1 by 0.009. Adding LLM-based paraphrases of rare-class reports gives the best configuration (macro-F1 0.915), although its gain over the weighted loss alone (0.001) is within seed variance.*

پیام (۱ جمله): *Error and attention analyses indicate that the remaining errors stem mainly from single-label annotation of multi-event reports rather than from model capacity.*

فهرست جدول‌ها و شکل‌ها

شماره	محتوا	فایل یا منبع
Fig. 1	نمای کلی روش (معماری)	باید کشیده شود
Fig. 2	توزیع کلاس‌ها	`reports/class_distribution.png`
Fig. 3	Macro-F1، نمودار میله‌ای با میله‌ی خطا (محور از صفر)	`fig_macro_f1.png` از `presentations/_build`
Fig. 3b	recall بحرانی، همان شکل	`fig_critical_recall.png` از `presentations/_build`
Fig. 4	ماتریس درهم‌ریختگی	`reports/confusion_matrix.png`
Fig. 5	recall هر کلاس	`reports/per_class_recall.png`
Table 1	داده	بخش ۵
Table 2	تنظیمات آموزش	بخش ۶-۶
Table 3	نتایج اصلی	بخش ۸-۱
Table 4	هر کلاس	بخش ۸-۴
Table 5	واژه‌های attention	بخش ۸-۶
Table 6	مثال‌های خطا	بخش ۸-۷

پیش از ارسال مقاله (چک‌لیست)

- ✓ نتایج LLM augmentation و BiLSTM بزرگ‌تر (انجام شد)
- ☐ seed سوم (حداقل برای ce، wce، oversampling و augmentation)
- ☐ آزمون paired bootstrap یا McNemar برای مقایسه‌های اصلی
- ☐ (پیشنهادی) یک مدل قوی‌تر، مثل RoBERTa یا DeBERTa
- ☐ شکل معماری
- ☐ بررسی همه‌ی منابع در Google Scholar
- ☐ انتشار کد در GitHub و لینکش در مقاله
- ☐ بازخوانی برای حذف هر ادعای بدون عدد یا منبع

کجا ارسال کنیم؟

برای شروع، دو نشریه‌ای را ببین که کارهای مرتبط در آن‌ها چاپ شده:

- **Systems** (MDPI): مقاله‌ی مرجع.

Ocean Engineering *(Elsevier): Black et al. (2026).*

تصمیم نهایی با استاد راهنماست. نشریه‌ها قالب و محدودیت تعداد کلمه‌ی خودشان را دارند.

بخش ۱۲: منابع

⚠️ پیش از ارسال، **همه** را در Google Scholar چک کن (سال، صفحه، نام نشریه).

Anaby-Tavor, A., et al. (2020). Do not have enough data? Deep learning to the rescue! AAAI.

Bahdanau, D., Cho, K., & Bengio, Y. (2015). Neural machine translation by jointly learning to align and translate. ICLR.

Black, H., Kurt, R., & Turan, O. (2026). A domain-adapted NLP pipeline for human factors classification of maritime accidents. Ocean Engineering, 357, 125625.

Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). SMOTE: Synthetic minority over-sampling technique. Journal of Artificial Intelligence Research, 16.

Cui, Y., Jia, M., Lin, T.-Y., Song, Y., & Belongie, S. (2019). Class-balanced loss based on effective number of samples. CVPR.

Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of deep bidirectional transformers for language understanding. NAACL-HLT.

Dietterich, T. G. (1998). Approximate statistical tests for comparing supervised classification learning algorithms. Neural Computation, 10(7).

Hochreiter, S., & Schmidhuber, J. (1997). Long short-term memory. Neural Computation, 9(8).

Jain, S., & Wallace, B. C. (2019). Attention is not explanation. NAACL-HLT.

Joachims, T. (1998). Text categorization with support vector machines: Learning with many relevant features. ECML.

Kang, B., et al. (2020). Decoupling representation and classifier for long-tailed recognition. ICLR.

Lin, T.-Y., Goyal, P., Girshick, R., He, K., & Dollár, P. (2017). Focal loss for dense object detection. ICCV.

Longpre, S., Wang, Y., & DuBois, C. (2020). How effective is task-agnostic data augmentation for pretrained transformers? Findings of EMNLP.

Loshchilov, I., & Hutter, F. (2019). Decoupled weight decay regularization. ICLR.

Micikevicius, P., et al. (2018). Mixed precision training. ICLR.

Munaev (2025). MAIB incident reports 5K [dataset]. Hugging Face: `baker-street/maib-incident-reports-5K`.

Nguyen, W., et al. (2025). Llamarine: Open-source maritime industry-specific large language model. arXiv:2503.00203.

Park, H., et al. (2025). AIS-LLM: A unified framework for maritime trajectory prediction, anomaly detection, and collision risk assessment with explainable forecasting. arXiv:2508.07668.

Qwen Team (2024). Qwen2.5 technical report. arXiv:2412.15115.

Salton, G., & Buckley, C. (1988). Term-weighting approaches in automatic text retrieval. Information Processing & Management, 24(5).

Schuster, M., & Paliwal, K. K. (1997). Bidirectional recurrent neural networks. IEEE Transactions on Signal Processing, 45(11).

Sennrich, R., Haddow, B., & Birch, A. (2016). Improving neural machine translation models with monolingual data. ACL.

Vaswani, A., et al. (2017). Attention is all you need. NeurIPS.

Wang, S., Hou, Y., Qiu, P., Wang, K., & Wang, B. (2026). Ship fire and explosion accident evolution modeling based on ontology-enhanced text mining and dynamic Bayesian network.

Wei, J., & Zou, K. (2019). EDA: Easy data augmentation techniques for boosting performance on text classification tasks. EMNLP-IJCNLP.

Wiegreffe, S., & Pinter, Y. (2019). Attention is not not explanation. EMNLP-IJCNLP.

Yu, H., Xu, X., Guo, Z., Wei, T., & Xu, L. (2026). Semantic modeling of ship collision reports: Ontology design, knowledge extraction, and severity classification.

Zhao, Z., Liu, X., Feng, L., Grifoll, M., & Feng, H. (2025). Causation analysis of marine traffic accidents using deep learning approaches: A case study from China's coasts. Systems, 13(4), 284.

Zhou, P., et al. (2016). Attention-based bidirectional long short-term memory networks for relation classification. ACL.

(نام نشریه‌ی Yu و Wang را از صفحه‌ی اول PDF خودشان در `docs/papers/` تکمیل کن.)

واژه‌نامه‌ی کوتاه

اصطلاح	معنی
ablation study	مطالعه‌ی حذفی: هر بار فقط یک جزء عوض می‌شود تا اثرش جدا دیده شود
baseline	خط مبنا: روش ساده برای مقایسه
class imbalance	نامتوازنی کلاس‌ها
data augmentation	افزایش داده: ساختن نمونه‌ی آموزشی جدید
data leakage	نشت داده: رسیدن اطلاعات آزمون به آموزش
fine-tuning	تنظیم دقیق مدل پیش‌آموخته برای کار جدید
macro-F1	میانگین ساده‌ی F1 همه‌ی کلاس‌ها
paraphrasing	بازنویسی با کلمه‌های دیگر و همان معنی
recall / precision	بازیابی / دقت هر کلاس
seed	عدد شروع تصادف
stratified split	تقسیم با حفظ نسبت کلاس‌ها