

راهنمای آمادگی جلسه

دسته بندی گزارش های حوادث دریایی با مدل های زبانی

هر چیزی که باید درباره ی پروژه بدانی، به زبان ساده، به همراه جواب آماده برای سؤال های
احتمالی استاد

محمد مهدی عرب · جلسه با دکتر هدی مشایخی · مهر ۱۴۰۵

این فایل را چطور بخوانی

- فقط ۲۰ دقیقه وقت داری؟ بخش ۱ (پیام ۶۰ ثانیه‌ای)، بخش ۲ (کارت عددها) و بخش ۱۶ (بانک سؤال‌ها) را بخوان.
- یک ساعت وقت داری؟ همه را به ترتیب بخوان. هر بخش با یک کادر «جمله‌ی آماده» تمام می‌شود که می‌توانی عیناً بگویی.
- صبح قبل از جلسه: فقط بخش ۲ (عددها) و بخش ۱۷ (جمله‌های ممنوع) را مرور کن.
- قانون طلایی: اگر جواب سؤال‌ی را نمی‌دانی، عدد نساز. بگو: «این را هنوز نیاموده‌ام؛ با این آزمایش می‌شود آزمودش.» استاد به صداقت بیشتر از جواب کامل نمره می‌دهد.

حتمأً به خاطر بسپار

مراقب باش: دام رایج

جمله‌ی آماده: عیناً بگو

فهرست

۱. پیام اصلی در ۶۰ ثانیه
۲. کارت عددها
۳. مسئله و هدف پژوهش
۴. داده
۵. مدل‌ها به زبان ساده
۶. توابع زیان
۷. Oversampling
۸. تنظیمات آموزش و دلیل هر کدام
۹. ارزیابی: Macro-F1، recall و «نوسان seed»
۱۰. نتایج اصلی: RQ1 و RQ2
۱۱. Attention و تحلیل خطا
۱۱. نتایج oversampling
۱۲. مقایسه با مقاله‌ی مرجع
۱۲. محدودیت‌ها
۱۴. گام‌های بعدی
۱۶. بانک سؤال و جواب
۱۱. جمله‌های ممنوع و جایگزین درست
۱۷. نقشه‌ی کد
۱۴. واژه‌نامه

۱. پیام اصلی در ۶۰ ثانیه

وقتی استاد گفت «خب، چه کار کردی؟»، این متن را با زبان خودت بگو. حفظ کردن کلمه به کلمه لازم نیست؛ ترتیب و عددها مهم‌اند.

متن ۶۰ ثانیه‌ای

«هدف پروژه دسته‌بندی خودکار گزارش‌های حوادث دریایی بر اساس نوع حادثه است، با تأکید روی کلاس‌های کمیاب و خطرناک: آتش‌سوزی، واژگونی و غرق‌شدن.»

«روی داده‌ی عمومی MAIB با ۹ کلاس، شش پیکربندی BERT را با تنظیمات کاملاً یکسان و دو seed آموزش دادم و با خط مبنای کلاسیک SVM + TF-IDF مقایسه کردم.»

«سه یافته‌ی اصلی دارم. **یک:** همه‌ی مدل‌های BERT از خط مبنای کلاسیک بهترند؛ Macro-F1 از 0.885 به 0.898 تا 0.914 رسید. **دو:** برخلاف ادعای مقاله‌ی مرجع، با تنظیمات یکسان، BiLSTM و attention بهبودی بیشتر از نوسان بین seedها ندادند. **سه:** بیشترین بهبود از تابع زیان وزن‌دار (wce) آمد؛ بهترین مدل attention + wce است با Macro-F1 برابر 0.914 و دقت 0.935.»

«oversampling را هم طبق خواسته‌ی جلسه‌ی قبل پیاده کردم. روی SVM عملاً اثری نداشت (0.0005+). نتیجه‌ی BERT را هم آورده‌ام [عدد امروز صبح].»

«تحلیل خطا نشان می‌دهد سقف حدود 0.91 بیشتر از ابهام برچسب‌ها می‌آید تا ضعف مدل؛ مثلاً گزارشی که هم خرابی موتور دارد و هم به گل نشستن.»

اگر فقط سه جمله یادت بماند

- BERT بهتر از SVM است: Macro-F1 از 0.885 به 0.914.
- لایه‌های اضافه (attention، BiLSTM) کمک معناداری نکردند؛ تابع زیان وزن‌دار کمک کرد (0.009+).
- سقف حدود 0.91 از ابهام برچسب گزارش‌های چندرویدادی است.

۲. کارت عددها

این عددها را قبل از جلسه دو بار بلند بخوان. استادها معمولاً با عدد امتحان می‌کنند که دانشجو واقعاً خودش کار کرده یا نه.

داده

چه چیزی	عدد	توضیح کوتاه
گزارش خام	5,768	دیتاست عمومی MAIB روی Hugging Face
تکراری حذف شده	1	یک گزارش دقیقاً تکراری
کلاس حذف شده	2	Hull Failure (۳ گزارش) و Non-accidental Event (۲ گزارش)
داده‌ی نهایی	5,762 گزارش، ۹ کلاس	
تقسیم ۷۰/۱۵/۱۵	4,033 / 864 / 865	آموزش / اعتبارسنجی / آزمون، stratified، seed = 42
نسبت نامتوازی	16.8	بزرگ‌ترین کلاس (Accident، 1,662) تقسیم بر کوچک‌ترین (Capsizing، 99)
میان‌ه‌ی طول گزارش	59 واژه	۷۵٪ گزارش‌ها کمتر از ۸۴ واژه
Capsizing (کمیب‌ترین)	69 آموزش، 15 آزمون	هر گزارش آزمون = 6.7 واحد recall

نتایج اصلی (Macro-F1 روی ۸۶۵ گزارش آزمون، میانگین $\pm$ انحراف معیار ۲ seed)

پیکربندی	Macro-F1	Recall کلاس‌های بحرانی	Accuracy
TF-IDF + SVM	0.885	0.827	0.914
TF-IDF + SVM + oversampling	0.885 (0.8851)	0.834	0.917
BERT	0.898 ± 0.007	0.873 ± 0.008	0.927
BERT + BiLSTM (مقاله‌ی مرجع)	0.901 ± 0.004	0.851 ± 0.040	0.928
BERT + BiLSTM + Attention	0.905 ± 0.004	0.845 ± 0.016	0.931
Attention + wce (بهترین)	0.914 ± 0.006	0.868 ± 0.016	0.935
+ Attention + focal	0.905 ± 0.001	0.858 ± 0.012	0.930
+ Attention + cb	0.910 ± 0.001	0.857 ± 0.000	0.935
+ Attention + oversampling	[امروز صبح]		

تفاوت‌های کلیدی

مقایسه	تغییر Macro-F1	حکم
BiLSTM در برابر BERT ساده	+0.004	در حد نوسان seed
Attention در برابر BiLSTM (RQ1)	+0.004	در حد نوسان seed
wce در برابر ce (RQ2)	+0.009	بزرگ‌تر از نوسان
cb در برابر ce	+0.005	کمی بزرگ‌تر از نوسان؛ قطعی نیست

مقایسه	تغییر Macro-F1	حکم
focal در برابر ce	± 0.000	بی‌اثر
SVM با oversampling در برابر SVM	$+0.0005$	عملاً صفر
بهترین مدل در برابر بازتولید مقاله‌ی مرجع	$+0.013$	بیشترش از تابع زیان

آموزش

تنظیم	مقدار
مدل پایه	bert-base-uncased (۱۲ لایه، بردار ۷۶۸ بعدی، حدود ۱۱۰ میلیون پارامتر)
حداکثر طول ورودی	192 توکن (حدود ۲٪ گزارش‌ها بریده می‌شوند)
batch مؤثر	$32 = 8 \times 4$ (gradient accumulation)
learning rate	2e-5 برای BERT، 1e-3 برای لایه‌های جدید
epoch	حداکثر ۵، توقف زودهنگام با صبر ۲
زمان	حدود ۷۵ دقیقه برای هر اجرا روی GTX 1650 Ti (4GB)؛ ۱۲ اجرا $\approx$ ۱۵ ساعت GPU
بهترین epoch	در ۹ اجرا از ۱۲ اجرا، epoch پنجم (آخرین)

۳. مسئله و هدف پژوهش

مسئله چیست؟

MAIB (Marine Accident Investigation Branch) سازمان بررسی سوانح دریایی بریتانیاست. برای هر حادثه یک گزارش کوتاه متنی ثبت می‌شود و یک کارشناس نوع حادثه را مشخص می‌کند: آتش‌سوزی، تصادم، به گل نشستن و غیره. هدف ما این است که مدل از روی متن، نوع حادثه را خودکار تشخیص دهد.

چرا مهم است؟ دسته‌بندی دستی کند و پرهزینه است. دسته‌بندی خودکار به جست‌وجو، آمارگیری و تشخیص زودهنگام الگوهای خطر کمک می‌کند.

چالش اصلی: نامتوازنی

کلاس‌های خطرناک‌تر کمیاب‌ترند. آتش‌سوزی، واژگونی و غرق‌شدن روی هم فقط حدود ۱۰٪ داده‌اند. مدلی که فقط به دقت کلی (accuracy) نگاه کند، می‌تواند این کلاس‌ها را تقریباً نادیده بگیرد و باز هم دقت بالایی بگیرد. برای همین این سه کلاس را «ایمنی‌بحرانی» نامیدیم و recall آن‌ها را جدا گزارش می‌کنیم.

پرسش‌های پژوهش (از پروپوزال)

- **RQ1:** آیا یک لایه‌ی attention روی خروجی BiLSTM، نسبت به معماری BERT + BiLSTM مقاله‌ی مرجع، نتیجه را بهتر می‌کند؟
- **RQ2:** کدام روش مقابله با نامتوازنی (cb, focal, wce) روی کلاس‌های کمیاب بهتر کار می‌کند؟
- **قید پروپوزال:** بدون تولید داده‌ی مصنوعی (data augmentation).

وظیفه‌ی جلسه‌ی قبل

- نتیجه‌ی کامل گرفتن و گزارش کامل ← انجام شد: ۱۲ اجرای BERT، SVM، گزارش Word و اسلاید.
- بررسی oversampling برای بهبود نتیجه ← روی SVM انجام شد؛ BERT در حال اجرا یا تازه تمام‌شده.

۴. داده

منبع

دیتاست عمومی `baker-street/maib-incident-reports-5K` روی Hugging Face (Munaev, 2025)؛ مجوز Apache-2.0). برچسب‌ها از فیلد «Main Event L1» خود MAIB آمده‌اند. ما برچسب‌ها را دستی تغییر ندادیم.

چرا این دیتاست خوب است

- عمومی است: هر کسی می‌تواند نتایج ما را دقیقاً بازتولید کند. داده‌ی مقاله‌ی مرجع عمومی نیست.
- برچسب رسمی دارد: برچسب‌ها را کارشناس MAIB زده، نه ما.

پاک‌سازی (فایل `step1_prepare_data.py`)

۱. فاصله‌های اضافه حذف شد و املای متفاوت یک برچسب یکی شد.
۲. گزارش‌های دقیقاً تکراری حذف شد (۱ گزارش). اگر یک متن با دو برچسب متفاوت آمده بود، حذف می‌شد (۰ مورد).
۳. کلاس‌های کمتر از ۲۰ گزارش حذف شدند: Hull Failure (۳) و Non-accidental Event (۲).
۴. تقسیم stratified ۷۰/۱۵/۱۵ با seed ثابت ۴۲.

کلاس‌ها

کلاس	فارسی	کل	آموزش	آزمون
Accident to person(s)	آسیب به اشخاص	1,662	1,163	250
Damage / Loss Of Equipment	آسیب یا از دست رفتن تجهیزات	1,374	962	206
Loss Of Control	از دست رفتن کنترل	823	576	124
Grounding / Stranding	به گل نشستن	561	393	84
Contact	برخورد با جسم ثابت (اسکله، پل)	406	284	61
Collision	تصادم دو شناور	326	228	49
Fire / Explosion	آتش‌سوزی و انفجار (بحرانی)	324	227	48
Flooding / Foundering	آب‌گرفتگی و غرق (بحرانی)	187	131	28
Capsizing / Listing	واژگونی و کج شدن (بحرانی)	99	69	15

سه تصمیم که باید بتوانی از آن دفاع کنی

سؤال: چرا دو کلاس را حذف کردی؟

با ۳ و ۲ گزارش، در مجموعه‌ی آزمون صفر یا یک نمونه از آن‌ها می‌ماند. یک پیش‌بینی درست یا غلط به‌تنهایی Macro-F1 را چند واحد جابه‌جا می‌کرد و مقایسه‌ی مدل‌ها بی‌معنی می‌شد. آستانه (۲۰ گزارش) در `config.py` است و در پایان‌نامه گزارش می‌شود.

سؤال: چرا تقسیم stratified؟

تا نسبت کلاس‌ها در آموزش، اعتبارسنجی و آزمون یکسان باشد. بدون آن، ممکن بود Capsizing در آزمون فقط ۵ نمونه داشته باشد.

سؤال: چرا یک تقسیم ثابت برای همه‌ی مدل‌ها؟

تا همه‌ی مدل‌ها «همان امتحان» را بدهند و تفاوت نتیجه فقط از مدل بیاید. seed تقسیم (۴۲) از seed آموزش (۱ و ۲) جداست.

طول ورودی ۱۹۲ توکن: میانه‌ی گزارش ۵۹ واژه است و BERT هر واژه را به حدود ۱ تا ۲ «word-piece» می‌شکند. با ۱۹۲ توکن فقط حدود ۲٪ گزارش‌ها بریده می‌شوند، و حافظه‌ی GPU چهار گیگابایتی هم کافی است.

۵. مدل‌ها به زبان ساده

چهار مدل داریم. سه مدل عصبی دقیقاً یک BERT مشترک دارند و فقط در «سر» (head) فرق دارند: اینکه بردارهای واژه‌ها چگونه به یک بردار برای کل گزارش تبدیل شوند.



مدل	سر (head) چه می‌کند	تشبیه ساده
BERT	فقط بردار توکن ویژه‌ی [CLS] را برمی‌دارد	خلاصه‌ای که BERT خودش از کل متن ساخته
BERT + BiLSTM (مرجع)	یک (128 BiLSTM واحد در هر جهت) متن را از چپ به راست و از راست به چپ می‌خواند؛ حالت پایانی دو جهت (256 عدد) به طبقه‌بند می‌رود	دو نفر متن را از دو طرف می‌خوانند و جمع‌بندی‌شان را می‌گویند
BERT + BiLSTM + Attention (پیشنهادی)	به هر واژه یک وزن می‌دهد و میانگین وزن‌دار همه‌ی واژه‌ها را به طبقه‌بند می‌دهد	زیر واژه‌های مهم خط کشیدن
TF-IDF + SVM (کلاسیک)	هر گزارش = بردار وزن واژه‌ها و جفت‌واژه‌ها؛ SVM خطی کلاس‌ها را جدا می‌کند	شمردن واژه‌های کلیدی

BERT و fine-tuning

BERT قبلاً روی میلیاردها واژه‌ی انگلیسی آموزش دیده و زبان را می‌فهمد. **Fine-tuning** یعنی همه‌ی وزن‌های BERT را با learning rate خیلی کوچک کمی تنظیم کنیم تا برای کار ما (۹ کلاس حادثه) تخصصی شود. ما BERT را منجمد نکردیم؛ کل

مدل آموزش می‌بیند.

word-piece: BERT واژه‌های ناآشنا را به تکه‌های آشنا می‌شکند؛ مثلاً `capsized` ممکن است `caps` + `ized` شود. اول هر متن توکن ویژه‌ی `[CLS]` و آخرش `[SEP]` می‌آید.

Attention دقیقاً چه می‌کند؟

خروجی BiLSTM برای هر واژه‌ی t یک بردار h_t است (256 عدد). Attention سه قدم دارد (Zhou et al., 2016):

```
score_t = v · tanh(W · h_t)      # one number per word: how useful is word t?
alpha    = softmax(score)         # weights between 0 and 1 that sum to 1
c        = Σ_t alpha_t · h_t      # weighted average = one vector for the whole report
```

- W و v پارامترهای قابل‌آموزش‌اند ($v: 128 \rightarrow 1$, $W: 256 \rightarrow 128$).
- واژه‌های padding (جاهای خالی برای هم‌طول کردن batch) قبل از softmax ماسک می‌شوند، پس وزنشان دقیقاً صفر است.
- **مزیت:** وزن‌های α را ذخیره می‌کنیم و می‌بینیم مدل به کدام واژه‌ها «نگاه کرده»: تفسیرپذیری.

سؤال احتمالی: «BERT خودش attention دارد، این چه فرقی دارد؟»

BERT در هر کدام از ۱۲ لایه‌اش self-attention دارد: هر واژه به همه‌ی واژه‌ها نگاه می‌کند تا **بردار خودش** را بسازد. Attention ما یک **attention pooling** است: فقط یک بار، برای ساختن یک بردار برای کل گزارش، به هر واژه یک وزن می‌دهد. مزیتش این است که این یک‌سری وزن را می‌شود مستقیم دید و تفسیر کرد.

جزئیات فنی سر مدل

- Dropout 0.1 قبل از لایه‌ی خطی آخر، برای جلوگیری از overfitting.
- BiLSTM با packing اجرا می‌شود تا padding روی حالت پایانی اثر نگذارد.
- BiLSTM، attention و طبقه‌بند در دقت fp32 اجرا می‌شوند، چون LSTM و softmax در fp16 ناپایدارند.

TF-IDF + SVM

- **TF-IDF**: برای هر واژه یک عدد. بالاست اگر واژه در این گزارش زیاد باشد و در کل گزارش‌ها کم.
- تنظیمات: واژه‌ها و جفت‌واژه‌ها (`ngram_range=(1,2)`)، حذف واژه‌هایی که فقط در یک گزارش آمده‌اند (`min_df=2`)، `sublinear_tf=True`.
- **LinearSVC** با $C=1$: یک مرز خطی بین کلاس‌ها. روی CPU چند ثانیه طول می‌کشد.
- **چرا لازم است؟** اگر BERT نتواند این مدل ساده را به‌روشنی شکست دهد، هزینه‌ی BERT توجیه ندارد. مقاله‌ی مرجع چنین خط مبنایی ندارد.

۶. توابع زیان

تابع زیان می‌گوید مدل برای هر اشتباه چقدر «جریمه» شود. چهار تابع زیان را مقایسه کردیم. وزن کلاس‌ها فقط از داده‌ی آموزش محاسبه شد؛ استفاده از شمارش val یا test نشت داده بود.

نام	ایده	فرمول	تنظیم
ce	همه‌ی گزارش‌ها برابرند؛ «هیچ اقدامی»	$-\log p$	مبنا
wce	کلاس کمیاب‌تر، جریمه‌ی بیشتر	$w_c = N / (K \cdot n_c)$	وزن معکوس فراوانی
focal	گزارش‌های آسان کمتر حساب شوند	$-(1 - p)^\gamma \cdot \log p$	$\gamma = 2$ (Lin et al., 2017)
cb	نسخه‌ی ملایم wce با «تعداد مؤثر»	$w_c \propto (1 - \beta) / (1 - \beta^{n_c})$	$\beta = 0.999$ (Cui et al., 2019)

در فرمول‌ها: p احتمالی است که مدل به کلاس درست می‌دهد، N کل گزارش‌های آموزش (4,033)، K تعداد کلاس‌ها (۹)، و n_c تعداد گزارش‌های کلاس c .

وزن‌های واقعی کلاس‌ها در آزمایش ما

کلاس	n_c (آموزش)	وزن wce	وزن cb
Capsizing / Listing	69	6.49	2.97
Flooding / Foundering	131	3.42	1.61
Fire / Explosion	227	1.97	0.98
Collision	228	1.97	0.97
Contact	284	1.58	0.80
Grounding / Stranding	393	1.14	0.61
Loss Of Control	576	0.78	0.45
Damage / Loss Of Equipment	962	0.47	0.32
Accident to person(s)	1,163	0.39	0.29

از این جدول چه بگوییم

- با wce یک اشتباه روی Capsizing حدود ۱۷ برابر یک اشتباه روی Accident جریمه دارد ($6.49 \div 0.39$).
- cb ملایم‌تر است: حدود ۱۰ برابر ($2.97 \div 0.29$)، چون فرض می‌کند گزارش‌های یک کلاس بزرگ تا حدی شبیه هم‌اند و هر گزارش جدید اطلاعات کمتری اضافه می‌کند.
- focal اصلاً به اندازه‌ی کلاس نگاه نمی‌کند؛ به «سختی» هر گزارش نگاه می‌کند. اگر مدل با احتمال 0.9 درست بگوید، ضریب جریمه $0.01 = (1 - 0.9)^2$ است؛ با احتمال 0.5، ضریب 0.25 است.

Oversampling .۷

ایده: به جای اینکه جریمه‌ی اشتباه روی کلاس کمیاب را بالا ببریم (wce)، کلاس کمیاب را بیشتر به مدل نشان بدهیم.

دو پیاده‌سازی

(step3_train.py --oversample) BERT	(step2_tfidf_svm.py) SVM	
روش	کپی تصادفی گزارش‌های کلاس‌های کوچک تا همه هم‌اندازه‌ی بزرگ‌ترین کلاس (1,163) شوند	
از 4,033 به 10,467 گزارش	هر epoch همچنان 4,033 نمونه‌گیری	اندازه‌ی داده‌ی آموزش
1,163 گزارش	حدود 448 نمونه (9 ÷ 4,033)	هر کلاس در هر epoch
حدود ۱۷ بار کپی	به‌طور میانگین 6.5 بار در هر epoch	یک گزارش Capsizing
—	ce (نه wce)	تابع زیان

سه تصمیم طراحی و دلیشان

۱. فقط داده‌ی آموزش **oversample** شد. val و test دست‌نخورده‌اند. اگر قبل از تقسیم داده تکثیر می‌کردیم، کپی یک گزارش می‌توانست هم در آموزش و هم در آزمون باشد و نمره‌ی آزمون مصنوعی بالا می‌رفت (نشت داده).
۲. در BERT طول epoch ثابت ماند. پس تعداد به‌روزرسانی وزن‌ها با بقیه‌ی اجراها برابر است و تفاوت نتیجه فقط از «ترکیب داده» می‌آید، نه از «آموزش بیشتر». کپی کامل، هر epoch را ۲/۵ برابر طولانی می‌کرد (حدود ۳ ساعت برای هر اجرا).
۳. با ce ترکیب شد، نه wce. هر دو نامتوازی را جبران می‌کنند؛ ترکیبشان جبران را دو برابر می‌کرد و مدل بیش از حد به سمت کلاس‌های کمیاب می‌رفت.

نکته‌ی طلایی (این را حتماً بگو؛ نشان می‌دهد عمیق فهمیده‌ای)

در BERT، تعداد دفعاتی که یک گزارش Capsizing در هر epoch دیده می‌شود (6.49) دقیقاً همان وزن wce آن کلاس است (6.49). یعنی oversampling و wce در امید ریاضی تقریباً یک کار می‌کنند: سهم هر کلاس در گرادین را برابر می‌کنند.

تفاوتشان در نحوه‌ی انجام است: wce هر گزارش را دقیقاً یک بار در هر epoch می‌بیند و فقط وزن جریمه را عوض می‌کند. oversampling تصادفی است: گزارش‌های کمیاب را تکرار می‌کند و در هر epoch حدود دوسوم گزارش‌های کلاس بزرگ اصلاً دیده نمی‌شوند. پس آزمایش ما در واقع می‌پرسد: «آیا روش متوازن‌سازی مهم است؟»

چرا روش‌های دیگر نه؟

- undersampling (کم کردن کلاس بزرگ): برای برابر شدن با Capsizing باید ۹۴٪ گزارش‌های Accident دور ریخته شود.
- SMOTE: نمونه‌ی مصنوعی در فضای بردار می‌سازد، نه متن واقعی. پروپوزال صراحتاً «بدون داده‌ی مصنوعی» است.
- augmentation (بازنویسی یا ترجمه‌ی برگشتی): داده‌ی مصنوعی است، خطر نویز برچسب دارد، و اگر قبل از تقسیم انجام شود نشت داده می‌دهد؛ دقیقاً مشکلی که در مقاله‌ی مرجع نامشخص است.

۸. تنظیمات آموزش و دلیل هر کدام

قاعده‌ی کلی: **همه‌ی مدل‌های BERT با تنظیمات کاملاً یکسان آموزش دیدند.** هر دو پیکربندی پشت‌سرهم فقط در یک جزء فرق دارند (معماری یا تابع زیان). این مهم‌ترین تفاوت روش‌شناختی ما با مقاله‌ی مرجع است.

تنظیم	مقدار	چرا
learning rate	2e-5 برای BERT؛ 1e-3 برای لایه‌های جدید	BERT از قبل آموزش دیده و فقط باید کمی تنظیم شود. لایه‌های جدید از صفر شروع می‌کنند و lr بزرگ‌تری لازم دارند. 2e-5 در بازه‌ی استاندارد fine-tuning BERT است (Devlin et al., 2019).
batch	32 × 8 = 32	GPU چهار گیگابایت است و batch 32 جا نمی‌شود. گرادیان ۴ دسته‌ی ۸ تایی جمع می‌شود و بعد یک به‌روزرسانی انجام می‌شود؛ ریاضی‌اش معادل batch 32 است (مثل مقاله‌ی مرجع).
optimizer	AdamW، weight decay 0.01	استاندارد fine-tuning ترنسفورمرها.
scheduler	10% warmup + کاهش خطی	شروع ملایم تا گرادیان‌های بزرگ اولیه BERT را خراب نکنند.
gradient clipping	1.0	جلوگیری از گرادیان‌های انفجاری، به‌ویژه در LSTM.
دقت محاسبات	fp16 (mixed precision) + GradScaler	سریع‌تر و با حافظه‌ی کمتر. GradScaler گرادیان‌های خیلی کوچک را از صفر شدن در fp16 حفظ می‌کند.
epoch	حداکثر 5، صبر 2	محدودیت زمان: هر اجرا حدود ۷۵ دقیقه.
انتخاب مدل	بهترین epoch با Macro-F1 مجموعه‌ی val	test هیچ تصمیمی را تحت تأثیر قرار نمی‌دهد.
test	فقط یک بار، در پایان هر اجرا	تا نمره‌ی test برآورد صادقانه‌ای باشد.
seed	1 و 2	seed ثابت = نتیجه‌ی تکرارپذیر. دو seed برای سنجیدن نوسان تصادفی.

سؤال احتمالی: «مقاله‌ی مرجع lr را 1e-6 گذاشته، چرا تو 2e-5؟»

«1e-6 خیلی کوچک است و برای همگرایی ده‌ها epoch لازم دارد؛ با ۵ epoch مدل عملاً آموزش نمی‌بیند. 2e-5 مقدار استاندارد BERT fine-tuning است. برای بازتولید دقیق تنظیمات مقاله هم یک گزینه‌ی آماده در کد دارم: paper-settings - - با lr = 1e-6 و ۳۰ epoch. به‌خاطر زمان GPU هنوز اجرایش نکرده‌ام.»

۹. ارزیابی: Macro-F1، recall و «نوسان seed»

سه معیار پایه، با مثال Capsizing

- **Recall** (بازیابی): از ۱۵ گزارش واقعی Capsizing، مدل چندتا را پیدا کرد؟ اگر ۱۲ تا را پیدا کند، $\text{recall} = 12/15 = 0.80$. یعنی «چندتا را از دست ندادیم».
- **Precision** (دقت ردّه): از همه‌ی گزارش‌هایی که مدل گفت Capsizing، چندتا واقعاً Capsizing بودند؟ یعنی «چقدر هشدار اشتباه دادیم».
- **F1**: میانگین هارمونیک precision و recall؛ فقط وقتی بالاست که هر دو بالا باشند.

چرا Macro-F1 و نه Accuracy؟

Macro-F1 = میانگین ساده‌ی F1 نه کلاس. هر کلاس، کوچک یا بزرگ، وزن برابر دارد.

مثال قانع‌کننده برای استاد

فرض کن مدلی هیچ‌وقت Capsizing را پیش‌بینی نکند. accuracy فقط ۱۵ از ۸۶۵ گزارش، یعنی ۱.۷٪، پایین می‌آید. ولی F1 آن کلاس صفر می‌شود و چون Macro-F1 میانگین ۹ کلاس است، حدود ۰.۱۰ پایین می‌آید. پس Macro-F1 دقیقاً همان خطایی را می‌بیند که برای ما مهم است: نادیده گرفتن کلاس کمیاب و خطرناک.

Recall کلاس‌های بحرانی = میانگین recall سه کلاس آتش‌سوزی، واژگونی و آب‌گرفتگی. accuracy را فقط برای مقایسه با مقالات گزارش می‌کنیم.

«بزرگ‌تر از نوسان seed» یعنی چه؟


هر پیکربندی با دو seed آموزش دید و میانگین $\pm$ انحراف معیار گزارش شد. قاعده‌ی ما ساده است:

```
if |difference of means| > max(std of A, std of B): 'larger than seed-to-seed noise'
else: 'within seed-to-seed noise'
```

مهم‌ترین دام کل جلسه

هرگز نگو «تفاوت معنادار است» (significant). این یک آزمون آماری نیست؛ یک قاعده‌ی ساده است و با فقط ۲ seed، خود انحراف معیار هم تقریبی است. بگو: «بزرگ‌تر از نوسان بین seedها». اگر استاد پرسید آزمون آماری کردی یا نه، صادقانه بگو: «هنوز نه. گام بعدی bootstrap جفت‌شده یا آزمون McNemar روی پیش‌بینی‌های test است، که پیش‌بینی‌هایش در فایل‌های نتیجه ذخیره شده‌اند.»

۱۰. نتایج اصلی: RQ1 و RQ2



Macro-F1 و recall کلاس‌های بحرانی. نقطه: میانگین دو seed؛ خط: $\pm$ یک انحراف معیار.

آیا BERT بهتر از روش کلاسیک است؟

بله، به روشنی. همه‌ی مدل‌های BERT (0.898 تا 0.914) از SVM (0.885) بهترند. بیشترین برتری در Capsizing است: SVM ۱۰ گزارش از ۱۵ را پیدا می‌کند و مدل‌های BERT ۱۰.۵ تا ۱۲.

ولی صادق باش

فاصله‌ی SVM و BERT فقط حدود ۰.۰۱ تا ۰.۰۳ است. دلیلش این است که گزارش‌ها کوتاه و فرمولی‌اند و واژه‌های کلیدی (fire, aground, capsized) بار اصلی را می‌برند. این خودش یک یافته است: این مسئله بیشتر «واژه‌محور» است تا «معنای‌محور».

RQ1: آیا attention کمک می‌کند؟

BiLSTM نسبت به BERT ساده +0.004 و attention نسبت به BiLSTM +0.004 تغییر داد. هر دو در حد نوسان seed (0.004 تا 0.007) هستند.

جواب RQ1

«با تنظیمات یکسان، نه BiLSTM و نه attention بهبودی بیشتر از نوسان بین seedها نداد. فقط یک الگوی کوچک دیدم: attention در هر دو seed بهترین recall را روی سه کلاس «برخورد» داشت (Collision, Contact) و به گل نشستن)، کلاس‌هایی که معنایشان نزدیک است و تشخیصشان به یک واژه‌ی کلیدی وسط متن بستگی دارد. ولی این اثر کوچک است: حدود ۲ تا ۳ گزارش در Contact. پس ادعای مقاله‌ی مرجع درباره‌ی برتری BiLSTM روی این داده تأیید نشد. ارزش اصلی attention در کار ما تفسیرپذیری است.»

RQ2: کدام روش مقابله با نامتوازنی؟

تابع زیان	تغییر Macro-F1 نسبت به ce	تغییر recall بحرانی	حکم
wce	+0.009	+0.022	بزرگتر از نوسان
cb	+0.005	+0.011	کمی بزرگتر؛ با ۲ seed قطعی نیست
focal	±0.000	+0.013	در حد نوسان

جواب RQ2

«wce بیشترین بهبود را داد، +0.009 در Macro-F1 که از نوسان seedها بزرگتر است، و accuracy هم پایین نیامد (از 0.931 به 0.935). بهبود بیشتر در Collision و Loss of Control و حدود یک گزارش در Capsizing است، به قیمت حدود ۱.۵ گزارش از ۲۵۰ در Accident. cb بهبود کوچکتری داد و focal در Macro-F1 بی‌اثر بود.»

سؤال: چرا focal کمک نکرد؟ (احتمالاً می‌پرسد)

یک توضیح محتمل: focal روی «سختی» هر گزارش کار می‌کند، نه «کمیابی» کلاس. BERT بیشتر گزارش‌ها را با اطمینان بالا درست می‌گیرد، پس focal عملاً وزن چند گزارش سخت را بالا می‌برد که لزوماً از کلاس‌های کمیاب نیستند. ۷ را هم تنظیم نکردیم (مقدار پیش‌فرض مقاله‌ی اصلی، ۲). این را به‌عنوان فرضیه بگو، نه نتیجه‌ی قطعی.

تعداد گزارش‌های درست تشخیص داده‌شده در هر کلاس (میانگین دو seed)

کلاس (تعداد در آزمون)	SVM	BERT	+BiLSTM	+Att	+Att+wce
Capsizing (15)	10	12	11	10.5	11.5
Flooding (28)	24	23.5	23.5	24	24
Fire (48)	46	47	47	47	47
Collision (49)	43	44.5	45	45.5	47
Contact (61)	49	48.5	50	52	51.5
Grounding (84)	78	78	79	79.5	79.5
Loss Of Control (124)	110	109.5	110.5	110	113
Damage (206)	186	193	192	191	191
Accident (250)	245	246	244.5	246	244.5

سؤال احتمالی: «چرا BERT ساده بهترین recall بحرانی را دارد (0.873)؟»

«تفاوت مدل‌های BERT در Capsizing بین ۱۰.۵ و ۱۲ از ۱۵ است، یعنی فقط ۱ تا ۲ گزارش. با ۱۵ نمونه‌ی آزمون، هر گزارش ۶.۷ واحد recall را جابه‌جا می‌کند، پس این تفاوت قابل اتکا نیست. آنچه قطعی است برتری همه‌ی مدل‌های BERT بر SVM در این کلاس است.»

در ۹ اجرا از ۱۲ اجرا بهترین epoch همان epoch پنجم (آخر) بود و در ۳ اجرا epoch سوم. یعنی احتمالاً آموزش طولانی‌تر هنوز کمی بهبود می‌داد. این را در محدودیت‌ها آورده‌ام و گام بعدی، آموزش با ۸ epoch است.

۱۱. Attention و تحلیل خطا

واژه‌هایی که attention بیشترین وزن را به آن‌ها داد

کلاس	واژه‌های پروزن
Accident to person(s)	fractured ,injury ,passenger ,sustained ,fell
Capsizing	lost ,boat ,entered ,hit ,capsized
Collision	moored ,tanker ,manoeuvring ,pilot ,collided
Contact	lock ,struck ,quayside ,contact
Damage / Loss Of Equipment	regulations ,conform ,pilot ,ladder ,solas
Fire / Explosion	extinguish ,smoke ,caught ,engine
Flooding	started ,taking ,water ,ingress
Grounding	aground ,ran ,grounded
Loss Of Control	propulsion ,towed ,fouled ,engine ,failure

یافته‌ی غیرمنتظره (برجسته‌ترین نکته‌ی کیفی کارت)

در کلاس «آسیب تجهیزات»، پروزن‌ترین واژه‌ها regulations و conform, pilot, ladder, solas هستند. یعنی بخش بزرگی از این کلاس گزارش‌هایی درباره‌ی عدم انطباق پلکان راهنما (pilot ladder) با مقررات SOLAS است: یک زیرگروه همگن که مدل با چند واژه‌ی ثابت تشخیص می‌دهد. این را خود تحلیل attention آشکار کرد. SOLAS = کنوانسیون بین‌المللی ایمنی جان اشخاص در دریا. Pilot ladder = نردبانی که راهنمای بندر با آن سوار کشتی می‌شود.

احتیاط علمی (اگر استاد ایراد گرفت)


«وزن attention نشان می‌دهد مدل کجا را نگاه کرده، نه لزوماً چرا تصمیم گرفته است. این بحث در ادبیات شناخته‌شده است (Jain & Wallace, 2019: Attention is not Explanation). برای همین از attention برای «کشف الگو» استفاده کرده‌ام، نه به‌عنوان توضیح علی. در بعضی نمونه‌ها هم وزن بالا روی واژه‌های دستوری مثل a و and دیده می‌شود.»

تحلیل خطا: سه الگوی تکرارشونده

الگو	مثال واقعی از داده	معنی
زنجیره‌ی علت ← پیامد	«propulsion failure ... grounded» با برچسب Grounding، پیش‌بینی Loss of Control. برعکس: «dragged anchor ... went aground» با برچسب Loss of Control، پیش‌بینی Grounding.	MAIB گاهی علت را برچسب می‌زند و گاهی پیامد را.
گزارش چندرویدادی	«hit the lock side ... crewmember fell overboard» با برچسب Contact، پیش‌بینی Accident to person.	هر دو برداشت منطقی است.
واژگان تخصصی دریایی	«girting» (نوعی واژگونی یدک‌کش) و «allided» (برخورد با جسم ثابت)	BERT عمومی این واژه‌ها را نمی‌شناسد.

بیشترین اشتباه‌ها (بهترین مدل، جمع دو seed)

کلاس واقعی	پیش‌بینی مدل	تعداد
Damage / Loss Of Equipment	Loss Of Control	13
Loss Of Control	Damage / Loss Of Equipment	9
Contact	Collision	8
Damage / Loss Of Equipment	Contact	7
Grounding	Loss Of Control	6
Flooding	Grounding	5



ماتریس درهم‌ریختگی بهترین پیکربندی (Attention + wce). سطرها نرمال شده‌اند؛ قطر اصلی = recall.

نتیجه‌ی تحلیل خطا

«سقف حدود 0.91 بیش از آنکه از ظرفیت مدل باشد، از ابهام ذاتی برچسب تک‌کلاسه برای گزارش‌های چندرویدادی می‌آید. این توضیح می‌دهد چرا TF-IDF به BERT نزدیک است و چرا لایه‌های اضافه کمک کمی می‌کنند. یک جهت پژوهشی بعدی، دسته‌بندی چندبرچسبی یا جدا کردن علت از پیامد است.»

۱۲. نتایج oversampling

SVM (نتیجه‌ی قطعی)

تغییر	oversampling با	بدون oversampling	کلاس (تعداد در آزمون)
0	10	10	Capsizing (15)
0	24	24	Flooding (28)
+1	47	46	Fire (48)
+1	44	43	Collision (49)
0	49	49	Contact (61)
0	78	78	Grounding (84)
+3	113	110	Loss Of Control (124)
0	186	186	Damage (206)
-3	242	245	Accident (250)
+0.0005	0.8851	0.8846	Macro-F1
+2 گزارش	0.9168	0.9145	Accuracy

جواب oversampling روی SVM

«روی SVM، oversampling عملاً اثری نداشت: Macro-F1 فقط +0.0005. فقط حدود ۳ گزارش از بزرگ‌ترین کلاس (Accident) به کلاس‌های میانی جابه‌جا شد و کمیاب‌ترین کلاس، Capsizing، هیچ تغییری نکرد (۱۰ از ۱۵). پس پنج گزارش Capsizing که SVM اشتباه می‌گیرد، احتمالاً مشکل کمبود داده نیستند؛ احتمالاً مشکل معنایی‌اند و با کلاس‌های دیگر قاطی می‌شوند. این را هنوز گزارش‌به‌گزارش بررسی نکرده‌ام.»

«در ضمن، SVM بدون oversampling دقیقاً همان 0.8846 قبلی را داد؛ یعنی کد کاملاً تکرارپذیر است.»

BERT (امروز صبح کامل می‌شود)

بسته به عددی که امروز صبح می‌آید، یکی از این‌ها را بگو. «Δ» یعنی تفاوت با (0.905) Attention + ce و با Attention + wce (0.914).

اگر نتیجه این شد	بگو
حدود wce (0.909 تا 0.919)	«oversampling به همان سطح wce رسید. منطقی است، چون در امید ریاضی هر دو یک کار می‌کنند (6.49 = 6.49). پس روش متوازن‌سازی مهم نیست؛ wce ساده‌تر و ارزان‌تر است چون داده را تغییر نمی‌دهد.»
بین ce و wce، نزدیک هر دو	«oversampling بین ce و wce است و از هیچ‌کدام به‌روشنی جدا نیست. با ۲ seed نمی‌توان گفت کمک کرده؛ wce همچنان تنها بهبود قطعی است.»
پایین‌تر از ce، ولی recall بحرانی بالاتر	«oversampling کلاس‌های کمیاب را بیشتر پیش‌بینی کرد و recall آن‌ها بالا رفت، ولی بخشی از این پیش‌بینی‌ها اشتباه بود و precision افت کرد؛ مرز تصمیم بیش از حد به سمت کلاس‌های کمیاب رفت.»
پایین‌تر از ce و recall بحرانی هم پایین	«یک توضیح محتمل: هر یک از ۶۹ گزارش Capsizing در هر epoch حدود ۶.۵ بار تکرار می‌شود و مدل ممکن است همین گزارش‌ها را حفظ کند wce (overfitting). همین جبران را بدون تکرار داده انجام می‌دهد.»
بالاتر از wce (بیش از 0.920)	«oversampling بهترین پیکربندی فعلی است. با seed سوم تأییدش می‌کنم.»

اگر اجرای BERT تمام نشده بود

«پیاده‌سازی کامل است و اجرا در جریان است؛ هر اجرا حدود ۷۵ دقیقه طول می‌کشد. نتیجه‌ی SVM را دارم که اثری نشان نداد. نتیجه‌ی BERT را امروز برایتان می‌فرستم.» اگر فقط seed اول تمام شده بود، عددش را بگو، ولی حتماً اضافه کن «یک seed، نتیجه‌ی اولیه».

۱۳. مقایسه با مقاله‌ی مرجع (Zhao et al., 2025)

جنبه	مقاله‌ی مرجع	کار ما
وظیفه	دسته‌بندی علت حادثه (۳۲ کلاس)	دسته‌بندی نوع رویداد (۹ کلاس)
داده	GISIS و گزارش‌های سواحل چین؛ غیرعمومی	MAIB؛ عمومی
نامتوازن	افزایش داده تا حدود ۸۰۰ نمونه در هر کلاس	بدون داده‌ی مصنوعی؛ توابع زیان و oversampling
تنظیمات مدل‌ها	dropout، منظم‌سازی، آستانه‌ی گرادیان و تابع فعال‌سازی متفاوت بین مدل‌ها (جدول ۹ مقاله)	کاملاً یکسان
تکرار	یک اجرا	۲ seed، میانگین $\pm$ انحراف معیار
خط مبنای کلاسیک	ندارد	TF-IDF + SVM
معیار اصلی	Accuracy	Macro-F1 و recall هر کلاس

ایرادهای روش‌شناختی مقاله (با احترام بیان کن)

- تغییر هایپرپارامتر از بهبود ادعا شده بزرگ‌تر است. در جدول ۳ خود مقاله، با تغییر هایپرپارامترها، دقت BERT + BiLSTM بین 0.875 و 0.898 جابه‌جا می‌شود (۲.۳ واحد). بهبود ادعا شده‌ی BiLSTM نسبت به BERT (از 0.887 به 0.898) فقط ۱.۱ واحد است.
- تنظیمات متفاوت برای مدل‌ها (جدول ۹). پس معلوم نیست بهبود از معماری است یا از تنظیمات.
- یک اجرا بدون گزارش نوسان تصادفی.

۴. ترتیب augmentation و تقسیم داده مشخص نیست. در متن مقاله augmentation قبل از تقسیم داده شرح داده شده. اگر واقعاً قبل از تقسیم انجام شده باشد، نسخه‌های تقریباً یکسان یک گزارش می‌توانند هم در آموزش و هم در آزمون باشند.
۵. خط مبنای کلاسیک ندارد و معیار اصلی‌اش accuracy است که روی داده‌ی نامتوازن گمراه‌کننده است.

مراقب باش

نگو «نتیجه‌ی ما بهتر از مقاله است». وظیفه و داده فرق دارد و عددها مستقیماً قابل مقایسه نیستند. بگو: «با تنظیمات یکسان و چند seed، روی این داده بهبود BiLSTM را مشاهده نکردیم.» و درباره‌ی augmentation بگو «مشخص نیست»، نه «اشتباه کرده‌اند».

سهم (contribution) ما چیست؟

اگر پرسید «نوآوری کار تو چیست؟»

- ارزیابی منصفانه: تنظیمات یکسان، چند seed، خط مبنای کلاسیک و Macro-F1 با recall هر کلاس. با این روش ادعای برتری BiLSTM را آزمودیم و روی این داده تأیید نشد.
- مقایسه‌ی نظام‌مند چهار تابع زیان و oversampling، بدون داده‌ی مصنوعی، روی داده‌ی عمومی؛ با تأکید روی کلاس‌های ایمنی‌بحرانی.
- تفسیرپذیری: attention زیرگروه پنهان SOLAS را در کلاس آسیب تجهیزات آشکار کرد.
- تحلیل خطا: نشان دادیم سقف عملکرد از ابهام برچسب علت/پیامد می‌آید.
- بازتولیدپذیری: کد کامل روی داده‌ی عمومی؛ هر کسی با چند دستور همین عددها را می‌گیرد.

۱۴. محدودیت‌ها

محدودیت‌ها را خودت بگو، قبل از اینکه استاد بگوید. این نشانه‌ی بلوغ پژوهشی است، نه ضعف.

محدودیت	چطور بگویی
فقط ۲ seed	«برآورد انحراف معیار با ۲ نمونه تقریبی است. seed سوم و آزمون bootstrap گام بعدی است.»
آزمون آماری انجام نشده	«قاعده‌ی من مقایسه با نوسان seed است، نه آزمون معناداری. پیش‌بینی‌ها ذخیره شده و bootstrap جفت‌شده آماده‌ی اجراست.»
۱۵ نمونه‌ی Capsizing در آزمون	«هر گزارش ۶.۷ واحد recall است. تفاوت‌های ۱ تا ۲ گزارشی را تفسیر نمی‌کنم.»
حداکثر ۵ epoch	«در ۹ اجرا از ۱۲، بهترین epoch آخرین بود. آموزش ۸ epoch را بررسی می‌کنم.»
۷ و β تنظیم نشدند	«مقادیر پیشنهادی مقاله‌های اصلی را استفاده کردم؛ تنظیمشان کار بعدی است.»
یک تقسیم داده	«همه‌ی مدل‌ها روی یک تقسیم ثابت‌اند تا مقایسه منصفانه باشد؛ cross-validation هزینه‌ی GPU را ۵ برابر می‌کند.»
۲ کلاس حذف شد	«نتایج برای ۹ کلاس است؛ دو کلاس فقط ۵ گزارش داشتند.»
فقط BERT پایه	«مدل‌های قوی‌تر (DeBERTa، RoBERTa) و مدل دامن‌هی دریایی را هنوز امتحان نکرده‌ام.»

۱۵. گام‌های بعدی (به ترتیب اولویت)

گام	چرا	هزینه‌ی تقریبی
seed سوم برای پیکربندی‌های اصلی + bootstrap جفت‌شده	تبدیل «بزرگ‌تر از نوسان» به ادعای آماری	حدود ۸ ساعت GPU + نیم روز
آموزش با ۸ epoch برای بهترین مدل	بررسی اثر محدودیت ۵ epoch	حدود ۲ ساعت برای هر اجرا
بررسی دستی خطاهای Capsizing	فهمیدن اینکه چرا oversampling کمک نکرد	۱ تا ۲ ساعت
مدل‌های قوی‌تر: RoBERTa، DeBERTa، مدل دامنه‌ای	آیا سقف 0.91 با مدل بهتر جابه‌جا می‌شود؟	۱ تا ۲ روز GPU
LLM به‌صورت zero-shot یا few-shot	مقایسه با روش‌های جدید؛ داوران مقاله معمولاً می‌پرسند	یک تا دو روز
دسته‌بندی چندبرچسبی یا علت/پیامد	پاسخ به یافته‌ی تحلیل خطا	پژوهش جدید؛ نیاز به برچسب

اگر پرسید «قابل انتشار است؟»

«با وضعیت فعلی، پایه‌ی یک مقاله‌ی کنفرانسی یا مجله‌ی داخلی را دارد. برای مجله‌ی معتبر باید seed بیشتر و آزمون آماری، مدل‌های قوی‌تر و یک مقایسه با LLM اضافه شود. نقطه‌ی قوت اصلی، ارزیابی منصفانه روی داده‌ی عمومی و یافته‌ی ابهام برچسب است.»

۱۶. بانک سؤال و جواب

جواب‌ها کوتاه‌اند تا بشود گفتشان. اگر استاد بیشتر خواست، از بخش‌های قبل جزئیات بده.

داده

سؤال: چرا این دیتاست را انتخاب کردی؟

عمومی است (Apache-2.0)، برچسبش رسمی و از خود MAIB است، و هر کسی می‌تواند نتایج را بازتولید کند. داده‌ی مقاله‌ی مرجع عمومی نیست.

سؤال: چطور جلوی نشت داده (data leakage) را گرفتی؟

پنج کار: (۱) تکراری‌ها قبل از تقسیم حذف شد؛ (۲) وزن کلاس‌ها فقط از داده‌ی آموزش؛ (۳) oversampling فقط روی آموزش؛ (۴) انتخاب بهترین epoch فقط با val؛ (۵) test فقط یک بار در پایان هر اجرا.

سؤال: داده را دستی بررسی کردی؟ برچسب‌ها درست‌اند؟

برچسب‌ها رسمی‌اند و تغییرشان ندادم. در تحلیل خطا دیدم برخی برچسب‌ها مبهم‌اند (علت یا پیامد). این را به‌عنوان یافته گزارش کرده‌ام، نه اینکه برچسب‌ها را عوض کنم.

سؤال: گزارش‌های طولانی را چه کردی؟

حداکثر ۱۹۲ توکن. میانه‌ی گزارش ۵۹ واژه است و فقط حدود ۲٪ بریده می‌شوند.

مدل و روش

سؤال: چرا bert-base و نه مدل بزرگ‌تر؟

(۱) پروپوزال و مقاله‌ی مرجع BERT استفاده کرده‌اند و مقایسه باید هم‌سطح باشد. (۲) GPU من ۴ گیگابایت است. (۳) مدل‌های قوی‌تر در گام‌های بعدی‌اند.

سؤال: uncased یعنی چه؟

حروف بزرگ و کوچک یکی فرض می‌شوند: Fire و fire یکی‌اند.

سؤال: BiLSTM چطور به طبقه‌بند وصل می‌شود؟

در مدل مرجع حالت پایانی دو جهت به هم چسبانده می‌شود ($128 + 128 = 256$ عدد). در مدل پیشنهادی، attention میانگین وزن‌دار همه‌ی حالت‌ها را می‌سازد، باز هم ۲۵۶ عدد.

سؤال: Attention شما از کدام مقاله است؟

attention افزایشی (additive) مثل Zhou et al. (2016) برای BiLSTM؛ ریشه‌اش Bahdanau et al. (2015). فرمول: $\text{score} = v \cdot \tanh(W h)$ ، سپس softmax با ماسک padding.

سؤال: چرا BiLSTM روی BERT، وقتی BERT خودش متن را دوطرفه می‌فهمد؟

دقیقاً همین سؤال RQ1 ماست. جواب تجربی ما: با تنظیمات یکسان روی این داده، BiLSTM بهبودی بیش از نوسان نداد. این با شهود شما هم سازگار است.

سؤال: dropout چقدر است؟

0.1 قبل از لایه‌ی خطی آخر. داخل BERT هم dropout پیش‌فرض خودش (0.1) فعال است.

آموزش

سؤال: gradient accumulation چیست؟

GPU جای ۳۲ گزارش را با هم ندارد. ۴ دسته‌ی ۸ تایی را پشت‌سرهم پردازش می‌کنم، گرادیان‌ها را جمع می‌کنم و بعد یک بار وزن‌ها را به‌روز می‌کنم. ریاضی‌اش معادل batch 32 است.

سؤال: mixed precision یعنی چه؟

محاسبات BERT در اعداد ۱۶ بیتی (fp16) انجام می‌شود: سریع‌تر و با حافظه‌ی کمتر. GradScaler گرادیان را بزرگ می‌کند تا اعداد خیلی کوچک صفر نشوند. LSTM و attention در ۳۲ بیت می‌مانند چون در ۱۶ بیت ناپایدارند.

سؤال: چرا دو learning rate؟

BERT از قبل آموزش دیده و تغییر بزرگ دانشش را خراب می‌کند (catastrophic forgetting)، پس $2e-5$. لایه‌های جدید تصادفی شروع می‌کنند، پس $1e-3$.

سؤال: warmup چیست؟

در ۱۰٪ اول آموزش، learning rate از صفر به مقدار اصلی می‌رسد و بعد خطی کم می‌شود. در شروع، لایه‌های جدید تصادفی‌اند و گرادیان‌های بزرگ می‌توانند BERT را خراب کنند.

سؤال: چرا فقط ۵ epoch؟

محدودیت زمان: هر اجرا ۷۵ دقیقه و کل ۱۲ اجرا حدود ۱۵ ساعت. در ۹ اجرا بهترین epoch آخری بود؛ این را محدودیت گزارش کرده‌ام.

سؤال: چرا فقط ۲ seed؟ پروپوزال ۳ تا گفته بود.

به‌خاطر زمان GPU؛ seed سوم کد آماده دارد و با یک دستور اجرا می‌شود. اولویت اول گام بعدی است.

سؤال: نتایج تکرارپذیرند؟

بله. seed ثابت و تقسیم ثابت. مثلاً SVM دوباره دقیقاً همان 0.8846 را داد.

نتایج

سؤال: تفاوت‌ها معنادارند؟

آزمون آماری هنوز انجام نشده. قاعده‌ی من مقایسه‌ی تفاوت با انحراف معیار بین seedهاست. wce از این آستانه رد می‌شود؛ BiLSTM و attention نه.

سؤال: بهترین مدل کدام است؟

BERT + BiLSTM + Attention + wce: Macro-F1 برابر 0.914 ± 0.006 , accuracy 0.935, recall بحرانی 0.868.

سؤال: اگر attention کمک نکرد، چرا نگهش داشتی؟

اول، سؤال RQ1 پروپوزال است و جواب منفی هم جواب است. دوم، به‌اندازه‌ی بقیه‌ی مدل‌ها خوب است و وزن‌هایش تفسیرپذیری می‌دهد، که یافته‌ی SOLAS را آشکار کرد.

سؤال: چرا SVM اینقدر به BERT نزدیک است؟

گزارش‌ها کوتاه و فرمولی‌اند و واژه‌های کلیدی (smoke, aground, capsized) بار اصلی را می‌برند. برتری BERT بیشتر در کلاس‌های معنایی نزدیک و کمیاب است.

سؤال: سقف 0.91 از کجاست؟

تحلیل خطا: زنجیره‌ی علت ← پیامد، گزارش‌های چندرویدادی، و واژگان تخصصی. بیشترش ابهام برچسب است، نه ضعف مدل.

Oversampling

سؤال: فرق oversampling با wce؟

در امید ریاضی تقریباً یکی‌اند: یک گزارش Capsizing در هر epoch به‌طور میانگین 6.49 بار دیده می‌شود و وزن wce آن هم 6.49 است. تفاوت در تصادفی بودن و تکرار است.

سؤال: چرا روی SVM اثری نداشت؟

Capsizing تغییری نکرد (۱۰ از ۱۵)؛ پس احتمالاً خطاهای آن معنایی‌اند، نه کمبود نمونه. تکرار یک گزارش اطلاعات جدیدی به SVM نمی‌دهد؛ فقط وزن آن نقطه را بالا می‌برد.

سؤال: چرا SMOTE یا augmentation نه؟

پروپوزال بدون داده‌ی مصنوعی است. SMOTE نمونه‌ی مصنوعی در فضای بردار می‌سازد، و augmentation متنی خطر نویز برچسب و نشت داده دارد.

سؤال: چرا oversampling را با wce ترکیب نکردی؟

چون جبران دو برابر می‌شد: هم بیشتر دیده می‌شود و هم بیشتر جریمه دارد. مدل بیش از حد به سمت کلاس‌های کمیاب می‌رفت.

مقاله‌ی مرجع

سؤال: چرا عدد تو با مقاله فرق دارد؟

وظیفه‌ها فرق دارند: آن‌ها علت حادثه را با ۳۲ کلاس روی داده‌ی چین دسته‌بندی کرده‌اند و ما نوع رویداد را با ۹ کلاس روی MAIB. عددها مستقیماً قابل مقایسه نیستند. مقایسه‌ی معنادار، مقایسه‌ی ادعای آن‌هاست (برتری BiLSTM)، که با تنظیمات یکسان روی داده‌ی ما تأیید نشد.

سؤال: چرا تنظیمات مقاله را دقیقاً تکرار نکردی؟

epoch ۵ با $lr = 1e-6$ همگرا نمی‌شود. گزینه‌ی `--paper-settings` را در کد گذاشته‌ام ($lr = 1e-6$ ، epoch ۳۰) و با زمان GPU کافی اجراش می‌کنم.

سؤال‌های غافلگیرکننده

سؤال: اگر فردا یک گزارش جدید بیاید، مدل چطور استفاده می‌شود؟

متن به tokenizer داده می‌شود، مدل ۹ امتیاز می‌دهد و بیشترین امتیاز کلاس پیش‌بینی است. وزن‌های attention هم نشان می‌دهند مدل به کدام واژه‌ها نگاه کرده.

سؤال: چرا از ChatGPT یا LLM استفاده نکردی؟

پروپوزال روی مدل‌های رمزگذار (BERT) تعریف شده و مقاله‌ی مرجع هم همین است. مقایسه با LLM به‌صورت zero-shot در گام‌های بعدی است و برای انتشار هم لازم است.

سؤال: این مدل در دنیای واقعی کجا به درد می‌خورد؟

برچسب‌زنی اولیه‌ی خودکار برای کارشناس، جست‌وجو و آمارگیری روی آرشیو، و هشدار برای گزارش‌هایی که احتمال کلاس بحرانی دارند. recall کلاس‌های بحرانی برای همین گزارش می‌شود.

۱۷. جمله‌های ممنوع و جایگزین درست

نگو X	بگو ✓
«تفاوت معنادار است.»	«تفاوت بزرگ‌تر از نوسان بین seedهاست.»
«مدل ما از مقاله‌ی مرجع بهتر است.»	«وظیفه و داده فرق دارد. با تنظیمات یکسان، بهبود BiLSTM را روی این داده مشاهده نکردیم.»
«attention نشان می‌دهد مدل چرا تصمیم گرفت.»	«attention نشان می‌دهد مدل به کجا نگاه کرد؛ از آن برای کشف الگو استفاده کردم.»
«BiLSTM بی‌فایده است.»	«روی این داده و با تنظیمات یکسان، بهبودی بیش از نوسان نداد.»
«oversampling شکست خورد.»	«روی SVM اثری نداشت؛ این خودش یک یافته است.»
«مقاله‌ی مرجع اشتباه کرده.»	«در شرح روش مشخص نیست که تقسیم داده قبل از augmentation انجام شده باشد.»
«همه‌ی گزارش‌ها را دیدم.»	«نمونه‌های خطای بهترین مدل را بررسی کردم.»
عدد حدسی	«عدد دقیقش را در جدول دارم» یا «این را نیازموده‌ام.»

۱۸. نقشه‌ی کد

اگر استاد خواست کد را ببیند، این ترتیب را نشان بده: هر فایل یک گام پروپوزال است.

فایل	کار	گام پروپوزال
config.py	همه‌ی تنظیمات در یک جا	—
step1_prepare_data.py	بارگذاری، پاک‌سازی، تقسیم ۷۰/۱۵/۱۵	۱
step2_tfidf_svm.py	TF-IDF + SVM، با و بدون oversampling	۲-الف
models.py	سه مدل BERT و کلاس Attention	۲-ب، ۲-ج، ۳
losses.py	چهار تابع زیان	۴
step3_train.py	آموزش و ارزیابی یک پیکربندی (+ oversampling)	—
step4_run_experiments.py	اجرای کل جدول آزمایش‌ها؛ اجرای قطع‌شده را ادامه می‌دهد	۲ تا ۴
step5_report.py	جدول اصلی، recall هر کلاس، ماتریس درهم‌ریختگی، حکم نوسان	۵

فایل	کار	گام پروپوزال
step6_attention.py	واژه‌های پروزن و نمونه‌های رنگی attention	۵
common.py	خواندن داده و محاسبه‌ی معیارها	—

```
python step1_prepare_data.py
python step2_tfidf_svm.py
python step4_run_experiments.py --seeds 1 2
python step4_run_experiments.py --oversample --seeds 1 2
python step5_report.py
python step6_attention.py
```

۱۹. واژه‌نامه

اصطلاح	معنی ساده
fine-tuning	تنظیم کوچک وزن‌های یک مدل از قبل آموزش‌دیده برای کار جدید
epoch	یک بار دیدن کل داده‌ی آموزش
batch	تعداد گزارش‌هایی که با هم پردازش می‌شوند
learning rate	اندازه‌ی قدم تغییر وزن‌ها در هر به‌روزرسانی
loss (تابع زیان)	عددی که می‌گوید پیش‌بینی چقدر بد بود؛ آموزش آن را کم می‌کند
overfitting	حفظ کردن داده‌ی آموزش به‌جای یادگیری الگو
early stopping	توقف آموزش وقتی نتیجه‌ی val دیگر بهتر نمی‌شود
seed	عدد شروع تصادف؛ seed یکسان یعنی نتیجه‌ی یکسان
stratified split	تقسیم داده با حفظ نسبت کلاس‌ها در هر بخش
data leakage	رسیدن اطلاعات آزمون به آموزش؛ نمره را مصنوعی بالا می‌برد
token / word-piece	تکه‌ی واژه که BERT با آن کار می‌کند
[CLS]	توکن ویژه‌ی اول متن که بردارش خلاصه‌ی کل متن است
BiLSTM	شبکه‌ی بازگشتی که متن را از دو طرف می‌خواند
attention pooling	میانگین وزن‌دار بردار واژه‌ها با وزن‌های یادگرفته‌شده
softmax	تبدیل چند عدد به احتمال‌هایی که جمعشان ۱ است
recall	از نمونه‌های واقعی یک کلاس، چندتا پیدا شد
precision	از پیش‌بینی‌های یک کلاس، چندتا درست بود
Macro-F1	میانگین ساده‌ی F1 همه‌ی کلاس‌ها؛ کلاس کوچک و بزرگ وزن برابر
confusion matrix	جدولی که نشان می‌دهد هر کلاس با کدام کلاس اشتباه گرفته شده
oversampling	بیشتر نشان دادن نمونه‌های کلاس کمیاب در آموزش
SOLAS	کنوانسیون بین‌المللی ایمنی جان اشخاص در دریا

آخرین توصیه

- اول نتیجه را بگو، بعد جزئیات. استادها عدد و نتیجه را زودتر می‌خواهند.
- اگر سؤالی را نفهمیدی، بپرس «منظورتان X است یا Y؟». این ضعف نیست.
- اگر ایرادی گرفت که درست بود، بگو «نکته‌ی درستی است؛ این را به گام‌های بعدی اضافه می‌کنم» و یادداشتش کن.
- خوب بخواب. ذهن خسته از ذهن ناآماده بدتر است.