گزارش تکمیلی: افزایش داده با مدل زبانی و BiLSTM بزرگ‌تر

پیگیری درخواست‌های جلسه‌ی ۱۹ مهر ۱۴۰۵ · محمد مهدی عرب · ۲۱ مهر ۱۴۰۵

استاد راهنما: دکتر هدی مشایخی · استاد مشاور: دکتر مریم خدابخش

خلاصه

- **افزایش داده (Data Augmentation):** با یک مدل زبانی، ۱٬۰۶۸ گزارش آموزشی تازه برای رده‌های کم‌نمونه ساخته شد تا هر رده به ۴۰۰ گزارش آموزشی برسد.
- **روی SVM کمی کمک کرد:** Macro-F1 از 0.8846 به 0.8892 و بازیابی رده‌های بحرانی از 0.827 به 0.850 رسید.
- **روی مدل BERT بهبودی بیشتر از نوسان بین seedها نداد:** با ce از 0.905 به 0.009 ± 0.908 و با wce از 0.914 به 0.002 ± 0.915. یعنی به سطح wce رسید، نه بالاتر از آن.
- **نتیجه:** تابع زیان وزن‌دار (wce) همچنان بهترین و ساده‌ترین روش است. افزایش داده هزینه‌ی بیشتری دارد (حدود ۲٫۵ ساعت تولید و ۲۲٪ زمان آموزش بیشتر) و چیزی به wce اضافه نکرد.
- **BiLSTM بزرگ‌تر:** سه پیکربندی در حال اجراست و نتیجه پس از پایان اجرا فرستاده می‌شود.

۱. چرا افزایش داده؟

oversampling همان گزارش‌های کمیاب را تکرار می‌کند: مدل ۶۹ گزارش واژگونی را بارها می‌بیند، ولی چیز تازه‌ای یاد نمی‌گیرد. در افزایش داده، یک مدل زبانی هر گزارش واقعی را با واژه‌ها و ساختار جمله‌ی تازه بازنویسی می‌کند (paraphrasing). واقعیت‌های حادثه همان می‌ماند، پس برچسب هم همان است؛ اما متن تازه است.

۲. روش

بخش	انتخاب
مدل زبانی	Qwen2.5-1.5B-Instruct، اجرای محلی روی GPU لپ‌تاپ (GTX 1650 Ti، ۴ گیگابایت)
دستور (prompt)	گزارش را با واژه‌ها و ساختار تازه بازنویسی کن؛ نوع شناور، رخداد، علت، آسیب‌ها و خسارت را دقیقاً حفظ کن؛ واقعیت تازه اضافه نکن و نام رده را نیاور
تنظیم تولید	temperature 0.8، top_p 0.95، حداکثر ۲۵۶ توکن
داده‌ی ورودی	فقط گزارش‌های **آموزشی**؛ داده‌ی اعتبارسنجی و آزمون هرگز به مدل زبانی داده نشد
هدف	هر رده‌ی کمتر از ۴۰۰ گزارش آموزشی تا ۴۰۰ پر شد

هر بازنویسی فقط وقتی پذیرفته شد که از چهار صافی بگذرد:

۱. طولش بین نصف و دو برابر گزارش اصلی باشد.

۲. هم‌پوشانی واژه‌هایش با اصل (Jaccard) بین 0.15 و 0.8 باشد: نه رونوشت باشد و نه داستانی دیگر.

۳. تکراری نباشد.

۴. **بررسی برچسب:** یک TF-IDF + SVM که فقط روی گزارش‌های واقعی آموزشی دیده، باید بازنویسی را در همان رده‌ی گزارش اصلی بگذارد. این روش از LAMBADA گرفته شده است (Anaby-Tavor و همکاران، ۲۰۲۰). بازنویسی‌های ردشده کنار گذاشته و با بازنویسی تازه جایگزین شدند.

رده	گزارش واقعی	بازنویسی تولیدشده	پذیرفته در بررسی برچسب	نرخ پذیرش	مجموع آموزشی
واژگونی (Capsizing)	69	487	331	٪68	400
آب‌گرفتگی (Flooding)	131	408	269	٪66	400
آتش‌سوزی (Fire)	227	184	173	٪94	400
تصادم (Collision)	228	187	172	٪92	400
برخورد با جسم ثابت (Contact)	284	215	116	٪54	400
به گل نشستن (Grounding)	393	12	7	٪58	400
جمع		**1,493**	**1,068**	**٪71.5**	

داده‌ی آموزشی از ۴٬۰۳۳ به ۵٬۱۰۱ گزارش رسید. رده‌های آتش‌سوزی و تصادم واژه‌های شاخص دارند (fire، collided) و بازنویسی‌شان بیشتر پذیرفته شد. در Contact و Flooding مدل زبانی بیشتر نوع رخداد را با واژه‌هایی می‌گوید که به رده‌ی دیگری می‌خورد. بررسی برچسب سخت‌گیر است و گاهی بازنویسی درست را هم رد می‌کند؛ نمونه: یک گزارش Contact که بازنویسی‌اش «collided with a concrete quay wall» بود.

۳. نتایج

مجموعه‌ی آزمون: ۸۶۵ گزارش واقعی. مدل‌های BERT با ۲ seed اجرا شدند (میانگین ± انحراف معیار). SVM قطعی است و یک بار اجرا شد.

روش	Macro-F1	بازیابی رده‌های بحرانی	Accuracy
TF-IDF + SVM	0.885	0.827	0.914
با oversampling	0.885	0.834	0.917
با افزایش داده	**0.889**	**0.850**	0.916
BERT + BiLSTM + Attention با ce	0.905 ± 0.004	0.845 ± 0.016	0.931
با oversampling	0.909 ± 0.001	0.851 ± 0.008	0.931
با افزایش داده	0.908 ± 0.009	0.862 ± 0.008	0.932
BERT + BiLSTM + Attention با wce	0.914 ± 0.006	0.868 ± 0.016	0.935
با افزایش داده	**0.915 ± 0.002**	**0.868 ± 0.016**	0.935

رده‌های بحرانی: آتش‌سوزی، واژگونی و آب‌گرفتگی. قاعده‌ی مقایسه همان قاعده‌ی گزارش قبلی است: تفاوتی واقعی شمرده می‌شود که از بیشترین انحراف معیار دو طرف بزرگ‌تر باشد.

- **SVM:** Macro-F1 به اندازه‌ی 0.005 و بازیابی رده‌های بحرانی به اندازه‌ی 0.022 بالا رفت. در واژگونی ۱۱ گزارش از ۱۵ درست تشخیص داده شد (بدون افزایش داده: ۱۰). در تصادم و Contact هم هر کدام ۱ گزارش بیشتر. تک‌اجراست و برآورد نوسان ندارد.

- **BERT با ce:** 0.003 بهتر، در حد نوسان. دو seed نتیجه‌ی 0.902 و 0.914 دادند؛ پراکندگی زیاد است.
- **BERT با ce، افزایش داده در برابر oversampling:** 0.001 کمتر؛ عملاً برابر.
- **BERT با wce:** 0.001 بهتر، در حد نوسان. فقط پراکندگی بین seedها کمتر شد (0.002 به‌جای 0.006).
- **رده‌های پرتکرار آسیب ندیدند:** میانگین F1 چهار رده‌ی پرتکرار تقریباً ثابت ماند (با wce از 0.936 به 0.935).

تعداد گزارش‌های آزمونِ درست تشخیص داده‌شده در رده‌های افزوده‌شده (میانگین دو seed):

رده (تعداد در آزمون)	ce	ce با افزایش داده	wce	wce با افزایش داده
واژگونی (15)	10.5	11	11.5	11.5
آب‌گرفتگی (28)	24	24.5	24	24
آتش‌سوزی (48)	47	47	47	47
تصادم (49)	45.5	47.5	47	48.5
Contact (61)	52	52	51.5	51.5

تنها بهبود پایدار در رده‌ی تصادم است (۱٫۵ تا ۲ گزارش بیشتر). باقی تفاوت‌ها نیم‌گزارش یا کمتر است.

۴. تفسیر: چرا BERT سود نبرد؟

۱. **بازنویسی واژه‌ی تازه می‌آورد، نه واقعیت تازه.** SVM هر واژه را یک ویژگی جدا می‌بیند؛ مترادف تازه برایش ویژگی تازه است، پس کمک می‌کند. BERT از پیش‌آموزش می‌داند که capsized و overturned هم‌معنا هستند؛ برای BERT بازنویسی همان اطلاعات قبلی است. این با یافته‌ی Longpre و همکاران (۲۰۲۰) هم‌خوان است: افزایش داده‌ی عمومی، مانند بازنویسی و ترجمه‌ی رفت‌وبرگشتی، معمولاً به مدل‌های پیش‌آموزش‌دیده کمک چندانی نمی‌کند.

۲. **wce، oversampling و افزایش داده یک کار مشترک دارند:** سهم رده‌های کمیاب را در آموزش بالا می‌برند. وقتی wce این سهم را درست کرده باشد، نمونه‌ی بازنویسی‌شده چیز تازه‌ای اضافه نمی‌کند. برای همین wce + افزایش داده تقریباً برابر wce است.

۳. **مجموعه‌ی آزمون کوچک است:** ۱۵ گزارش واژگونی دارد، پس هر گزارش ۶٫۷ درصد بازیابی است. تفاوت‌های کمتر از حدود 0.01 در Macro-F1 با ۲ seed از نوسان جدا نمی‌شوند. گام بعدی، آزمون آماری (McNemar یا bootstrap جفتی) است.

هزینه: تولید بازنویسی‌ها حدود ۲٫۵ ساعت (یک بار). هر اجرای آموزش BERT ۹۲ دقیقه به‌جای ۷۵ دقیقه طول کشید (۲۲٪ بیشتر)، چون داده‌ی آموزشی بزرگ‌تر شد.

محدودیت‌ها:

- ۲۸٫۵٪ بازنویسی‌ها در بررسی برچسب رد شدند.
- بررسی دستی چند نمونه نشان داد که نوع رخداد حفظ می‌شود، اما جزئیات فرعی گاهی تغییر می‌کند؛ مثلاً lifeboat به liferaft یا escorted به towed.
- مدل زبانی بزرگ‌تر (۷ میلیارد پارامتر یا بیشتر) با GPU چهار گیگابایتی ممکن نبود.

۵. BiLSTM بزرگ‌تر (در حال اجرا)

خروجی BERT در هر توکن ۷۶۸ بعد دارد. BiLSTM فعلی در هر جهت ۱۲۸ واحد دارد، پس خروجی‌اش ۲۵۶ بعد است. سه پیکربندی بزرگ‌تر آزموده می‌شوند، همه با wce و ۲ seed:

پیکربندی	واحد در هر جهت	تعداد لایه	خروجی BiLSTM
فعلی	128	1	256
پهن‌تر (هم‌اندازه‌ی BERT)	384	1	768
عمیق‌تر	128	2	256
پهن‌تر و عمیق‌تر (هم‌اندازه‌ی BERT)	384	2	768

۶ اجرا، حدود ۸ ساعت. نتیجه پس از پایان اجرا فرستاده می‌شود.

۶. پرسش از استاد راهنما

۱. افزایش داده از wce بهتر نشد. آیا wce را روش نهایی مدیریت عدم توازن در مقاله در نظر بگیرم و افزایش داده را به‌عنوان یک آزمایش مقایسه‌ای گزارش کنم؟

۲. یا ادامه‌ی این مسیر را لازم می‌دانید؛ مثلاً مدل زبانی بزرگ‌تر، یا تولید گزارش تازه به‌جای بازنویسی گزارش‌های موجود؟

منابع

Anaby-Tavor, A., et al. (2020). Do Not Have Enough Data? Deep Learning to the Rescue! AAAI.

Longpre, S., Wang, Y., & DuBois, C. (2020). How Effective is Task-Agnostic Data Augmentation for Pretrained Transformers? Findings of EMNLP.

Qwen Team (2024). Qwen2.5 Technical Report. arXiv:2412.15115.

کد و همه‌ی نتایج: `maib-thesis/step7_augment.py` و پوشه‌ی `maib-thesis/results/`. نمونه‌های بازنویسی در کنار گزارش اصلی: `maib-thesis/reports/augmentation_examples.md`.