گزارش کامل نتایج پایان‌نامه

دسته‌بندی گزارش‌های حوادث دریایی با استفاده از مدل‌های زبانی

محمد مهدی عرب · دانشگاه صنعتی شاهرود · ۲۱ مهر ۱۴۰۵

استاد راهنما: دکتر هدی مشایخی · استاد مشاور: دکتر مریم خدابخش

خلاصه

- **همه‌ی مدل‌های BERT از خط مبنای کلاسیک (TF-IDF + SVM) بهترند:** Macro-F1 از 0.885 به 0.898 تا 0.915 می‌رسد.
- **تغییر معماری بهبودی بیشتر از نوسان بین seedها نداد:** افزودن BiLSTM، افزودن attention و بزرگ‌تر کردن BiLSTM (تا حدود ۸ برابر پارامتر) هیچ‌کدام بهبود قابل اتکا ندادند.
- **تابع زیان وزن‌دار (wce) مؤثرترین روش بود:** Macro-F1 از 0.905 به 0.914 و بازیابی رده‌های بحرانی از 0.845 به 0.868 رسید. این بهبود از نوسان بین seedها بزرگ‌تر است.
- **oversampling و افزایش داده با مدل زبانی (Data Augmentation)** روی BERT به سطح wce رسیدند، نه بالاتر. افزایش داده روی SVM کمی کمک کرد (0.885 به 0.889).
- **مدل پیشنهادی:** BERT + BiLSTM + Attention با wce؛ Macro-F1 برابر 0.914 ± 0.006 و Accuracy برابر 0.935.

۱. مسیر کار در یک نگاه

گام	کار انجام‌شده	گام پروپوزال
۱	آماده‌سازی داده‌ی عمومی MAIB: پاک‌سازی، ۹ رده، تقسیم ۷۰/۱۵/۱۵	گام ۱
۲	خط مبنای کلاسیک: TF-IDF + SVM	گام ۲
۳	بازتولید مقاله‌ی مرجع: BERT و BERT + BiLSTM با تنظیمات یکسان	گام ۲
۴	مدل پیشنهادی: BERT + BiLSTM + Attention	گام ۳
۵	مقابله با عدم توازن: سه تابع زیان (wce، focal، cb)	گام ۴
۶	تحلیل: recall هر رده، ماتریس درهم‌ریختگی، واژه‌های پروزن attention	گام ۵ و ۶
۷	درخواست جلسه‌ی قبل: oversampling	تکمیلی
۸	درخواست‌های جلسه‌ی ۱۹ مهر: افزایش داده با مدل زبانی و BiLSTM بزرگ‌تر	تکمیلی

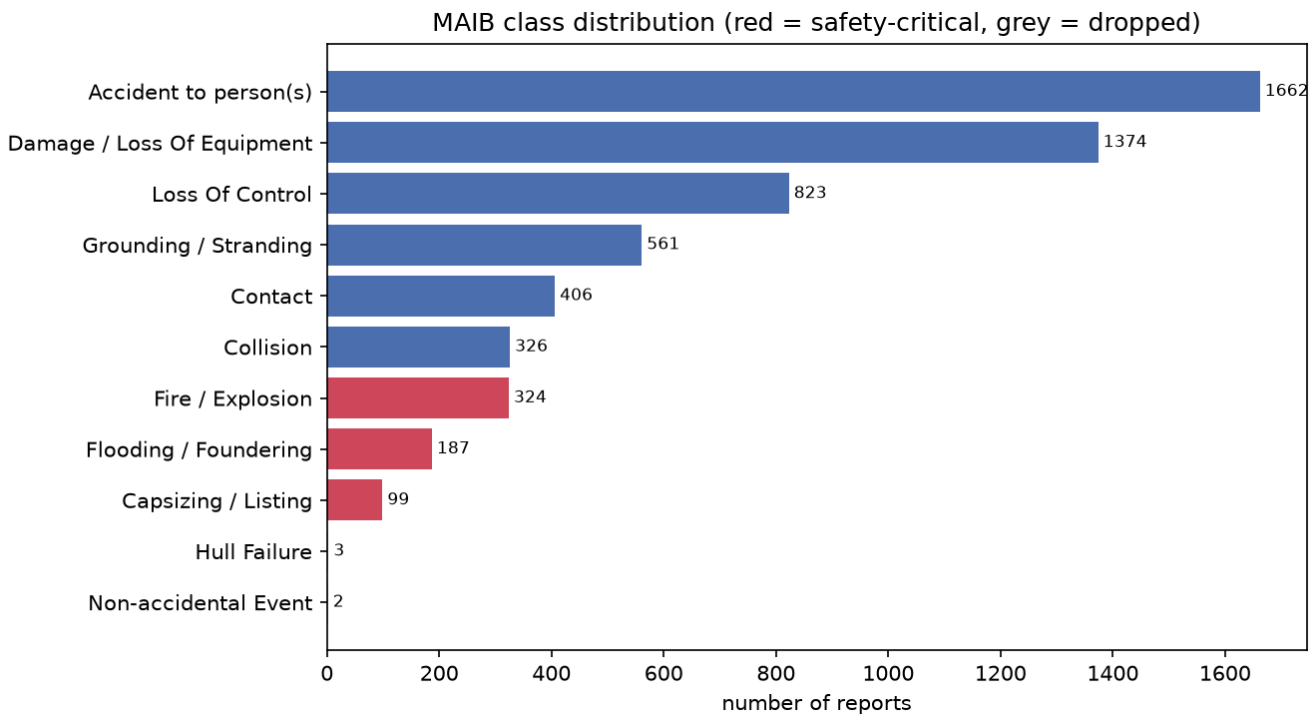
حجم کار: ۲۴ اجرای آموزش BERT (۱۲ پیکربندی × ۲ seed) و ۳ اجرای SVM؛ در مجموع حدود ۳۱ ساعت آموزش روی GPU لپ‌تاپ (GTX 1650 Ti) و ۲٫۵ ساعت تولید داده با مدل زبانی.

۲. داده

دادگان عمومی MAIB (اداره‌ی بررسی حوادث دریایی بریتانیا): ۵,۷۶۸ گزارش کوتاه انگلیسی. پس از حذف ۱ گزارش تکراری و دو رده‌ی بسیار کوچک (۳ و ۲ گزارش)، ۵,۷۶۲ گزارش در ۹ رده ماند. نسبت بزرگ‌ترین به کوچک‌ترین رده ۱۶٫۸ است. تقسیم داده طبقه‌بندی‌شده (stratified) و با seed ثابت ۴۲ انجام شد.

رده	کل	آموزش	آزمون
Accident to person(s)	1,662	1,163	250
Damage / Loss of Equipment	1,374	962	206
Loss of Control	823	576	124
Grounding / Stranding	561	393	84
Contact	406	284	61
Collision	326	228	49
Fire / Explosion	324	227	48
Flooding / Foundering	187	131	28
Capsizing / Listing	99	69	15
جمع	**5,762**	**4,033**	**865**

رده‌های پررنگ «بحرانی» هستند: کمیاب‌اند و بیشترین خطر جانی را دارند. ۸۶۴ گزارش باقی‌مانده برای اعتبارسنجی (انتخاب بهترین epoch) است.



شکل ۱. تعداد گزارش‌های هر رده. قرمز: رده‌های بحرانی. خاکستری: رده‌های حذف‌شده.

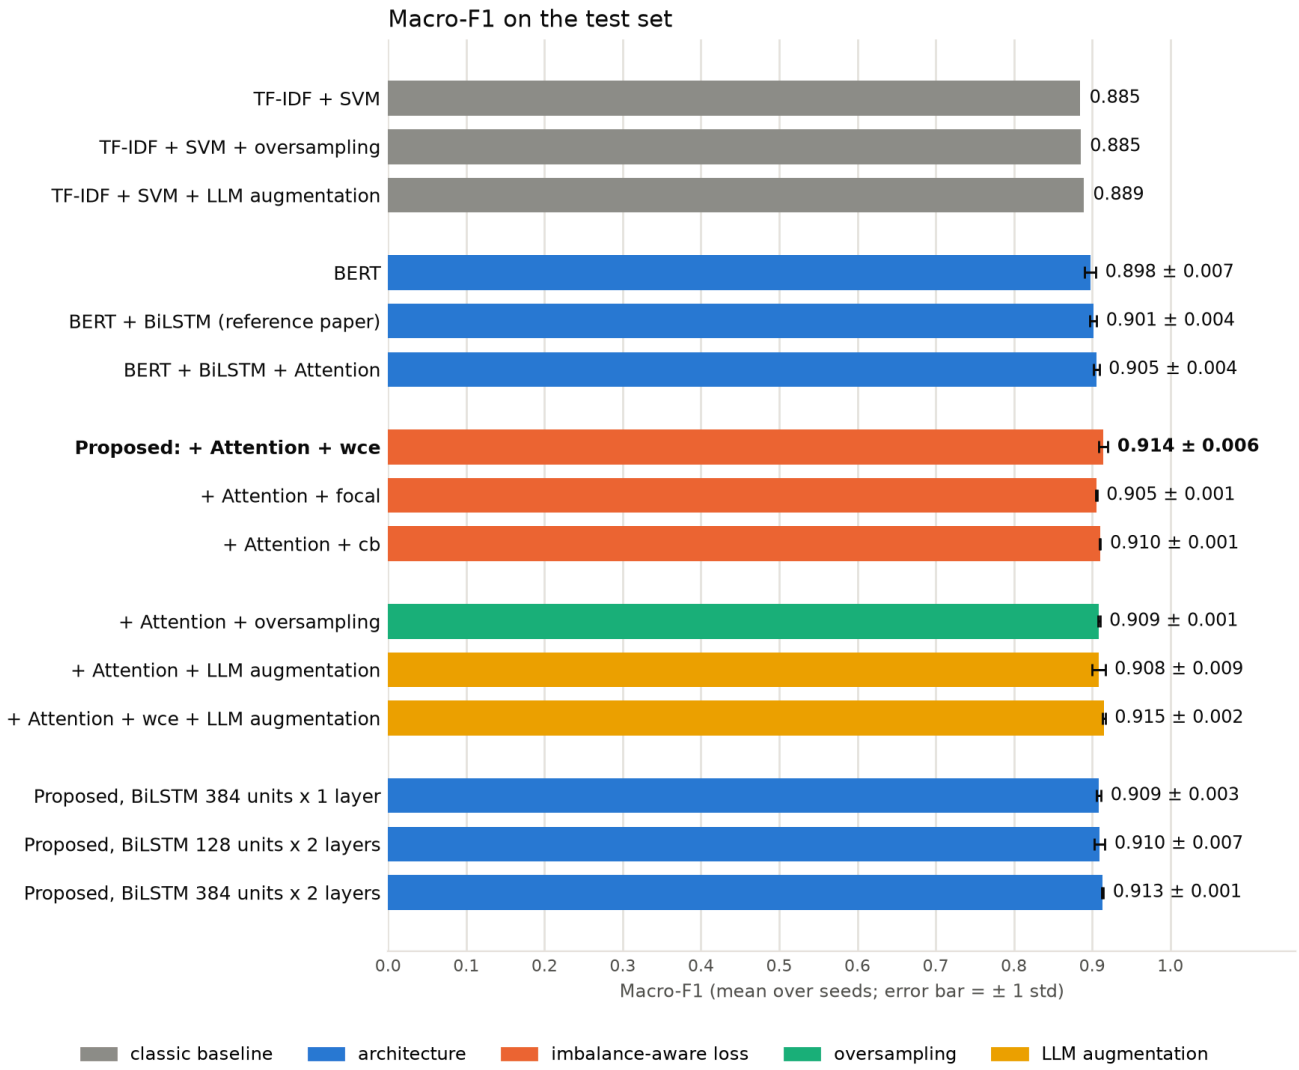
۳. روش ارزیابی

- **Macro-F1:** میانگین F1 همه‌ی ۹ رده با وزن برابر؛ رده‌ی کمیاب همان‌قدر مهم است که رده‌ی پرتکرار. معیار اصلی است.
- **بازیابی رده‌های بحرانی:** میانگین recall سه رده‌ی آتش‌سوزی، واژگونی و آب‌گرفتگی.
- **تکرار:** هر مدل BERT با ۲ seed آموزش دید؛ میانگین ± انحراف معیار گزارش می‌شود. SVM قطعی است و یک بار اجرا شد.
- **قاعده‌ی مقایسه:** تفاوتی واقعی شمرده می‌شود که از بیشترین انحراف معیار دو طرف بزرگ‌تر باشد. این آزمون آماری نیست؛ آزمون McNemar گام بعدی است.
- **تنظیمات یکسان:** همه‌ی مدل‌های BERT با یک دستور آموزش یکسان (bert-base-uncased، ۱۹۲ توکن، batch مؤثر ۳۲، حداکثر ۵ epoch، توقف زودهنگام) آموزش دیدند؛ هر دو پیکربندی پشت‌سرهم فقط در یک جزء تفاوت دارند.

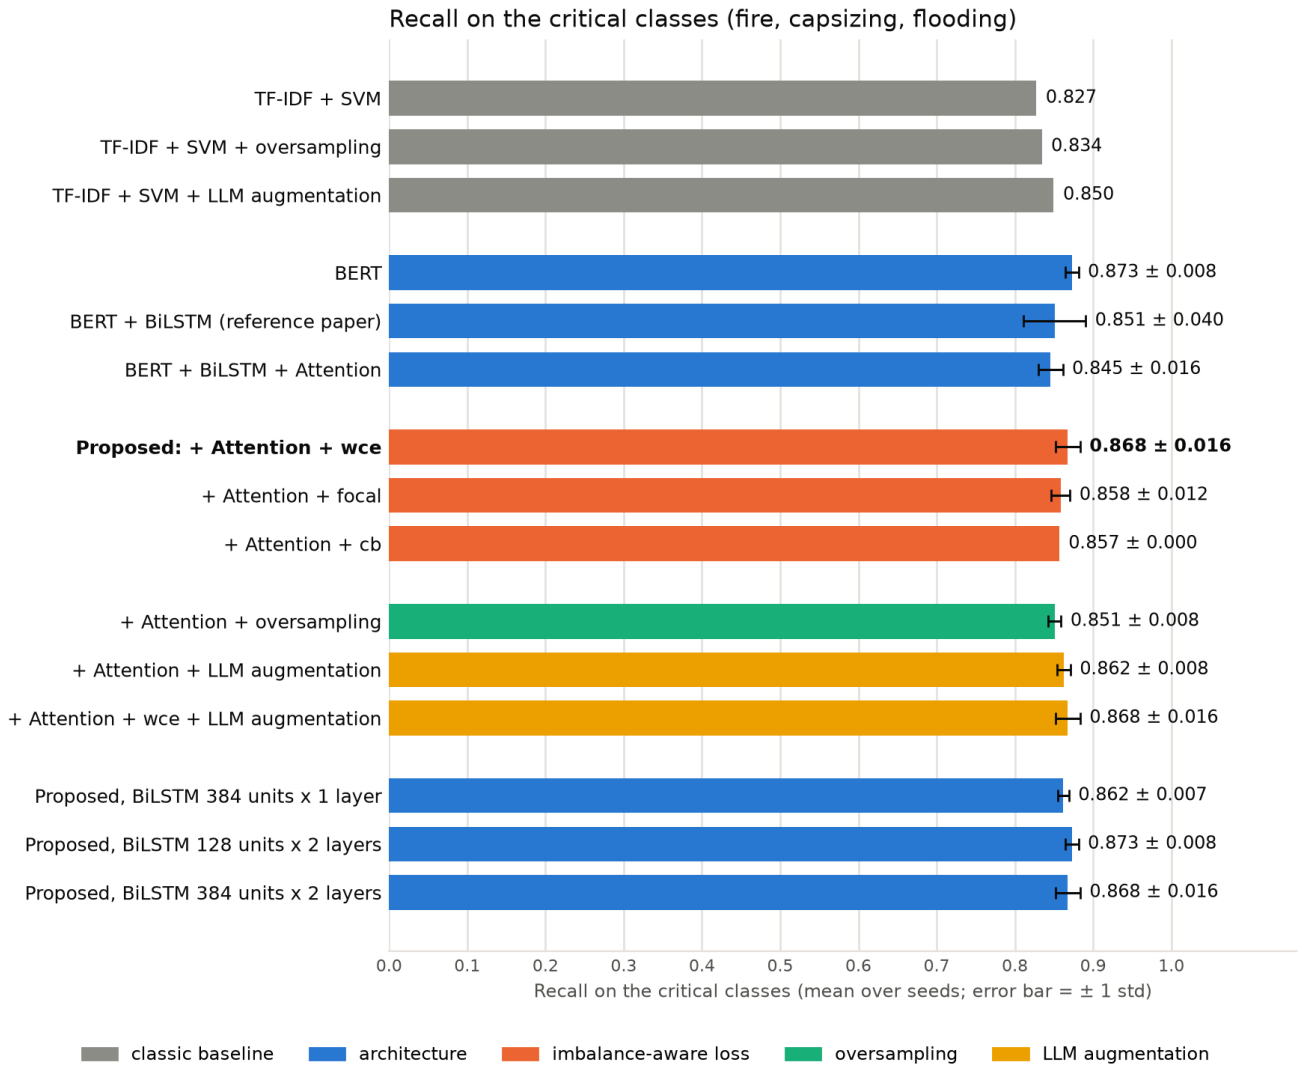
۴. جدول اصلی نتایج

مجموعه‌ی آزمون: ۸۶۵ گزارش واقعی.

پیکربندی	Macro-F1	بازیابی رده‌های بحرانی	Accuracy
TF-IDF + SVM	0.885	0.827	0.914
TF-IDF + SVM با oversampling	0.885	0.834	0.917
TF-IDF + SVM با افزایش داده	0.889	0.850	0.916
BERT	0.898 ± 0.007	0.873 ± 0.008	0.927
BERT + BiLSTM (مقاله‌ی مرجع)	0.901 ± 0.004	0.851 ± 0.040	0.928
BERT + BiLSTM + Attention با ce	0.905 ± 0.004	0.845 ± 0.016	0.931
BERT + BiLSTM + Attention با wce (پیشنهادی)	**0.914 ± 0.006**	**0.868 ± 0.016**	**0.935**
BERT + BiLSTM + Attention با focal	0.905 ± 0.001	0.858 ± 0.012	0.930
BERT + BiLSTM + Attention با cb	0.910 ± 0.001	0.857 ± 0.000	0.935
BERT + BiLSTM + Attention با oversampling	0.909 ± 0.001	0.851 ± 0.008	0.931
BERT + BiLSTM + Attention با افزایش داده (ce)	0.908 ± 0.009	0.862 ± 0.008	0.932
BERT + BiLSTM + Attention با افزایش داده (wce)	0.915 ± 0.002	0.868 ± 0.016	0.935
پیشنهادی با BiLSTM ۳۸۴ واحد، ۱ لایه	0.909 ± 0.003	0.862 ± 0.007	0.929
پیشنهادی با BiLSTM ۱۲۸ واحد، ۲ لایه	0.910 ± 0.007	0.873 ± 0.008	0.935
پیشنهادی با BiLSTM ۳۸۴ واحد، ۲ لایه	0.913 ± 0.001	0.868 ± 0.016	0.932



شکل ۲. Macro-F1 همه‌ی پیکربندی‌ها روی مجموعه‌ی آزمون. طول میله: میانگین دو seed؛ خط سیاه: ± یک انحراف معیار؛ رنگ: نوع تغییر. محور از صفر شروع می‌شود تا تفاوت‌های کوچک بزرگ‌تر از واقع دیده نشوند.



شکل ۳. بازیابی رده‌های بحرانی (آتش‌سوزی، واژگونی و آب‌گرفتگی) برای همه‌ی پیکربندی‌ها؛ نشانه‌گذاری مانند شکل ۲.

۵. پاسخ پرسش‌های پژوهش

پرسش ۱: آیا معماری پیچیده‌تر کمک می‌کند؟

مقایسه	تغییر Macro-F1	نوسان (انحراف معیار)	حکم
BERT در برابر SVM	0.013 بیشتر	0.007	**بزرگ‌تر از نوسان**
BERT + BiLSTM در برابر BERT	0.004 بیشتر	0.007	در حد نوسان
BERT + BiLSTM + Attention در برابر	0.004 بیشتر	0.004	در حد نوسان
BiLSTM ۱×۳۸۴ در برابر ۱×۱۲۸ (هر دو wce)	0.006 کمتر	0.006	در حد نوسان
BiLSTM ۲×۱۲۸ در برابر ۱×۱۲۸	0.005 کمتر	0.007	در حد نوسان
BiLSTM ۲×۳۸۴ در برابر ۱×۱۲۸	0.001 کمتر	0.006	در حد نوسان

پرسش ۲: کدام روش مقابله با عدم توازن کمک می‌کند؟

همه نسبت به BERT + BiLSTM + Attention با ce:

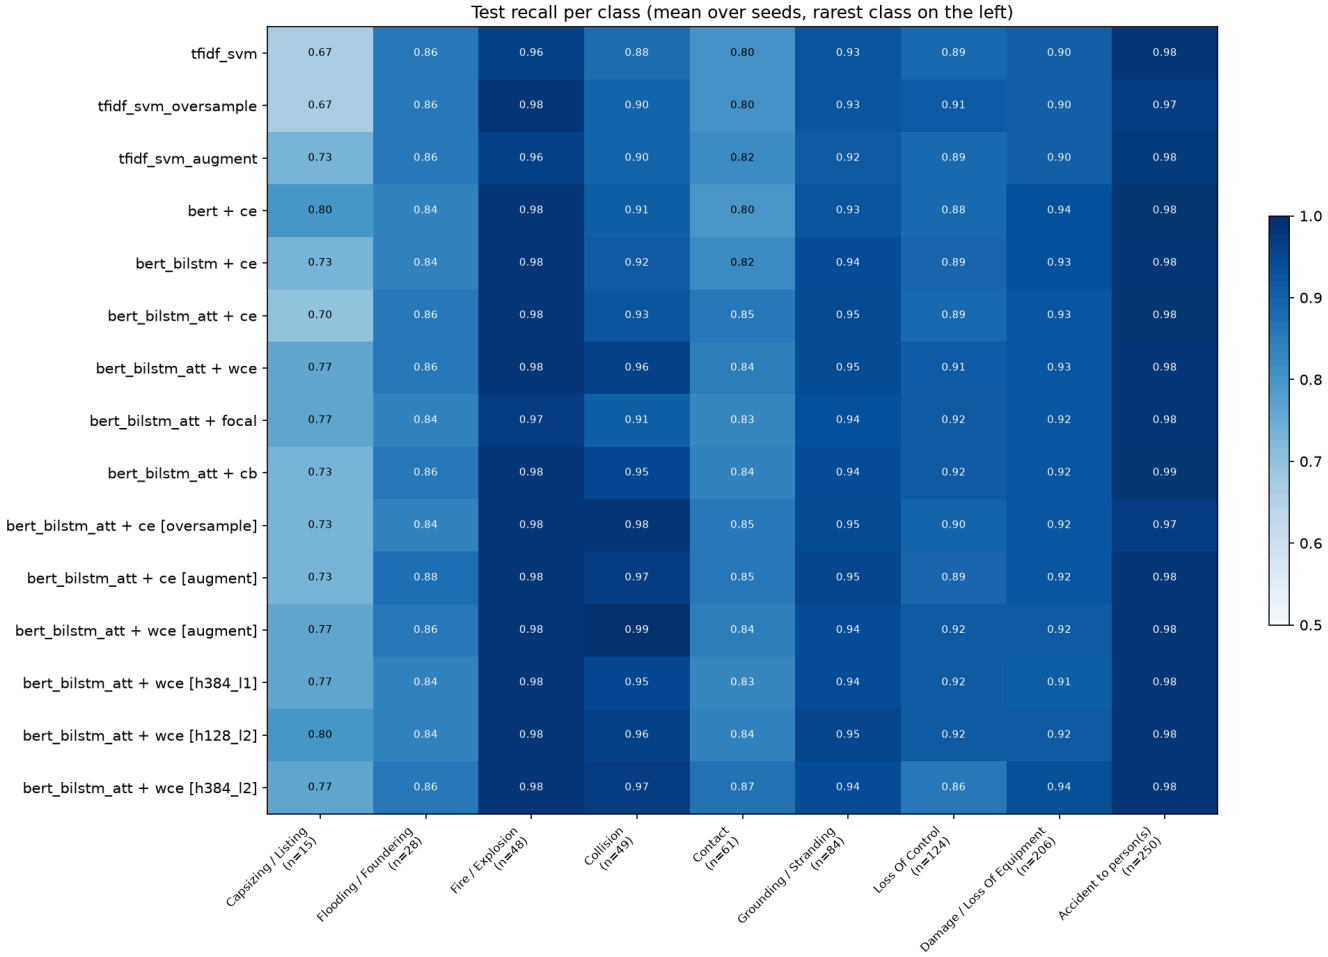
روش	تغییر Macro-F1	تغییر بازیابی بحرانی	حکم
wce	**0.009 بیشتر**	**0.022 بیشتر**	**بزرگ‌تر از نوسان**
cb	0.005 بیشتر	0.011 بیشتر	کمی بزرگ‌تر از نوسان
focal	بدون تغییر	0.013 بیشتر	در حد نوسان
oversampling	0.003 بیشتر	0.005 بیشتر	در حد نوسان
افزایش داده	0.003 بیشتر	0.017 بیشتر	در حد نوسان
wce + افزایش داده (نسبت به wce)	0.001 بیشتر	بدون تغییر	در حد نوسان

۶. نتایج هر رده

تعداد گزارش‌های آزمونِ درست تشخیص داده‌شده (میانگین دو seed)؛ کمیاب‌ترین رده بالاست:

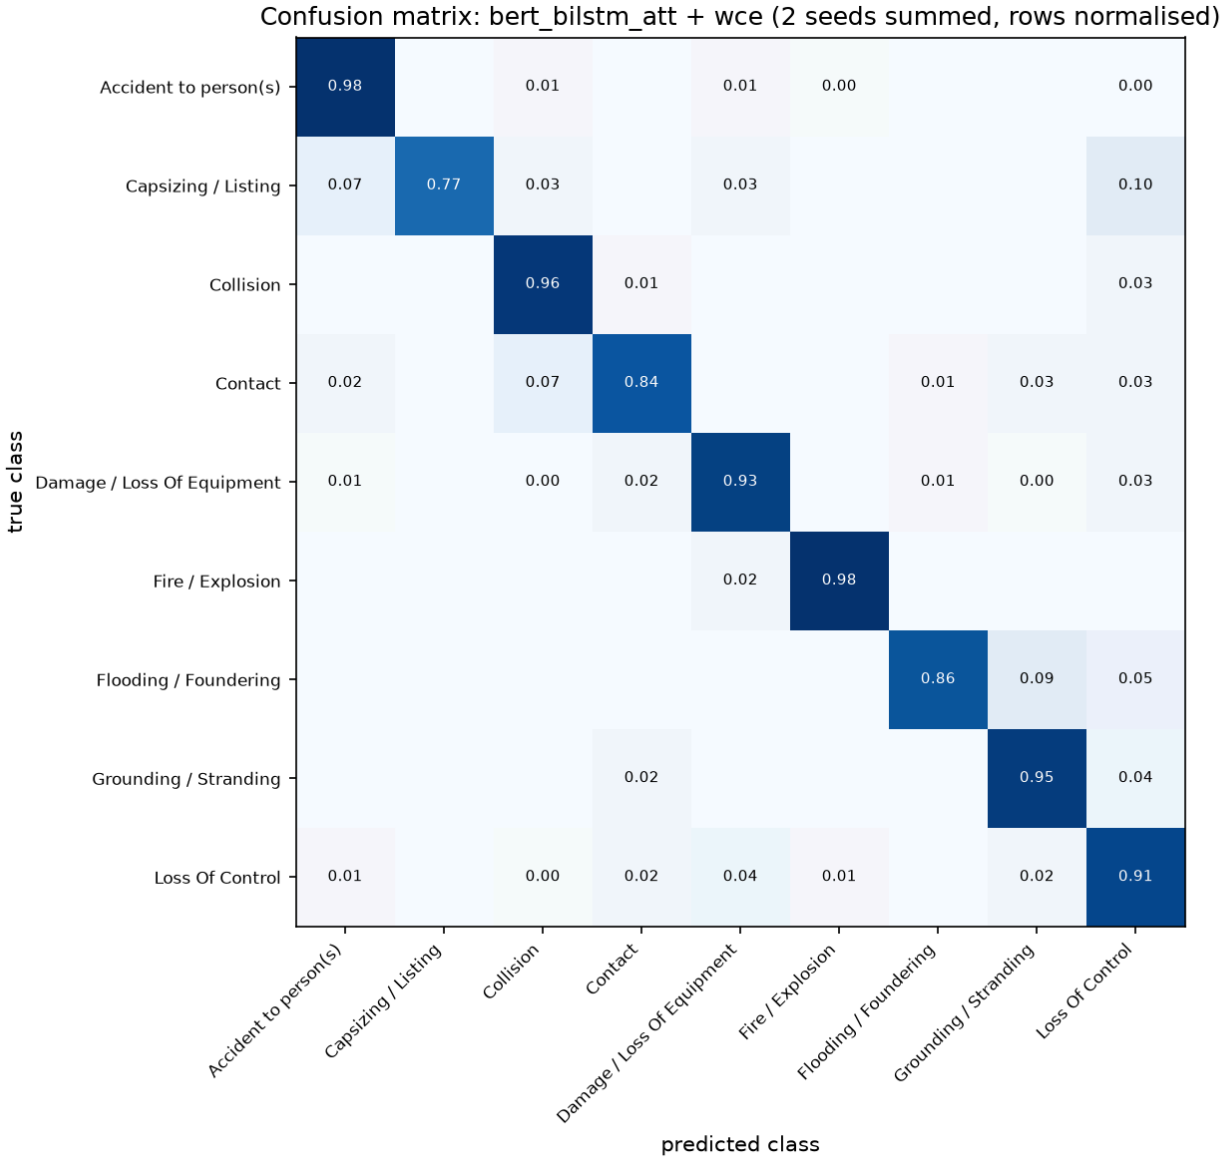
رده (تعداد در آزمون)	SVM	BERT	+ BiLSTM	+ Attention	+ Attention + wce
Capsizing (15)	10	12	11	10.5	11.5
Flooding (28)	24	23.5	23.5	24	24
Fire (48)	46	47	47	47	47
Collision (49)	43	44.5	45	45.5	47
Contact (61)	49	48.5	50	52	51.5
Grounding (84)	78	78	79	79.5	79.5
Loss of Control (124)	110	109.5	110.5	110	113
Damage (206)	186	193	192	191	191
Accident (250)	245	246	244.5	246	244.5

wce با ۳٫۵ گزارش درست بیشتر در مجموع، خطا را از پرتکرارترین رده (Accident، ۱٫۵ گزارش کمتر) به رده‌های کوچک‌تر (Capsizing، Collision و Loss of Control) جابه‌جا کرد. با ۱۵ گزارش واژگونی در آزمون، هر گزارش ۶٫۷ درصد recall است؛ پس تفاوت‌های ۱ تا ۲ گزارشی میان مدل‌های BERT قابل اتکا نیست.



شکل ۴. recall هر رده برای همه‌ی پیکربندی‌ها (میانگین seedها؛ کمیاب‌ترین رده در چپ).

۷. ماتریس درهم‌ریختگی و تحلیل خطا



شکل ۵. ماتریس درهم‌ریختگی مدل پیشنهادی (BERT + BiLSTM + Attention با wce)، جمع دو seed. هر سطر نرمال شده است، پس قطر اصلی همان recall است.

مدل پیشنهادی در مجموع دو seed، ۱۱۲ اشتباه از ۱٬۷۳۰ پیش‌بینی داشت. پرتکرارترین اشتباه‌ها:

ردهٔ واقعی	پیش‌بینی مدل	تعداد
Damage / Loss of Equipment	Loss of Control	13
Loss of Control	Damage / Loss of Equipment	9
Contact	Collision	8
Damage / Loss of Equipment	Contact	7
Grounding	Loss of Control	6
Flooding	Grounding	5

بیشتر اشتباه‌ها میان رده‌هایی است که **علت و پیامد** یک رخداد را نام می‌برند. نمونه: «خرابی پیشرانه، سپس به گل نشستن» برچسب Grounding دارد، اما می‌تواند Loss of Control هم باشد. یعنی بخشی از خطا از **تک‌برچسبی بودن** گزارش‌های چندرویدادی می‌آید، نه از ضعف مدل.

واژه‌های پروزن attention (بیشترین مجموع وزن در گزارش‌های آزمونی که درست دسته‌بندی شدند):

رده	واژه‌ها
Accident	fell، sustained، passenger، injury، fractured
Capsizing	capsized
Collision	collided، manoeuvring، tanker، moored
Contact	contact، quayside، struck، lock
Damage	solas، ladder، pilot، conform، regulations
Fire	engine، caught، smoke، extinguish
Flooding	ingress، water، taking
Grounding	grounded، ran، aground، sandbank
Loss of Control	failure، engine، fouled، propulsion، propeller

یافته‌ی جالب: در رده‌ی Damage، attention بیشتر روی واژه‌های **نردبان راهنما (pilot ladder) و مقررات SOLAS** است. یعنی بخش بزرگی از این رده، گزارش‌های نردبان راهنمای غیراستاندارد است.

۸. افزایش داده با مدل زبانی (درخواست جلسه‌ی ۱۹ مهر)

oversampling همان گزارش‌های کمیاب را تکرار می‌کند و اطلاعات تازه‌ای نمی‌دهد. در افزایش داده، یک مدل زبانی هر گزارش آموزشی واقعی را با واژه‌ها و ساختار جمله‌ی تازه بازنویسی می‌کند. واقعیت‌های حادثه، و در نتیجه برچسب، همان می‌ماند.

بخش	انتخاب
مدل زبانی	Qwen2.5-1.5B-Instruct، اجرای محلی روی GPU لپ‌تاپ
دستور (prompt)	گزارش را با واژه‌ها و ساختار تازه بازنویسی کن؛ نوع شناور، رخداد، علت، آسیب‌ها و خسارت را دقیقاً حفظ کن؛ واقعیت تازه اضافه نکن و نام رده را نیاور
داده‌ی ورودی	فقط گزارش‌های **آموزشی**؛ داده‌ی اعتبارسنجی و آزمون هرگز به مدل زبانی داده نشد
هدف	هر رده‌ی کمتر از ۴۰۰ گزارش آموزشی تا ۴۰۰ پر شد
صافی‌ها	طول بین نصف و دو برابر اصل؛ هم‌پوشانی واژه‌ها بین 0.15 و 0.8؛ حذف تکراری‌ها
بررسی برچسب	یک TF-IDF + SVM آموزش‌دیده فقط روی داده‌ی واقعی باید بازنویسی را در رده‌ی اصلش بگذارد (مانند LAMBADA)؛ ردشده‌ها با بازنویسی تازه جایگزین شدند

رده	واقعی	تولیدشده	پذیرفته	نرخ پذیرش	مجموع آموزشی
Capsizing	69	487	331	٪68	400
Flooding	131	408	269	٪66	400
Fire	227	184	173	٪94	400

رده	واقعی	تولیدشده	پذیرفته	نرخ پذیرش	مجموع آموزشی
Collision	228	187	172	٪92	400
Contact	284	215	116	٪54	400
Grounding	393	12	7	٪58	400
جمع		**1,493**	**1,068**	**٪71.5**	

داده‌ی آموزشی از ۴٬۰۳۳ به ۵٬۱۰۱ گزارش رسید.

نتیجه:

مدل	Macro-F1 بدون افزایش داده	Macro-F1 با افزایش داده	بازیابی بحرانی بدون افزایش داده	بازیابی بحرانی با افزایش داده	حکم
TF-IDF + SVM	0.885	0.889	0.827	0.850	بهبود کوچک (تک‌اجرا)
پیشنهادی با ce	0.905	0.908	0.845	0.862	در حد نوسان
پیشنهادی با wce	0.914	0.915	0.868	0.868	در حد نوسان

با ce، افزایش داده و oversampling عملاً برابرند (0.908 در برابر 0.909).

رده (تعداد در آزمون)	ce	ce با افزایش داده	wce	wce با افزایش داده
Capsizing (15)	10.5	11	11.5	11.5
Flooding (28)	24	24.5	24	24
Fire (48)	47	47	47	47
Collision (49)	45.5	47.5	47	48.5
Contact (61)	52	52	51.5	51.5

چرا روی BERT کمک نکرد؟ بازنویسی **واژه‌ی تازه** می‌آورد، نه **واقعیت تازه**. SVM هر واژه را ویژگی جدا می‌بیند، پس مترادف تازه برایش ویژگی تازه است و کمک می‌کند. BERT از پیش‌آموزش می‌داند که capsized و overturned هم‌معنا هستند؛ برای BERT بازنویسی همان اطلاعات قبلی است. این با یافته‌ی Longpre و همکاران (۲۰۲۰) هم‌خوان است. هزینه: ۲٫۵ ساعت تولید و ۲۲٪ زمان آموزش بیشتر (۹۲ به‌جای ۷۵ دقیقه برای هر اجرا).

محدودیت: بررسی دستی نشان داد که نوع رخداد حفظ می‌شود، اما جزئیات فرعی گاهی تغییر می‌کند (مثلاً lifeboat به liferaft). بررسی برچسب سخت‌گیر است و گاهی بازنویسی درست را هم رد می‌کند.

۹. BiLSTM بزرگ‌تر (درخواست جلسه‌ی ۱۹ مهر)

خروجی BERT برای هر توکن ۷۶۸ بعد دارد. BiLSTM پیش‌فرض در هر جهت ۱۲۸ واحد و خروجی ۲۵۶ بعدی دارد. سه پیکربندی بزرگ‌تر با wce و ۲ seed آزموده شد:

BiLSTM	پارامترهای BiLSTM	Macro-F1	بازیابی بحرانی	Accuracy	زمان هر اجرا
۱۲۸ واحد، ۱ لایه (پیش‌فرض)	0.92M	**0.914 ± 0.006**	0.868 ± 0.016	0.935	۷۶ دقیقه
۳۸۴ واحد، ۱ لایه (هم‌اندازه‌ی BERT)	3.5M	0.909 ± 0.003	0.862 ± 0.007	0.929	۷۵ دقیقه
۱۲۸ واحد، ۲ لایه	1.3M	0.910 ± 0.007	0.873 ± 0.008	0.935	۶۷ دقیقه
۳۸۴ واحد، ۲ لایه	7.1M	0.913 ± 0.001	0.868 ± 0.016	0.932	۷۶ دقیقه

هیچ‌کدام از پیش‌فرض بهتر نشد؛ همه‌ی تفاوت‌ها در حد نوسان است.

چرا؟

۱. BERT با ۱۱۰ میلیون پارامتر و ۱۲ لایه‌ی self-attention کار اصلی را انجام می‌دهد. BiLSTM فقط خروجی آن را دوباره می‌خواند؛ حتی بزرگ‌ترینش (۷ میلیون پارامتر) اطلاعات تازه‌ای به آن اضافه نمی‌کند.

۲. لازم نیست خروجی BiLSTM هم‌اندازه‌ی BERT باشد: ورودی BiLSTM در همه‌ی حالت‌ها همان ۷۶۸ بعد است. اندازه‌ی BiLSTM فقط اندازه‌ی خلاصه‌ای است که برای ۹ رده ساخته می‌شود، و ۲۵۶ عدد برای این کار کافی است.

۳. نشانه‌ی حفظ کردن داده: در seed اول، با ۳۸۴ واحد خطای آموزش کمتر شد (0.064 در برابر 0.081)، اما Macro-F1 اعتبارسنجی همان ماند (0.915). ظرفیت اضافه صرف حفظ کردن داده‌ی آموزش شد، نه یادگیری بهتر.

این نتیجه یافته‌ی پرسش ۱ را تقویت می‌کند: **گلوگاه این مسئله معماری نیست.**

۱۰. جمع‌بندی

۱. **مدل پیشنهادی:** BERT + BiLSTM + Attention با wce؛ Macro-F1 برابر 0.914 و بازیابی رده‌های بحرانی 0.868.

۲. **تابع زیان مهم‌تر از معماری است:** wce با تغییر یک خط کد، بیشتر از هر لایه‌ی اضافه کمک کرد.

۳. **روش‌های بر پایه‌ی داده** (oversampling و افزایش داده) به سطح wce رسیدند، نه بالاتر، و هزینه‌ی بیشتری دارند.

۴. **سقف حدود 0.91** بیشتر از ابهام برچسب گزارش‌های چندرویدادی می‌آید تا از کمبود ظرفیت مدل.

۵. **attention** برای تفسیرپذیری ارزش دارد (یافته‌ی SOLAS و نردبان راهنما)، نه برای دقت.

محدودیت‌ها: فقط ۲ seed و بدون آزمون آماری؛ مجموعه‌ی آزمون کوچک برای رده‌های کمیاب (۱۵ گزارش واژگونی)؛ یک تقسیم داده؛ فقط BERT پایه؛ مدل زبانی کوچک (۱٫۵ میلیارد پارامتر) به دلیل GPU چهار گیگابایتی.

۱۱. پرسش‌ها از استاد راهنما

۱. آیا wce را روش نهایی مقابله با عدم توازن در نظر بگیرم و oversampling و افزایش داده را به‌عنوان آزمایش‌های مقایسه‌ای در مقاله گزارش کنم؟

۲. برای محکم‌تر شدن نتایج، کدام را در اولویت بگذارم: seed سوم برای مقایسه‌های اصلی، یا آزمون آماری McNemar روی همین اجراها؟

۳. برای مقاله، کدام نشریه یا کنفرانس را مناسب می‌دانید؟

منابع

Anaby-Tavor, A., et al. (2020). Do Not Have Enough Data? Deep Learning to the Rescue! AAAI.

Cui, Y., et al. (2019). Class-Balanced Loss Based on Effective Number of Samples. CVPR.

Devlin, J., et al. (2019). BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. NAACL.

Lin, T.-Y., et al. (2017). Focal Loss for Dense Object Detection. ICCV.

Longpre, S., Wang, Y., & DuBois, C. (2020). How Effective is Task-Agnostic Data Augmentation for Pretrained Transformers? Findings of EMNLP.

Qwen Team (2024). Qwen2.5 Technical Report. arXiv:2412.15115.

Zhao, Z., Liu, X., Feng, L., Grifoll, M., & Feng, H. (2025). Causation Analysis of Marine Traffic Accidents Using Deep Learning Approaches: A Case Study from China's Coasts. Systems, 13(4), 284.

Zhou, P., et al. (2016). Attention-Based Bidirectional Long Short-Term Memory Networks for Relation Classification. ACL.

کد و همه‌ی نتایج: پوشه‌ی `maib-thesis/` در مخزن پروژه.