نتایج آزمایش‌های پایان‌نامه

دسته‌بندی گزارش‌های حوادث دریایی با استفاده از مدل‌های زبانی

محمد مهدی عرب · ۲۱ مهر ۱۴۰۵

استاد راهنما: دکتر هدی مشایخی · استاد مشاور: دکتر مریم خدابخش

خلاصه‌ی نتایج

۱. **بهترین پیکربندی:** BERT + BiLSTM + Attention با تابع زیان وزن‌دار (wce) و افزایش داده با مدل زبانی؛ Macro-F1 برابر **0.002 ± 0.915** (بیشترین مقدار در همه‌ی آزمایش‌ها)، بازیابی رده‌های بحرانی 0.868 و Accuracy برابر 0.935.

۲. بیشترین سهم این بهبود از wce است: Macro-F1 از 0.905 (ce) به 0.914 (wce) رسید. افزودن افزایش داده به wce مقدار 0.001 دیگر افزود که در حد نوسان بین seedهاست، و پراکندگی بین دو اجرا را از 0.006 به 0.002 کاهش داد.

۳. همه‌ی مدل‌های مبتنی بر BERT از خط مبنای TF-IDF + SVM بهترند (Macro-F1 برابر 0.898 تا 0.915 در برابر 0.885). افزایش داده روی SVM هم بهبود کوچکی داد (0.885 به 0.889).

۴. افزودن BiLSTM و attention به BERT، و بزرگ‌تر کردن BiLSTM، بهبودی بیشتر از نوسان نداد. بیشترین بازیابی رده‌های بحرانی (0.873) را BERT ساده و BiLSTM دولایه داشتند؛ تفاوت آن با بهترین پیکربندی (0.868) در حد نوسان است.

۵. بیشتر خطاهای باقی‌مانده میان رده‌هایی است که علت و پیامد یک رخداد را نام می‌برند.

۱. تنظیمات آزمایش

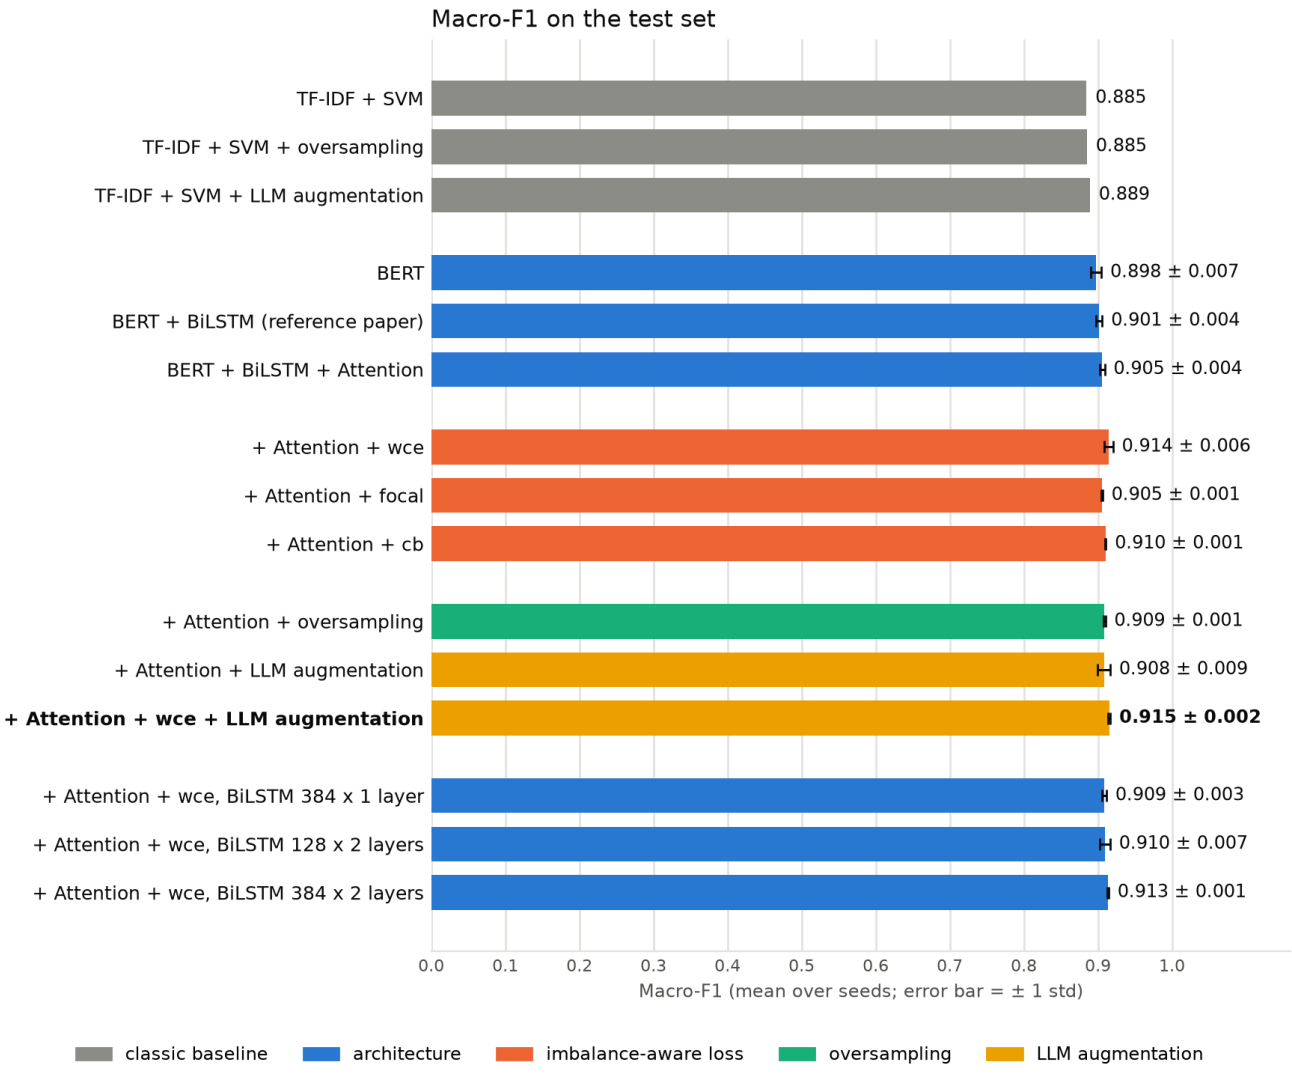
- **داده:** دادگان عمومی MAIB؛ ۵٬۷۶۲ گزارش در ۹ رده؛ نسبت بزرگ‌ترین به کوچک‌ترین رده ۱۶٫۸. تقسیم طبقه‌بندی‌شده‌ی ۷۰/۱۵/۱۵: ۴٬۰۳۳ آموزش، ۸۶۴ اعتبارسنجی، ۸۶۵ آزمون.
- **معیارها:** Macro-F1 (معیار اصلی)؛ بازیابی رده‌های بحرانی، یعنی میانگین recall سه رده‌ی آتش‌سوزی، واژگونی و آب‌گرفتگی؛ Accuracy.
- **مدل‌های BERT:** bert-base-uncased با تنظیمات آموزش یکسان (۱۹۲ توکن، batch مؤثر ۳۲، حداکثر ۵ epoch، انتخاب بهترین epoch با Macro-F1 اعتبارسنجی). هر پیکربندی با ۲ seed آموزش دید و میانگین ± انحراف معیار گزارش شده است. SVM قطعی است و یک بار اجرا شد.
- **قاعده‌ی مقایسه:** تفاوتی که از بیشترین انحراف معیار دو طرف بزرگ‌تر باشد «بزرگ‌تر از نوسان» شمرده شده است. آزمون آماری هنوز انجام نشده است.
- **حجم:** ۲۴ اجرای BERT (۱۲ پیکربندی × ۲ seed) و ۳ اجرای SVM.

۲. نتایج اصلی

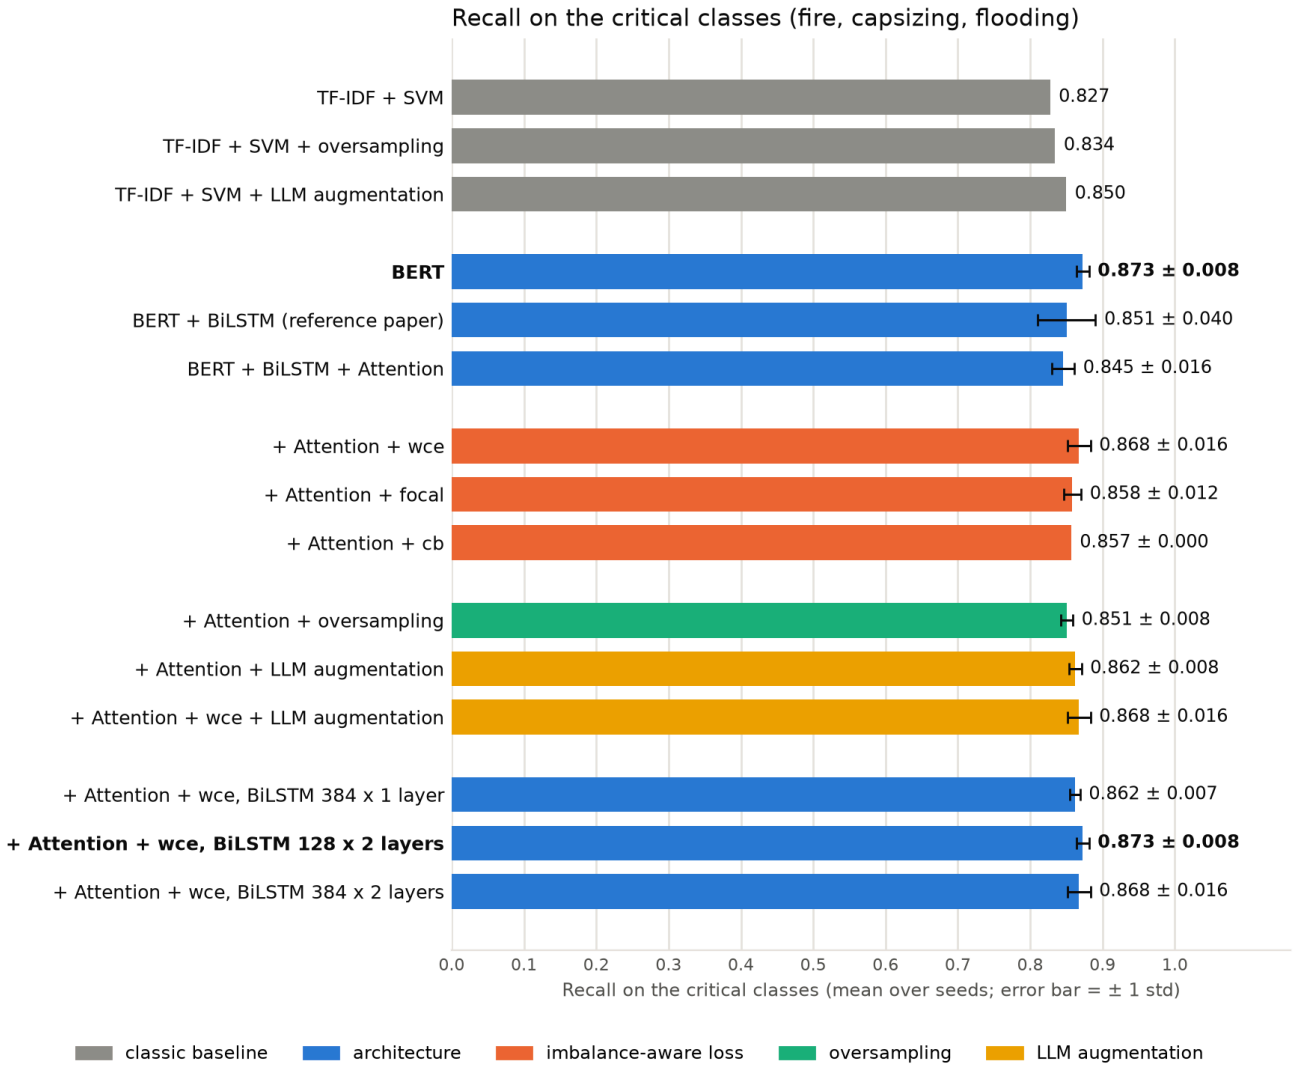
جدول ۱. نتایج همه‌ی پیکربندی‌ها روی مجموعه‌ی آزمون (۸۶۵ گزارش). عدد پررنگ: بیشترین مقدار هر ستون.

پیکربندی	Macro-F1	بازیابی رده‌های بحرانی	Accuracy
TF-IDF + SVM	0.885	0.827	0.914

پیکربندی	Macro-F1	بازیابی رده‌های بحرانی	Accuracy
TF-IDF + SVM با oversampling	0.885	0.834	0.917
TF-IDF + SVM با افزایش داده	0.889	0.850	0.916
BERT	0.898 ± 0.007	**0.873 ± 0.008**	0.927
BERT + BiLSTM (مقاله‌ی مرجع)	0.901 ± 0.004	0.851 ± 0.040	0.928
BERT + BiLSTM + Attention با ce	0.905 ± 0.004	0.845 ± 0.016	0.931
BERT + BiLSTM + Attention با wce	0.914 ± 0.006	0.868 ± 0.016	**0.935**
BERT + BiLSTM + Attention با focal	0.905 ± 0.001	0.858 ± 0.012	0.930
BERT + BiLSTM + Attention با cb	0.910 ± 0.001	0.857 ± 0.000	**0.935**
BERT + BiLSTM + Attention با oversampling	0.909 ± 0.001	0.851 ± 0.008	0.931
BERT + BiLSTM + Attention با افزایش داده (ce)	0.908 ± 0.009	0.862 ± 0.008	0.932
BERT + BiLSTM + Attention با wce و افزایش داده (بهترین)	**0.915 ± 0.002**	0.868 ± 0.016	**0.935**
Attention با wce، BiLSTM ۳۸۴ واحد، ۱ لایه	0.909 ± 0.003	0.862 ± 0.007	0.929
Attention با wce، BiLSTM ۱۲۸ واحد، ۲ لایه	0.910 ± 0.007	**0.873 ± 0.008**	**0.935**
Attention با wce، BiLSTM ۳۸۴ واحد، ۲ لایه	0.913 ± 0.001	0.868 ± 0.016	0.932



شکل ۱. Macro-F1 همه‌ی پیکربندی‌ها. طول میله: میانگین دو seed؛ خط سیاه: ± یک انحراف معیار؛ رنگ: نوع تغییر؛ پررنگ: بیشترین مقدار.



شکل ۲. بازیابی رده‌های بحرانی (آتش‌سوزی، واژگونی و آب‌گرفتگی)؛ نشانه‌گذاری مانند شکل ۱.

۳. مقایسه‌ها

جدول ۲. تفاوت هر پیکربندی با پیکربندی پایه‌ی آن.

مقایسه	تغییر Macro-F1	تغییر بازیابی بحرانی	حکم
معماری			
BERT در برابر TF-IDF + SVM	+0.013	+0.045	**بزرگ‌تر از نوسان**
BERT + BiLSTM در برابر BERT	+0.004	-0.022	در حد نوسان
BERT + BiLSTM + Attention در برابر	+0.004	-0.005	در حد نوسان
BiLSTM ۱×۳۸۴ در برابر ۱×۱۲۸ (هر دو wce)	-0.006	-0.006	در حد نوسان
BiLSTM ۲×۱۲۸ در برابر ۱×۱۲۸	-0.005	+0.005	در حد نوسان
BiLSTM ۲×۳۸۴ در برابر ۱×۱۲۸	-0.001	0.000	در حد نوسان

مقایسه	تغییر Macro-F1	تغییر بازیابی بحرانی	حکم
عدم توازن (نسبت به Attention با ce)			
wce	+0.009	+0.022	**بزرگ‌تر از نوسان**
cb	+0.005	+0.011	کمی بزرگ‌تر از نوسان
focal	0.000	+0.013	در حد نوسان
oversampling	+0.003	+0.005	در حد نوسان
افزایش داده	+0.003	+0.017	در حد نوسان
wce با افزایش داده	+0.010	+0.022	**بزرگ‌تر از نوسان**
wce با افزایش داده، نسبت به wce	+0.001	0.000	در حد نوسان
SVM (نسبت به SVM)			
oversampling	+0.001	+0.007	تک‌اجرا
افزایش داده	+0.005	+0.022	تک‌اجرا

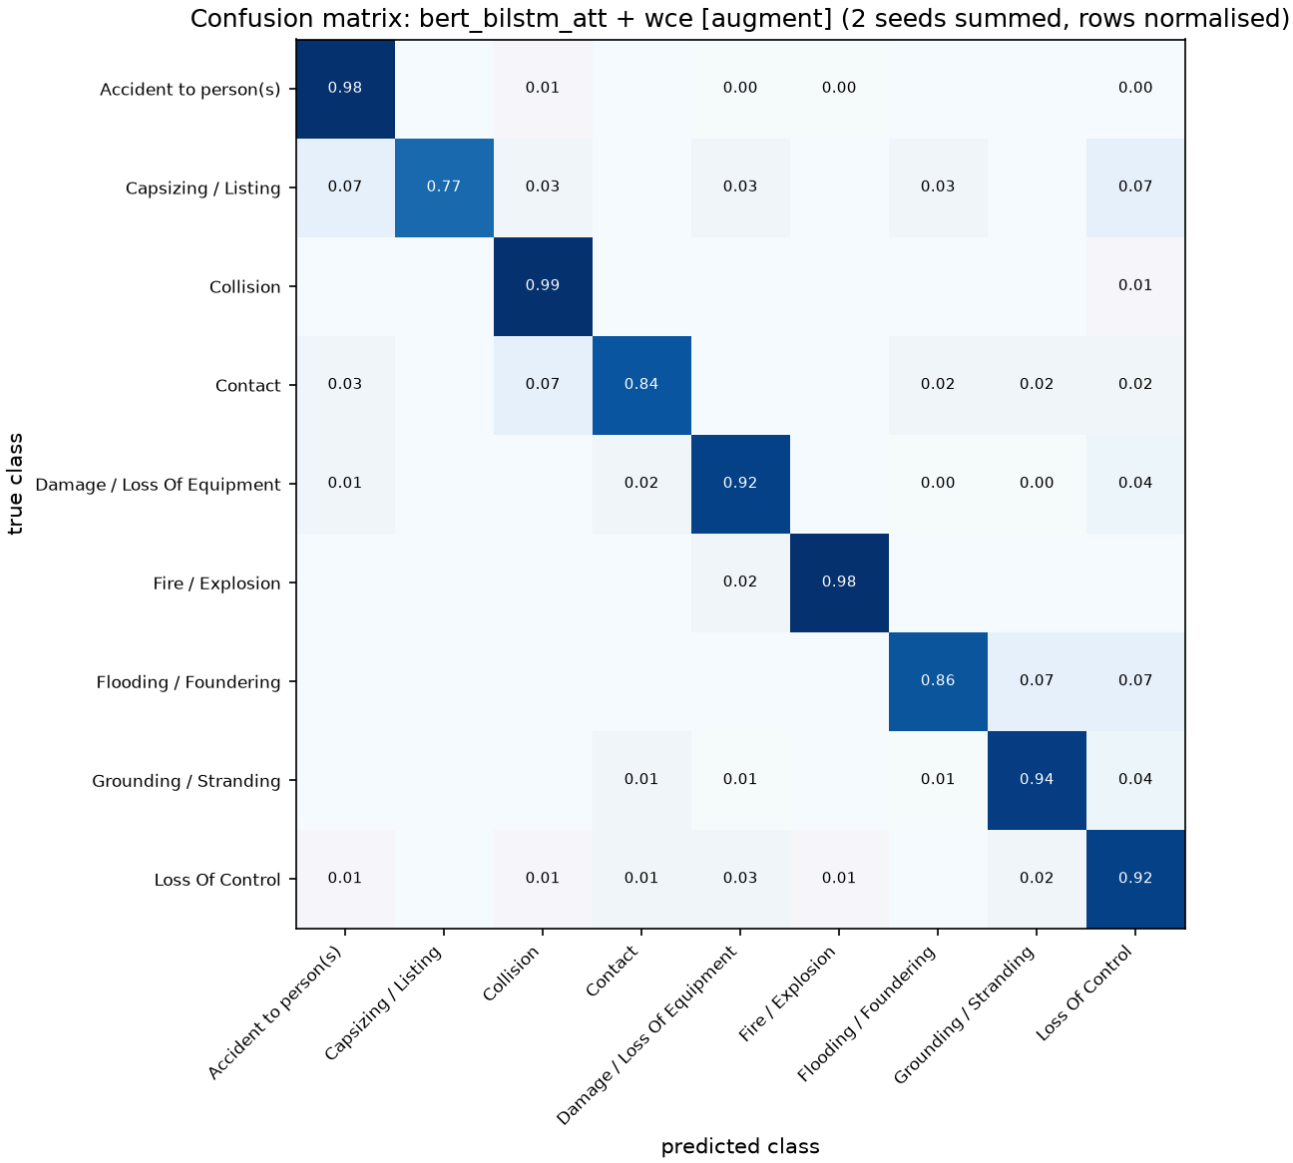
۴. نتایج هر رده

جدول ۳. تعداد گزارش‌های آزمونِ درست تشخیص داده‌شده (میانگین دو seed)؛ کمیاب‌ترین رده بالاست.

رده (تعداد در آزمون)	SVM	BERT	+ BiLSTM	+ Attention	+ wce	+ wce + افزایش داده (بهترین)
Capsizing / Listing (15)	10	12	11	10.5	11.5	11.5
Flooding / Foundering (28)	24	23.5	23.5	24	24	24
Fire / Explosion (48)	46	47	47	47	47	47
Collision (49)	43	44.5	45	45.5	47	48.5
Contact (61)	49	48.5	50	52	51.5	51.5
Grounding / Stranding (84)	78	78	79	79.5	79.5	79
Loss of Control (124)	110	109.5	110.5	110	113	113.5
Damage / Loss of Equipment (206)	186	193	192	191	191	189
Accident to person(s) (250)	245	246	244.5	246	244.5	245
جمع درست (865)	791	802	802.5	805.5	809	809

wce نسبت به ce در مجموع ۳٫۵ گزارش درست بیشتر داشت: ۱٫۵ گزارش کمتر در پرتکرارترین رده (Accident) و در عوض گزارش‌های بیشتر در Capsizing، Collision و Loss of Control. افزودن افزایش داده به wce تعداد کل درست‌ها را تغییر نداد (۸۰۹ در هر دو)؛ در Collision ۱٫۵ گزارش بیشتر و در Damage ۲ گزارش کمتر درست تشخیص داده شد. با ۱۵ گزارش واژگونی در آزمون، هر گزارش ۶٫۷ درصد recall است؛ پس تفاوت‌های ۱ تا ۲ گزارشی میان مدل‌های BERT قابل اتکا نیست.

۵. تحلیل خطا



شکل ۳. ماتریس درهم‌ریختگی بهترین پیکربندی (BERT + BiLSTM + Attention با wce و افزایش داده)، جمع دو seed. سطرها نرمال شده‌اند، پس قطر اصلی همان recall است.

جدول ۴. پرتکرارترین اشتباه‌های بهترین پیکربندی (جمع دو seed؛ ۱۱۲ اشتباه از ۱٬۷۳۰ پیش‌بینی). ستون آخر همان عدد را برای wce بدون افزایش داده نشان می‌دهد.

رده‌ی واقعی	پیش‌بینی مدل	تعداد	wce بدون افزایش داده
Damage / Loss of Equipment	Loss of Control	17	13
Damage / Loss of Equipment	Contact	8	7
Contact	Collision	8	8
Loss of Control	Damage / Loss of Equipment	7	9
Grounding / Stranding	Loss of Control	6	6
Loss of Control	Grounding / Stranding	5	4

بیشتر اشتباه‌ها میان رده‌هایی است که علت و پیامد یک رخداد را نام می‌برند؛ مثلاً «خرابی پیشرانه و سپس به گل نشستن» برچسب Grounding دارد ولی با Loss of Control هم سازگار است.

جدول ۵. واژه‌های با بیشترین وزن attention در مدل BERT + BiLSTM + Attention با wce (seed 1)؛ مجموع وزن در گزارش‌های آزمونی که درست دسته‌بندی شدند).

رده	واژه‌ها
Accident	fell، sustained، passenger، injury، fractured
Capsizing	capsized
Collision	collided، manoeuvring، tanker، moored
Contact	contact، quayside، struck، lock
Damage	solas، ladder، pilot، conform، regulations
Fire	engine، caught، smoke، extinguish
Flooding	ingress، water، taking
Grounding	grounded، ran، aground، sandbank
Loss of Control	failure، engine، fouled، propulsion، propeller

در رده‌ی Damage، بیشترین وزن روی واژه‌های نردبان راهنما (pilot ladder) و مقررات SOLAS است؛ بخش بزرگی از این رده گزارش‌های نردبان راهنمای غیراستاندارد است.

۶. افزایش داده با مدل زبانی (درخواست جلسه‌ی ۱۹ مهر)

روش: مدل زبانی Qwen2.5-1.5B-Instruct (اجرای محلی) گزارش‌های **آموزشی** رده‌های کم‌نمونه را با واژه‌ها و ساختار تازه بازنویسی کرد، با حفظ همه‌ی واقعیت‌ها و بدون نام بردن رده. هر رده تا ۴۰۰ گزارش آموزشی پر شد. داده‌ی اعتبارسنجی و آزمون به مدل زبانی داده نشد. هر بازنویسی باید از صافی طول، هم‌پوشانی واژه‌ها (0.15 تا 0.8) و تکراری نبودن می‌گذشت. همچنین یک TF-IDF + SVM آموزش‌دیده روی داده‌ی واقعی باید آن را در رده‌ی گزارش اصلی می‌گذاشت (بررسی برچسب، مانند LAMBADA).

جدول ۶. تعداد بازنویسی‌ها.

رده	واقعی	تولیدشده	پذیرفته	نرخ پذیرش	مجموع آموزشی
Capsizing	69	487	331	٪68	400
Flooding	131	408	269	٪66	400
Fire	227	184	173	٪94	400
Collision	228	187	172	٪92	400
Contact	284	215	116	٪54	400
Grounding	393	12	7	٪58	400
جمع		**1,493**	**1,068**	**٪71.5**	

داده‌ی آموزشی از ۴٬۰۳۳ به ۵٬۱۰۱ گزارش رسید.

نتیجه: روی SVM، Macro-F1 از 0.885 به 0.889 و بازیابی رده‌های بحرانی از 0.827 به 0.850 رسید. روی BERT با ce، از 0.905 به 0.908 رسید (در حد نوسان)؛ در این حالت افزایش داده و oversampling عملاً برابرند (0.908 و 0.909). ترکیب wce و افزایش داده **بیشترین Macro-F1 همه‌ی آزمایش‌ها (0.002 ± 0.915)** را داد؛ برتری آن بر wce تنها ± 0.914) (0.006 برابر 0.001 و در حد نوسان است، اما پراکندگی بین دو اجرا کمتر است.

تفسیر: بازنویسی واژه‌ی تازه می‌آورد، نه اطلاعات تازه. SVM مترادف تازه را ویژگی تازه می‌بیند و از آن سود بیشتری می‌برد؛ BERT از پیش‌آموزش با مترادف‌ها آشناست، پس سودش کمتر است. این با یافته‌ی Longpre و همکاران (۲۰۲۰) درباره‌ی اثر کم افزایش داده‌ی عمومی بر مدل‌های پیش‌آموزش‌دیده هم‌خوان است. هزینه: ۲٫۵ ساعت تولید و ۲۲٪ زمان آموزش بیشتر. بررسی دستی نمونه‌ها نشان داد نوع رخداد حفظ می‌شود، اما جزئیات فرعی گاهی تغییر می‌کند (مثلاً lifeboat به liferaft).

۷. اندازه‌ی BiLSTM (درخواست جلسه‌ی ۱۹ مهر)

جدول ۷. BERT + BiLSTM + Attention با wce (بدون افزایش داده)، با BiLSTM در اندازه‌های مختلف.

BiLSTM	پارامترهای BiLSTM	Macro-F1	بازیابی بحرانی	Accuracy
۱۲۸ واحد، ۱ لایه (پیش‌فرض)	0.92M	**0.914 ± 0.006**	0.868 ± 0.016	0.935
۳۸۴ واحد، ۱ لایه	3.5M	0.909 ± 0.003	0.862 ± 0.007	0.929
۱۲۸ واحد، ۲ لایه	1.3M	0.910 ± 0.007	0.873 ± 0.008	0.935
۳۸۴ واحد، ۲ لایه	7.1M	0.913 ± 0.001	0.868 ± 0.016	0.932

هیچ‌کدام از پیش‌فرض بهتر نشد. BERT (حدود ۱۱۰ میلیون پارامتر) نمایش اصلی را می‌سازد و BiLSTM بزرگ‌تر اطلاعات تازه‌ای به آن اضافه نمی‌کند. در seed اول، با ۳۸۴ واحد خطای آموزش کمتر شد (0.064 در برابر 0.081) ولی Macro-F1 اعتبارسنجی تغییری نکرد (0.915)؛ یعنی ظرفیت اضافه صرف برازش بیشتر داده‌ی آموزش شد.

۸. جمع‌بندی و گام‌های بعدی

- **بهترین پیکربندی:** BERT + BiLSTM + Attention با wce و افزایش داده با مدل زبانی؛ Macro-F1 برابر 0.002 ± 0.915، بازیابی رده‌های بحرانی 0.868 و Accuracy برابر 0.935.
- **یافته‌ی اصلی:** در این مسئله، مقابله با عدم توازن مهم‌تر از معماری است. بیشترین سهم بهبود از wce است (+0.009)؛ افزایش داده روی آن 0.001 دیگر افزود و اجراها را پایدارتر کرد. تغییرات معماری بهبودی بیشتر از نوسان ندادند.
- **محدودیت‌ها:** ۲ seed و بدون آزمون آماری؛ تعداد کم گزارش‌های آزمون در رده‌های کمیاب (۱۵ گزارش واژگونی)؛ یک تقسیم داده؛ مدل زبانی کوچک به دلیل GPU چهار گیگابایتی.
- **گام‌های بعدی پیشنهادی:** آزمون McNemar برای مقایسه‌های اصلی؛ seed سوم برای پیکربندی‌های اصلی؛ شروع نگارش مقاله.

موارد نیازمند نظر شما:

۱. پیکربندی نهایی مقاله wce با افزایش داده باشد (بیشترین Macro-F1)، یا wce تنها (نتیجه‌ی تقریباً برابر با هزینه‌ی کمتر و بدون نیاز به مدل زبانی)؟

۲. اولویت با کدام است: seed سوم یا آزمون آماری روی اجراهای موجود؟

منابع

Anaby-Tavor, A., et al. (2020). Do Not Have Enough Data? Deep Learning to the Rescue! AAAI.

Longpre, S., Wang, Y., & DuBois, C. (2020). How Effective is Task-Agnostic Data Augmentation for Pretrained Transformers? Findings of EMNLP.

Qwen Team (2024). Qwen2.5 Technical Report. arXiv:2412.15115.

Zhao, Z., Liu, X., Feng, L., Grifoll, M., & Feng, H. (2025). Causation Analysis of Marine Traffic Accidents Using Deep Learning Approaches: A Case Study from China's Coasts. Systems, 13(4), 284.