گزارش پیشرفت پایان‌نامه‌ی کارشناسی ارشد

طبقه‌بندی گزارش‌های حوادث دریایی با مدل‌های زبانی مبتنی بر ترنسفورمر

Classification of Marine Incident Reports Using Transformer-Based Language Models

دانشجو: محمدمهدی عرب
استاد راهنما: دکتر هدی مشایخی
استاد مشاور: دکتر مریم خدابخش

دانشکده‌ی مهندسی کامپیوتر · دانشگاه صنعتی شاهرود · آبان ۱۴۰۵

نتیجه در یک نگاه

0.915

Macro-F1 مدل برتر

BERT + BiLSTM + Att + wce + LLM augmentation

+0.031

برتری معنادار بر TF-IDF + SVM

آزمون بوت‌استرپ جفتی: p = 0.005

wce

منبع اصلی بهبود

BiLSTM و attention نسبت به BERT ساده بهبود معنادار ندارند

پیام اصلی: مدل‌های مبتنی بر BERT از روش کلاسیک بهترند، و برای کلاس‌های نادر، تابع زیان وزن‌دار از معماری پیچیده‌تر مهم‌تر است.

کلاس‌های حیاتی، نادرترین کلاس‌ها هستند

کدگذاری دستی

کدگذاری گزارش‌ها هنوز دستی، کند و وابسته به کدگذار است.

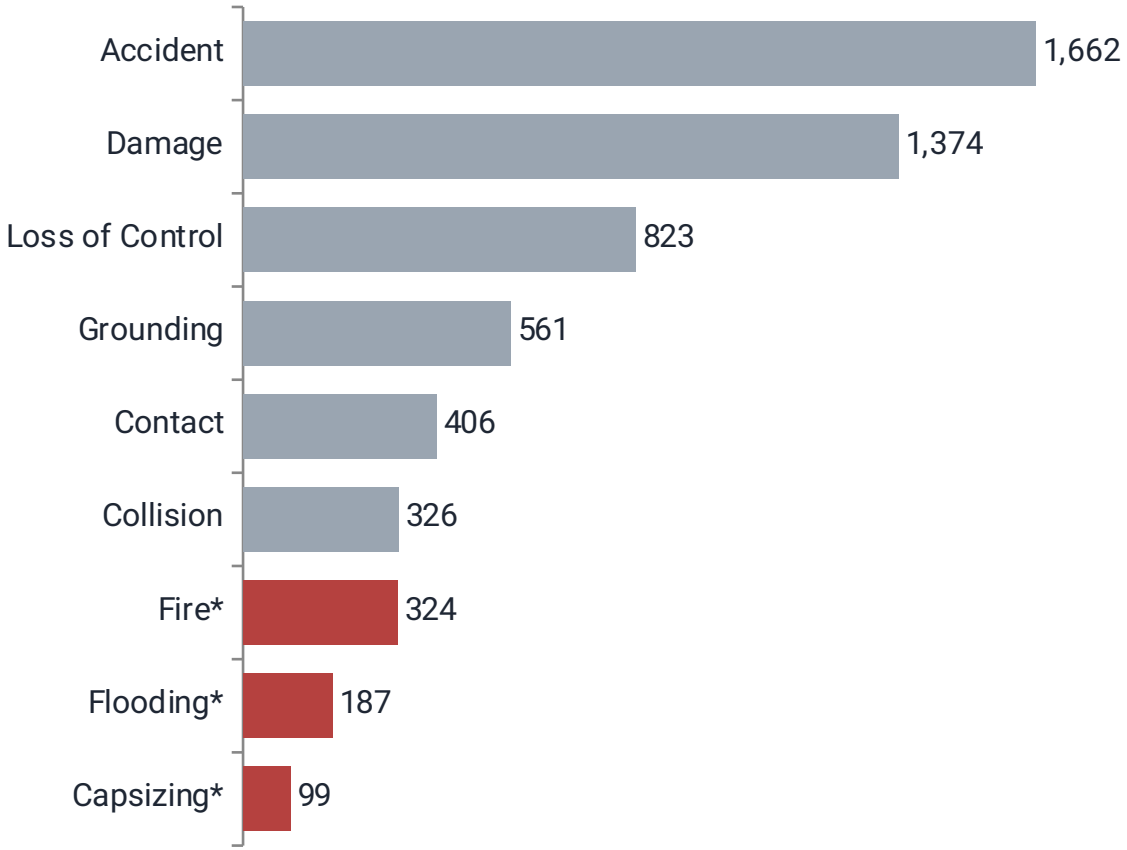
عدم‌توازن شدید

بزرگ‌ترین کلاس حدود 17 برابر کوچک‌ترین کلاس گزارش دارد.

ریسک کلاس‌های حیاتی

آتش‌سوزی، آب‌گرفتگی و واژگونی نادرند؛ مدلی که فقط accuracy را بهینه کند آن‌ها را نادیده می‌گیرد.

تعداد گزارش در هر کلاس (MAIB گزارش 5,762)



* کلاس‌های حیاتی

مطالعه‌ی مرجع چه چیزی را باز گذاشته بود

Zhao et al. (2025) · BERT + BiLSTM	این پژوهش
مدل‌ها با تنظیمات آموزش متفاوت مقایسه شده‌اند	یک دستورالعمل آموزش یکسان برای همه‌ی مدل‌ها
اجرای تکراری گزارش نشده است	دو seed برای هر پیکربندی و آزمون معناداری
معیار اصلی فقط accuracy است	Macro-F1 و Recall کلاس‌های حیاتی
داده‌ها عمومی نیستند	داده‌ی عمومی MAIB و نتایج قابل بازتولید

چارچوب پیشنهادی



مدل‌های پایه: روش کلاسیک TF-IDF + SVM، مدل BERT ساده، و مدل Zhao یعنی BERT + BiLSTM

طراحی آزمایش: مقایسه‌ی منصفانه و تکرارپذیر

داده

تقسیم طبقه‌ای 70/15/15: 4,033 آموزش، 864 اعتبارسنجی، 865 آزمون

تکرار

12 پیکربندی عصبی × 2 seed و 3 اجرای SVM؛ مجموعاً 27 اجرا

معیارها

Macro-F1 (معیار اصلی)، Macro-Precision و Recall، Accuracy، Recall کلاس‌های حیاتی

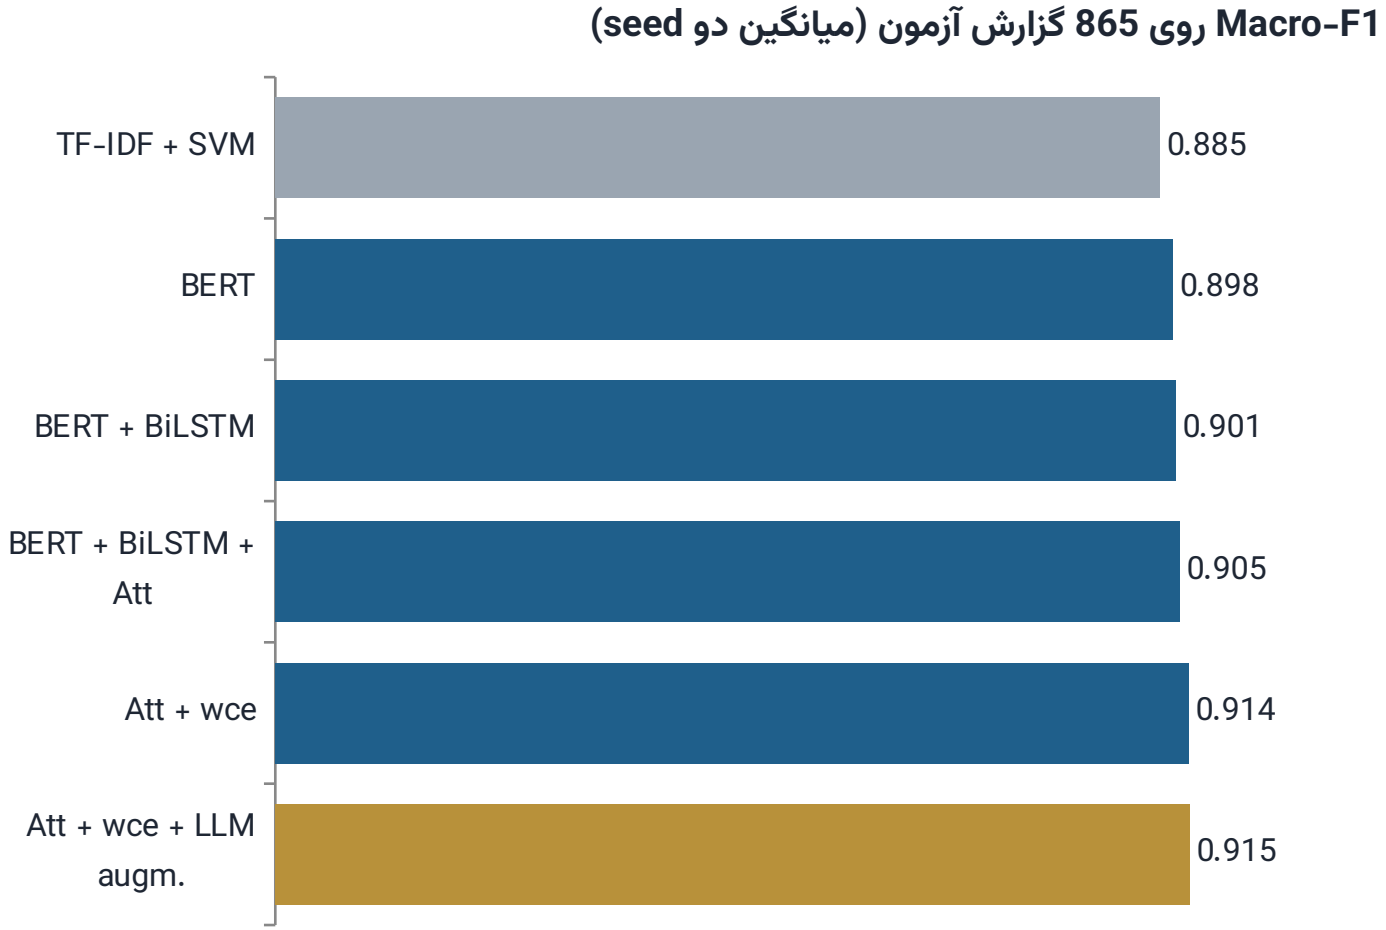
آزمون آماری

McNemar دقیق برای هر seed و بوت‌استرپ جفتی روی میانگین دو seed

تنظیمات مشترک همه‌ی مدل‌های مبتنی بر BERT

Setting	Value
Encoder	bert-base-uncased
Max. length	192 word-pieces
Effective batch	32 (8 × 4 accumulation)
Optimizer	AdamW, weight decay 0.01
Learning rate	2e-5 (BERT), 1e-3 (new layers)
Schedule	10% warm-up, linear decay
Epochs	max. 5, early stopping (patience 2)
Hardware	GTX 1650 Ti 4 GB, ≈75 min per run

همه‌ی مدل‌های مبتنی بر BERT از baseline بهترند



بهترین میانگین
Att + wce + LLM augmentation با 0.915 ± 0.002 و accuracy برابر ٪93.5 (SVM: ٪91.4)

هم‌تراز با wce
Att + wce با 0.914 ± 0.006؛ اختلاف 0.001 کمتر از نوسان بین seedهاست

سهم معماری
افزودن BiLSTM و سپس attention هر کدام حدود 0.004؛ در حد نوسان seed

تابع زیان وزن‌دار (wce) مؤثرترین روش بود

روش	Macro-F1	Recall حیاتی	اختلاف با ce
ce (پایه)	0.905	0.845	—
focal	0.905	0.858	0.000
cb	0.910	0.857	+0.005
oversampling	0.909	0.851	+0.003
LLM augmentation	0.908	0.862	+0.003
wce	**0.914**	**0.868**	**+0.009**
wce + LLM augmentation	**0.915**	**0.868**	**+0.010**

همه‌ی روش‌ها روی مدل BERT + BiLSTM + Att. حیاتی: میانگین Recall سه کلاس Fire، Flooding و Capsizing

wce

تغییر یک‌خطی تابع زیان: Macro-F1 +0.009 و Recall حیاتی +0.022

oversampling و focal

تغییر در حد نوسان seed

افزایش داده با LLM

برای SVM مفیدتر (+0.005)؛ روی wce فقط +0.001، ولی پراکندگی seedها را کم کرد (0.002 در برابر 0.006)

عملکرد روی کلاس‌های حیاتی

0.827 → 0.868

Recall میانگین کلاس‌های حیاتی: SVM ← مدل برتر

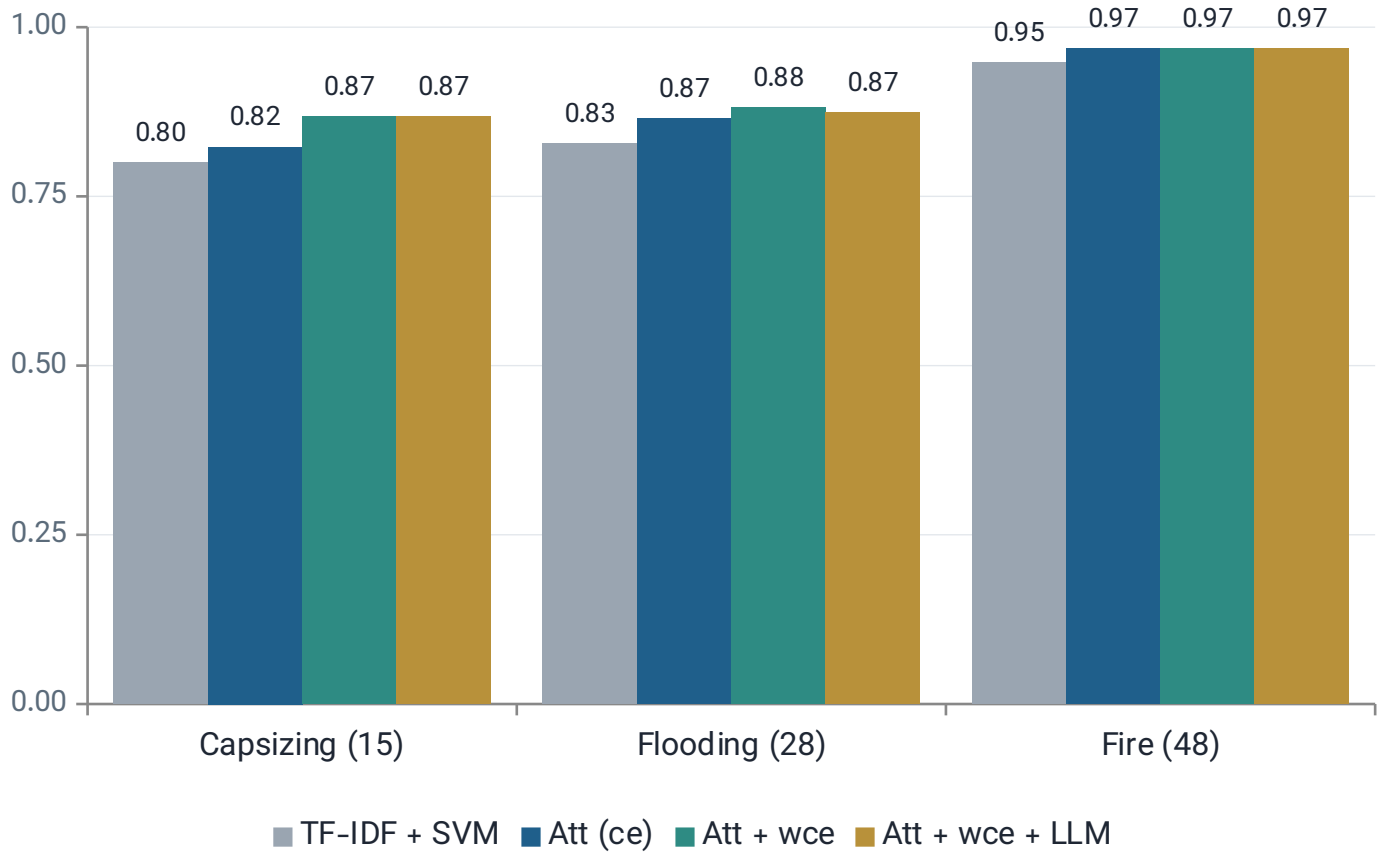
0.823 → 0.868

F1 کلاس Capsizing با افزودن wce

نکته‌ی صادقانه

BERT ساده بالاترین Recall حیاتی را دارد (0.873). تفاوت‌ها در حد نوسان seed است و فقط 15 گزارش Capsizing در آزمون هست.

F1 هر کلاس حیاتی روی داده‌ی آزمون (در پرانتز: تعداد گزارش آزمون)



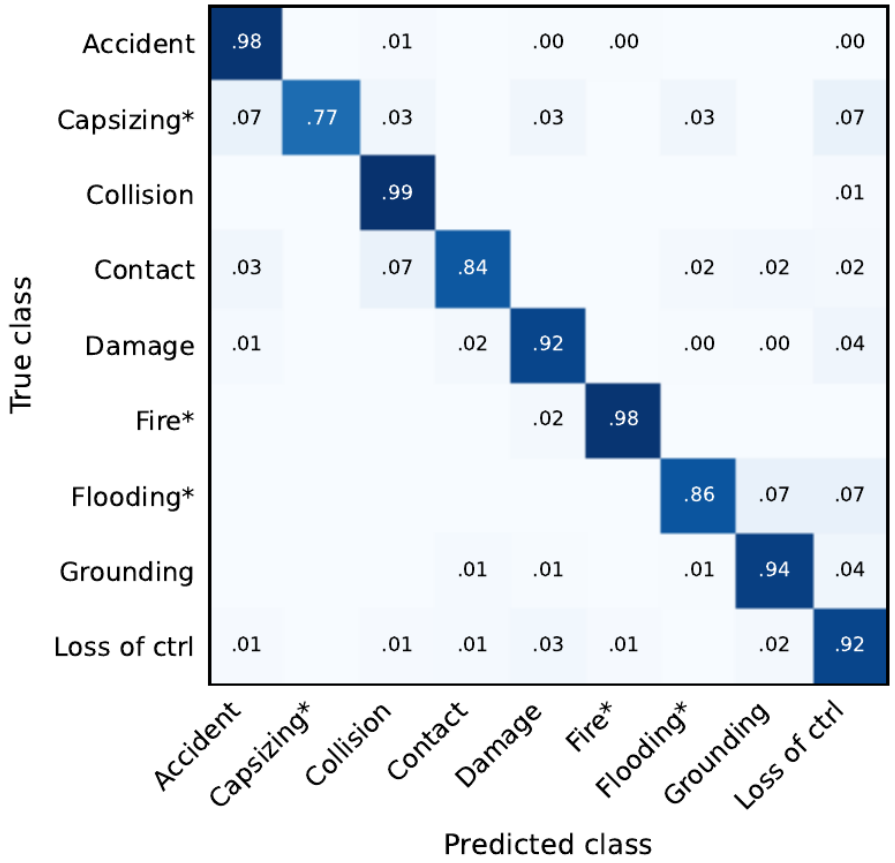
کدام تفاوت‌ها از نظر آماری معنادارند؟

مقایسه	اختلاف Macro-F1	بازه‌ی اطمینان ٪95	p	نتیجه
مدل برتر در برابر SVM	+0.031	[0.009, 0.056]	0.005	**معنادار**
Att + wce در برابر SVM	+0.030	[0.007, 0.059]	0.005	**معنادار**
BERT ساده در برابر SVM	+0.013	[-0.011, 0.039]	0.272	**معنادار نیست**
Att + wce در برابر Att (ce)	+0.009	[-0.003, 0.022]	0.142	**معنادار نیست**
BERT + BiLSTM در برابر BERT	+0.004	[-0.011, 0.018]	0.575	**معنادار نیست**
مدل برتر در برابر Att + wce	+0.001	[-0.007, 0.008]	0.839	**معنادار نیست**

بوت‌استرپ جفتی روی میانگین دو seed (2000 بازنمونه‌گیری). آزمون McNemar برای مدل برتر در برابر SVM: $p = 0.005$ و $p = 0.016$ در دو seed.

جمع‌بندی: فقط برتری مدل‌های دارای wce بر روش کلاسیک معنادار است؛ تفاوت‌های درون خانواده‌ی BERT معنادار نیستند.

خطاها بیشتر بین علت و پیامد هستند



پرتکرارترین خطاها (مدل برتر، دو seed، 112 خطا از 1,730 پیش‌بینی)

True class	Predicted as	Count
Damage	Loss of Control	17
Damage	Contact	8
Contact	Collision	8
Loss of Control	Damage	7
Grounding	Loss of Control	6

علت یا پیامد؟

نقص پیشرانش که به گیر کردن کشتی منجر می‌شود با هر دو برچسب قابل توصیف است، ولی هر گزارش فقط یک برچسب دارد. پس سقف حدود 0.91 احتمالاً از برچسب‌گذاری تک‌برچسبی می‌آید، نه از ظرفیت مدل.

لایه‌ی attention یک زیرگروه پنهان را نشان داد

Class	Top attention words (best model, seed 1)
Accident	passenger, fell, ship, cruise, sustained
Capsizing	capsized, boat, FRC, rescue, water
Collision	pilot, manoeuvring, collided, tanker, moored
Contact	contact, quayside, manoeuvring, cargo, lock
Damage	**SOLAS, ladder, pilot, regulations, conform**
Fire	engine, extinguish, caught, extinguished, smoke
Flooding	water, ingress, taking, started, motor
Grounding	grounded, aground, ran, water, rescue
Loss of Control	failure, engine, fishing, towed, fouled

کلمات عمومی (damage، crew، vessel و ...) حذف شده‌اند. FRC: قایق نجات سریع.

یافته

در کلاس Damage کلمات SOLAS، ladder و pilot بالاترین وزن را دارند: زیرگروهی تکرارشونده از گزارش‌های «نردبان راهنمای نامطابق با SOLAS» درون یک کلاس کلی.

احتیاط

وزن توجه نشان می‌دهد مدل به کجا نگاه کرده، نه اینکه چرا تصمیم گرفته.

اصلاحات انجام‌شده طبق نظر شما

- عنوان جدید مقاله
- چکیده به سبک مقالات مرجع، بدون نتایج عددی
- حذف سؤال‌های پژوهش (RQ)
- مقدمه با سه چالش اصلی و مرجع
- گسترش کارهای مرتبط در دو زیربخش
- توضیح ۳ تا ۴ خطی برای هر فرمول
- شکل ۱: یک pipeline با جعبه‌ی جدای تابع زیان
- بخش Evaluation: داده، تنظیمات، baseline، معیارها، بحث
- Precision و Recall کلی و جدول F1 هر کلاس
- بهترین پررنگ، دومی زیرخط‌دار؛ کپشن بدون ایتالیک
- بازبینی همه‌ی اعداد و اصلاح مدل برتر در کل متن
- ۶ صفحه، بدون مرجع کنفرانسی، برچسب Keywords

نسخه‌ی کامل در PR شماره‌ی 18 مخزن GitHub پروژه

همه‌ی اعداد از اجرای واقعی آزمایش‌ها آمده‌اند

27

اجرای مستقل، هر کدام با فایل نتیجه‌ی جداگانه

865

پیش‌بینی ذخیره‌شده برای هر اجرا، گزارش‌به‌گزارش

31 h

زمان کل آموزش روی GTX 1650 Ti (حدود 75 دقیقه هر اجرا)

27 / 27

فایل با بازمحاسبه‌ی Macro-F1 و accuracy از ماتریس درهم‌ریختگی سازگار است

- جدول‌های مقاله مستقیماً با کد (make_tables.py) از همین فایل‌ها ساخته می‌شوند؛ هیچ عددی دستی تایپ نشده است.
- فایل‌های نتیجه بین ۱۹ تا ۲۲ مهر با حساب GitHub خودم ثبت شده‌اند، همراه با loss هر epoch و زمان آموزش.
- امکان اجرای زنده در جلسه: baseline (TF-IDF + SVM) در حدود یک دقیقه دوباره اجرا می‌شود.

پرسش‌ها

تصمیم‌هایی که به نظر شما نیاز دارد

1. آیا ساختار جدید چکیده مورد تأیید است؟
2. ارجاع به مقاله‌ی اصلی BERT (کنفرانسی) و preprintهای arXiv مجاز است؟
3. ترتیب نویسندگان و محل انتشار هدف چه باشد؟
4. کد در GitHub منتشر و لینک آن در مقاله درج شود؟

گام‌های بعدی

- نهایی‌سازی مقاله با نظر شما
- در صورت صلاحدید: seed سوم برای تقویت آزمون‌ها
- نگارش فصل‌های پایان‌نامه

سپاس از راهنمایی‌های شما